

Clase 6: regresión logística, ¿sí o no?

Guía de lectura de las slides. Módulo 1: Introducción y fundamentos estadísticos, Diplomado en Ciencia de Datos Aplicada, UTFSM. Jueves 10 de septiembre de 2026.

Esta guía sigue el orden de las slides y sirve para repasar la clase o para leerla antes. Los números entre paréntesis son las slides donde aparece cada idea. El código completo está en el notebook `06_regresion_logistica.ipynb`.

El hilo de la clase

En las clases 4 y 5 la respuesta era un número (la duración de un viaje) y el modelo era una recta. Hoy la respuesta es un sí o un no: ¿este cliente dejará de pagar?, ¿este pasajero sobrevivió? La misma recta sirve, pero hay que pasarla por una curva. Y hay una idea que ordena toda la clase:

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros.

Dos ejemplos, ninguno de la EOD: 10.000 clientes de una tarjeta de crédito (datos del libro de James, Witten, Hastie y Tibshirani) y 891 pasajeros del Titanic.

Etapas 1: una respuesta que es sí o no (slides 5 a 8)

La variable respuesta y vale 1 (sí) o 0 (no), y hay una o más variables x con las que explicarla (slide 6). Un cliente tomado al azar es una **Bernoulli**: sí con probabilidad p , no con probabilidad $1 - p$. La media de una columna de ceros y unos es la fracción de unos, la **proporción**: en los clientes, $p = 0,033$, porque 333 de 10.000 dejaron de pagar (slides 7 y 8). Contar los síes entre n clientes es la binomial de la clase 5.

Un dato que importa al final: el sí es raro (3,3%).

Etapas 2: la recta no sirve (slides 9 y 10)

Si se ajusta la recta de mínimos cuadrados con la respuesta 0/1, la recta intenta ser una probabilidad y no lo logra: con saldo 0 predice $-0,08$, una probabilidad negativa, y con 2.000 dólares predice 0,18 cuando en ese tramo el 68% de los clientes no paga. Una probabilidad vive entre 0 y 1 y, en los datos, sube en forma de S: casi nadie deja de pagar hasta los 1.500 dólares y casi todos desde los 2.200. La recta no respeta ni el rango ni la forma.

Etapas 3: la regresión logística (slides 11 a 16)

La sigmoide (slide 12) es una función que toma cualquier número z y devuelve un número entre 0 y 1: en $z = 0$ vale 0,5, hacia la derecha se acerca a 1 y hacia la izquierda a 0, sin pasarse nunca. La **regresión logística** (slide 13) pasa la recta de siempre por esa función:

$$P(y = 1 \mid x) = 1 / (1 + e^{-(a + b \cdot x)})$$

donde $P(y = 1 \mid x)$ es la probabilidad de un sí dado x , y $a + b \cdot x$ es la recta. La misma ecuación, despejada, dice que la recta es el logaritmo de las **chances** (en inglés, odds), la razón sí contra no:

$$\log(P / (1 - P)) = a + b \cdot x$$

Con $P = 0,8$ las chances son $0,8 / 0,2 = 4$: cuatro síes por cada no. Como la recta está en escala de logaritmo, **e^b dice cuánto se multiplican las chances por cada unidad de x** , igual que en el modelo en log de la clase 4.

Cómo se lee b (slide 14). Con el saldo en cientos de dólares, $b = 0,55$ y $e^b = 1,73$: cada 100 dólares más de saldo multiplican las chances de no pagar por 1,7. En probabilidades: 0,01 con 1.000 dólares, 0,08 con 1.500, 0,59 con 2.000. La curva cruza 0,5 en 1.937 dólares.

Cómo se ajusta (slide 15). No por mínimos cuadrados, porque con un 0/1 no hay una distancia vertical con sentido, sino por **máxima verosimilitud**: se eligen los a y b que hacen más probable haber observado exactamente estos síes y noes. statsmodels lo resuelve por iteraciones; en el notebook, `smf.logit` con la misma sintaxis de fórmulas que `smf.ols` (slide 16), y `predict` entrega probabilidades.

Etapa 4: el mismo summary (slides 17 a 23)

El summary tiene las columnas de la clase 5: coeficiente, error estándar (EE), z , valor p e intervalo (slide 18). La única diferencia es z en lugar de t : con muchos datos la referencia es la normal en vez de la t de Student, y $P > |z|$ se lee igual que $P > |t|$.

Varias variables (slides 19 y 20). Solos, los estudiantes dejan de pagar más (4,3% contra 2,9%). Pero los estudiantes deben más (saldo medio 988 dólares contra 772), y a igual saldo dejan de pagar menos. Al poner el saldo en el modelo, el coeficiente de estudiante cambia de signo: $e^{(-0,65)} = 0,52$, a igual saldo e ingreso las chances de un estudiante son la mitad. Es la confusión de variables de la clase 4, ahora en la logística; `estudiante` es una dummy, como lo era el modo de transporte. El ingreso no aporta ($p = 0,71$): con el saldo en el modelo no dice nada nuevo.

El Titanic (slides 21 a 23). 891 pasajeros; el 74% de las mujeres sobrevivió contra el 19% de los hombres, y la clase del pasaje ordena a ambos grupos. El modelo usa el sexo, la clase (categórica, con dummies) y la edad, que falta en 177 pasajeros. Cada e^b compara con una referencia, a igualdad de las otras variables: las chances de sobrevivir de una mujer son 12 veces las de un hombre ($e^{2,52}$); las de la tercera clase, el 8% de las de la primera ($e^{-2,58}$); cada año de edad las multiplica por 0,96. Con varias variables, la recta suma el aporte de cada

una y la sigmoide da la probabilidad: 0,94 para una mujer de primera clase de 30 años, 0,08 para un hombre de tercera de la misma edad.

Etapa 5: clasificar (slides 24 a 33)

El umbral (slide 25). Un clasificador convierte la probabilidad en un sí o un no con un umbral; el más simple es 0,5. Con él, el modelo dice "no paga" desde los 1.937 dólares de saldo.

La matriz de confusión (slide 26) cruza lo real (filas) con lo predicho (columnas). La diagonal son los aciertos: verdaderos positivos y verdaderos negativos. Fuera de ella, los dos errores:

- **Falso negativo**: era sí y el modelo dijo no. Un cliente que no pagará y recibió la tarjeta (233 en el ejemplo).
- **Falso positivo**: era no y el modelo dijo sí. Un cliente que sí pagaba y a quien se le negó (42 en el ejemplo).

Los dos errores no cuestan lo mismo, y cuál cuesta más lo dice el problema, no el modelo (slide 27): para el banco, el falso negativo es dinero perdido y el falso positivo, un cliente perdido; para un filtro de correo, el falso positivo es un mensaje real en la carpeta de spam; para un examen médico, el falso negativo es una enfermedad sin detectar.

La exactitud engaña cuando el sí es raro (slide 28). La exactitud es la fracción de aciertos: el modelo acierta el 97,3%, pero decir que nadie deja de pagar acierta el 96,7%. De los 333 clientes que no pagan, el modelo detecta 100. Con un sí raro, la exactitud mide sobre todo lo fácil: los noes.

Sensibilidad y especificidad (slide 29) salen de la misma matriz y no engañan:

- **Sensibilidad** = $VP / (VP + FN)$: de los que eran sí, qué fracción detectó el modelo. En el ejemplo, $100 / 333 = 0,30$.
- **Especificidad** = $VN / (VN + FP)$: de los que eran no, qué fracción dejó en paz. En el ejemplo, $9.625 / 9.667 = 0,996$.

El umbral es una decisión (slide 30). Bajar el umbral sube la sensibilidad y baja la especificidad, siempre. Con umbral 0,2 se detectan 199 de los 333 morosos a cambio de 263 falsos positivos, y la exactitud baja, lo que no importa. No hay umbral correcto: hay un balance entre los dos errores, y lo fija el costo de cada uno. La **curva ROC** (slide 31) dibuja ese balance para todos los umbrales: sensibilidad contra 1 - especificidad, un punto por umbral; cuanto más se pega a la esquina superior izquierda, mejor separa el modelo, y la diagonal es adivinar al azar.

El Titanic como clasificador (slide 32). Con un sí frecuente (41%), la exactitud sí informa: 79% contra el 59% de decir que todos murieron. Sensibilidad 0,71 y especificidad 0,84: el modelo se equivoca más con los que sobrevivieron.

Evaluar fuera de la muestra (slide 33). Medir la exactitud en los mismos datos con que se ajustó el modelo es hacer trampa: el modelo ya los vio. Se separa al azar una parte de **prueba** antes de ajustar; el modelo se ajusta solo con la parte de **entrenamiento** y se mide en la de prueba. Con modelos simples como los de hoy las dos cifras se parecen; con modelos más flexibles la de

entrenamiento sube y la de prueba no, y la de prueba es la única que vale. Es el punto de partida de la evaluación de modelos en el resto del diplomado.

La respuesta a la pregunta de la clase (slides 34 y 35)

El modelo no dice quién deja de pagar ni quién sobrevivió: dice con qué probabilidad. El sí o el no lo ponemos nosotros con el umbral, y con él elegimos cuántos falsos positivos y cuántos falsos negativos aceptar. La exactitud sola no basta: hay que mirar los dos errores por separado, y medirlos en datos que el modelo no vio.

En el notebook

Sección	Qué se hace
2	La proporción, la binomial y la fracción que no paga por tramo de saldo.
3	La recta sobre el 0/1 y sus predicciones fuera de rango.
4	<code>smf.logit</code> , e^b , <code>predict</code> , la curva, el summary y el intervalo de e^b .
5	El estudiante con y sin el saldo; el Titanic con <code>C(clase)</code> ; los perfiles.
6	El umbral, <code>pd.crosstab</code> , la función <code>evaluar</code> , la tabla de umbrales y la curva ROC.
7	Reparto entrenamiento y prueba, y la exactitud en cada parte.

Glosario

- **Bernoulli**: variable que vale 1 con probabilidad p y 0 con probabilidad $1 - p$.
- **Proporción**: la media de una columna de ceros y unos; la fracción de síes.
- **Sigmoide**: función que convierte cualquier número en una probabilidad entre 0 y 1.
- **Chances (odds)**: $P / (1 - P)$, la razón sí contra no.
- e^b : cuánto se multiplican las chances por cada unidad de x .
- **Máxima verosimilitud**: el criterio de ajuste de la logística; elige los coeficientes que hacen más probable lo observado.
- **z**: el t del summary cuando la referencia es la normal; $P > |z|$ se lee igual que $P > |t|$.
- **Umbral**: la probabilidad a partir de la cual el clasificador dice sí.
- **Matriz de confusión**: la tabla de lo real contra lo predicho.
- **Falso positivo**: el modelo dijo sí y era no. **Falso negativo**: el modelo dijo no y era sí.
- **Exactitud**: fracción de aciertos sobre el total.
- **Sensibilidad**: fracción de los síes reales que el modelo detectó.
- **Especificidad**: fracción de los noes reales que el modelo dejó en paz.
- **Curva ROC**: sensibilidad contra $1 -$ especificidad para todos los umbrales.
- **Entrenamiento y prueba**: la parte de los datos con que se ajusta el modelo y la parte, separada antes, en que se mide.

Referencias

- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2a ed.). Springer. Capítulo 4 (regresión logística) y sección 5.1 (conjunto de validación). Disponible gratis en statlearning.com.
- Diez, D., Çetinkaya-Rundel, M. y Barr, C. (2019). *OpenIntro Statistics* (4a ed.). Sección 9.5 (regresión logística). Disponible gratis en openintro.org.
- Datos: `Default`, del libro de James et al. (statlearning.com), y `Titanic`, del repositorio seaborn-data (github.com/mwaskom/seaborn-data). Ambos en `datos/clase06/`.