

Clase 6: regresión logística, ¿sí o no?

Guía de lectura de las slides. Módulo 1: Introducción y fundamentos estadísticos, Diplomado en Ciencia de Datos Aplicada, UTFSM. Jueves 10 de septiembre de 2026.

Esta guía sigue el orden de las slides y sirve para repasar la clase o para leerla antes. Los números entre paréntesis son las slides donde aparece cada idea. El código completo está en el notebook `06_regresion_logistica.ipynb`.

El hilo de la clase

En las clases 4 y 5 la respuesta era un número (la duración de un viaje) y el modelo era una recta. Hoy la respuesta es un sí o un no: ¿este cliente dejará de pagar?, ¿este pasajero sobrevivió? La misma recta sirve, pero hay que pasarla por una curva. Y hay una idea que ordena toda la clase:

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros.

Dos ejemplos, ninguno de la EOD: 10.000 clientes de una tarjeta de crédito (datos del libro de James, Witten, Hastie y Tibshirani), con su deuda en la tarjeta, es decir, lo que deben después del pago mensual, su ingreso anual y si son estudiantes; y 891 pasajeros del Titanic.

Etapas 1: una respuesta que es sí o no (slides 5 a 8)

La variable respuesta y vale 1 (sí) o 0 (no), y hay una o más variables x con las que explicarla (slide 6). Un cliente tomado al azar es una **Bernoulli**: sí con probabilidad p , no con probabilidad $1 - p$. La media de una columna de ceros y unos es la fracción de unos, la **proporción**: en los clientes, 333 de 10.000 dejaron de pagar, $p = 333 / 10.000 = 0,033$, y $1 - p = 0,967$ (slides 7 y 8). Es la distribución más simple que existe: dos resultados y una probabilidad.

Un dato que importa al final: el sí es raro (3,3%).

Etapas 2: la recta no sirve (slides 9 a 11)

La probabilidad de no pagar, por tramo de deuda (slide 10). Se agrupan los clientes por **tramo** de deuda, un intervalo de 300 dólares (0 a 300, 300 a 600, y así hasta 2.700: nueve tramos), y en cada tramo se cuenta cuántos clientes hay y cuántos dejaron de pagar. En el tramo de 1.800 a 2.100 dólares hay 229 clientes y 114 dejaron de pagar: $114 / 229 = 0,50$. Esa fracción es la probabilidad de no pagar de un cliente con esa deuda, estimada con los datos, y es un punto del gráfico: nueve tramos, nueve puntos, que suben en forma de S: casi 0 con deudas bajas, 0,50 entre 1.800 y 2.100 dólares, 1 desde los 2.400.

La recta (slide 11). Si se ajusta la recta de mínimos cuadrados de la clase 4 con la respuesta 0/1, lo que predice para cada deuda es el promedio de y entre los clientes con esa deuda, y el promedio de una columna de ceros y unos es la fracción de unos: la recta predice la fracción que no paga según la deuda, la misma cantidad que las fracciones por tramo estiman sin modelo, y por eso se pueden comparar. La recta intenta ser una probabilidad y no lo logra: con deuda 0 predice -0,08, una probabilidad negativa, y con 2.000 dólares predice 0,18 cuando la fracción real de ese tramo es 0,50. Una probabilidad vive entre 0 y 1 y las fracciones suben en forma de S; la recta no respeta ni el rango ni la forma. La curva que sí lo hace es la regresión logística.

Etapas 3: la regresión logística (slides 12 a 20)

La idea central de esta etapa: la regresión logística no inventa una curva. Pone la recta de siempre en una escala donde no puede salirse de rango, y la S es cómo se ve esa recta al volver a las probabilidades. Se construye en tres pasos.

Los odds (chances) (slide 13). Son la probabilidad dicha de otra forma: cuántos síes hay por cada no, $\text{odds} = P / (1 - P)$. Con $P = 0,8$, de cada 10 clientes 8 no pagan y 2 pagan: odds $8 / 2 = 4$, cuatro a uno. Con $P = 0,5$, uno a uno. Con $P = 0,2$, 0,25, uno a cuatro. Los odds van de 0 a infinito: ya no tienen el techo de 1, pero no pueden ser negativas.

El logaritmo de los odds (slide 14). $\log(4) = 1,39$, $\log(1) = 0$, $\log(0,25) = -1,39$: negativo cuando el sí es menos probable que el no, cero cuando empatan, positivo cuando el sí es más probable. Puede ser cualquier número, sin techo ni piso: en esta escala sí cabe una recta. Además, el logaritmo convierte multiplicar en sumar: multiplicar los odds por 4 es sumar 1,39.

La misma relación en tres escalas (slide 15). Con los nueve tramos de la slide 10: el logaritmo de los odds de cada tramo contra la deuda sigue una recta, y eso es lo que el modelo supone. Al deshacer el logaritmo, la recta se vuelve una exponencial; al pasar de odds a probabilidad, la exponencial se vuelve la S. La recta y la S son la misma relación vista en dos escalas.

La fórmula (slide 16). El modelo es:

$$\log(P / (1 - P)) = a + b \cdot x$$

donde P es la probabilidad de un sí dado x, $P / (1 - P)$ son los odds, y $a + b \cdot x$ es la recta. Despejando P (se toma e a ambos lados y se ordena) queda:

$$P(y = 1 \mid x) = 1 / (1 + e^{-(a + b \cdot x)})$$

Por eso el exponente es $a + b \cdot x$: es la recta del modelo, que reaparece al despejar. Y como sumar b en el logaritmo es multiplicar afuera por e^b , **e^b dice cuánto se multiplican los odds por cada unidad de x**, igual que en el modelo en log de la clase 4.

La sigmoide (slide 17) es la función que apareció al despejar: toma el logaritmo de los odds z, cualquier número, y devuelve la probabilidad, entre 0 y 1. En $z = 0$ (odds uno a uno) vale 0,5; hacia la derecha se acerca a 1 y hacia la izquierda a 0, sin pasarse nunca.

Cómo se lee b (slide 18). Con la deuda en cientos de dólares, $b = 0,55$ y $e^b = 1,73$: cada 100 dólares más de deuda multiplican los odds de no pagar por 1,7. En probabilidades: 0,01 con 1.000 dólares, 0,08 con 1.500, 0,59 con 2.000. La curva cruza 0,5 en 1.937 dólares.

Cómo se ajusta (slide 19). No por mínimos cuadrados, porque con un 0/1 no hay una distancia vertical con sentido, sino por **máxima verosimilitud**: se eligen los a y b que hacen más probable haber observado exactamente estos síes y noes. statsmodels lo resuelve por iteraciones; en el notebook, `smf.logit` con la misma sintaxis de fórmulas que `smf.ols` (slide 20), y `predict` entrega probabilidades.

Etapa 4: el mismo summary (slides 21 a 29)

El summary tiene las columnas de la clase 5: coeficiente, error estándar (EE), z , valor p e intervalo (slide 22). La única diferencia es z en lugar de t : con muchos datos la referencia es la normal en vez de la t de Student, y $P > |z|$ se lee igual que $P > |t|$.

Varias variables (slides 23 y 24). Solos, los estudiantes dejan de pagar más (4,3% contra 2,9%). Pero los estudiantes deben más (deuda media 988 dólares contra 772), y a igual deuda dejan de pagar menos. Al poner la deuda en el modelo, el coeficiente de estudiante cambia de signo: $e^{-0,65} = 0,52$, a igual deuda e ingreso los odds de un estudiante son la mitad. Es la confusión de variables de la clase 4, ahora en la logística; `estudiante` es una dummy, como lo era el modo de transporte. El ingreso no aporta ($p = 0,71$): con la deuda en el modelo no dice nada nuevo.

El modelo final de los clientes, escrito (slide 25):

$$\log(P / (1 - P)) = -10,87 + 0,57 \cdot \text{deuda}_{100} - 0,65 \cdot \text{estudiante} + 0,003 \cdot \text{ingreso}$$

donde deuda_{100} es la deuda en cientos de dólares, `estudiante` vale 1 o 0 e ingreso está en miles de dólares; P sale de la sigmoide, $P = 1 / (1 + e^{-z})$ con z la recta. Un estudiante con 2.000 dólares de deuda y 20 mil de ingreso: $z = -10,87 + 0,57 \cdot 20 - 0,65 + 0,003 \cdot 20 = 0,02$, y $P = 0,50$, justo en la frontera.

El mecanismo, con un ejemplo inventado de 200 clientes:

	no estudiantes	estudiantes
deuda baja	80 clientes, 4 no pagan (5%)	20 clientes, 0 no pagan (0%)
deuda alta	20 clientes, 10 no pagan (50%)	80 clientes, 32 no pagan (40%)
total	100 clientes, 14 no pagan (14%)	100 clientes, 32 no pagan (32%)

Dentro de cada tramo los estudiantes pagan mejor, pero 80 de los 100 estudiantes están en el tramo de deuda alta y solo 20 de los 100 no estudiantes, así que en el total parecen peores. El modelo con solo `estudiante` lee el total; el modelo con la deuda compara dentro de cada tramo. Ninguno se equivoca en la aritmética: responden preguntas distintas, y la segunda es la que interesa.

El Titanic (slides 26 a 29). 891 pasajeros; el 74% de las mujeres sobrevivió contra el 19% de los hombres, y la clase del pasaje ordena a ambos grupos. El modelo usa el sexo, la clase (categórica, con dummies) y la edad, que falta en 177 pasajeros. Cada e^b compara con una referencia, a igualdad de las otras variables: los odds de sobrevivir de una mujer son 12 veces las de un hombre ($e^{2,52}$); las de la tercera clase, el 8% de las de la primera ($e^{-2,58}$); cada año de edad las multiplica por 0,96. Con varias variables, la recta suma el aporte de cada una y la sigmoide da la probabilidad: 0,94 para una mujer de primera clase de 30 años, 0,08 para un hombre de tercera de la misma edad.

El modelo del Titanic, escrito (slide 28):

$$\log(P / (1 - P)) = 1,25 + 2,52 \cdot \text{mujer} - 1,31 \cdot \text{clase2} - 2,58 \cdot \text{clase3} - 0,037 \cdot \text{edad}$$

donde mujer vale 1 para las mujeres y 0 para los hombres (la referencia), y clase2 y clase3 valen 1 en segunda y tercera clase y las dos valen 0 en primera (la referencia). Una mujer de primera clase de 30 años: $z = 1,25 + 2,52 - 0,037 \cdot 30 = 2,7$, $P = 0,93$.

Etapas 5: clasificar (slides 30 a 37)

El umbral (slide 31). Un clasificador convierte la probabilidad en un sí o un no con un umbral; el más simple es 0,5. Con él, el modelo dice "no paga" desde los 1.937 dólares de deuda.

La matriz de confusión (slide 32) cruza lo real (filas) con lo predicho (columnas). La diagonal son los aciertos: verdaderos positivos y verdaderos negativos. Fuera de ella, los dos errores:

- **Falso negativo:** era sí y el modelo dijo no. Un cliente que no pagará y recibió la tarjeta (233 en el ejemplo).
- **Falso positivo:** era no y el modelo dijo sí. Un cliente que sí pagaba y a quien se le negó (42 en el ejemplo).

Los dos errores no cuestan lo mismo, y cuál cuesta más lo dice el problema, no el modelo (slide 33): para el banco, el falso negativo es dinero perdido y el falso positivo, un cliente perdido; para un filtro de correo, el falso positivo es un mensaje real en la carpeta de spam; para un examen médico, el falso negativo es una enfermedad sin detectar. Cómo elegir el umbral según ese costo queda para la próxima clase.

La exactitud (slide 34) es la fracción de aciertos: la diagonal de la matriz dividida por el total, $(VP + VN) / n = (100 + 9.625) / 10.000 = 0,973$. Hay que compararla con la **base**, la exactitud de no tener modelo y predecir siempre la clase más frecuente: decir que todos pagan acierta $9.667 / 10.000 = 0,967$.

La exactitud engaña cuando el sí es raro (slide 35). Comparadas: el modelo acierta el 97,3%, pero decir que nadie deja de pagar acierta el 96,7%. De los 333 clientes que no pagan, el modelo detecta 100. Con un sí raro, la exactitud mide sobre todo lo fácil: los noes.

Lo que queda para la próxima clase. Dos medidas que salen de la misma matriz y no engañan cuando el sí es raro (sensibilidad y especificidad), cómo elegir el umbral según el costo de cada

error, y la curva ROC, se ven el martes 15.

El Titanic como clasificador (slide 36). Con un sí frecuente (41%), la exactitud sí informa: 79% contra el 59% de decir que todos murieron. Los errores: 83 falsos negativos (pasajeros que sobrevivieron y el modelo daba por muertos) y 68 falsos positivos.

Evaluar fuera de la muestra (slide 37). Medir la exactitud en los mismos datos con que se ajustó el modelo es hacer trampa: el modelo ya los vio. Se separa al azar una parte de **prueba** antes de ajustar; el modelo se ajusta solo con la parte de **entrenamiento** y se mide en la de prueba. Con modelos simples como los de hoy las dos cifras se parecen; con modelos más flexibles la de entrenamiento sube y la de prueba no, y la de prueba es la única que vale. Es el punto de partida de la evaluación de modelos en el resto del diplomado.

La respuesta a la pregunta de la clase (slides 38 y 39)

El modelo no dice quién deja de pagar ni quién sobrevivió: dice con qué probabilidad. El sí o el no lo ponemos nosotros con el umbral, y cada umbral deja una cantidad de falsos positivos y de falsos negativos. La exactitud sola no basta: hay que mirar los dos errores por separado, y medirlos en datos que el modelo no vio.

En el notebook

Sección	Qué se hace
2	La proporción p .
3	La fracción que no paga por tramo de deuda: los nueve puntos.
4	La recta sobre el 0/1: predicciones fuera de rango y lejos de los puntos.
5	<code>smf.logit</code> , e^b , <code>predict</code> , la curva, el summary y el intervalo de e^b .
6	El caso del estudiante paso a paso: el total, la deuda por grupo, la comparación por tramo y los dos modelos; después el ingreso.
7	Otro problema: el Titanic con <code>C(clase)</code> y los perfiles.
8	El umbral 0,5, la matriz de confusión con <code>pd.crosstab</code> , los dos errores, la exactitud contra la base y el Titanic como clasificador.
9	Reparto entrenamiento y prueba, y la exactitud en cada parte.

Glosario

- **Bernoulli**: variable que vale 1 con probabilidad p y 0 con probabilidad $1 - p$; la distribución de un sí o no.
- **Proporción**: la media de una columna de ceros y unos; la fracción de síes.
- **Odds (chances)**: $P / (1 - P)$, cuántos síes por cada no; van de 0 a infinito.
- **Logaritmo de los odds (logit)**: la escala en que la logística es una recta; cualquier número, positivo o negativo.
- **Sigmoide**: la función que devuelve la probabilidad a partir del logaritmo de los odds; siempre entre 0 y 1.

- **e^b** : cuánto se multiplican los odds por cada unidad de x .
- **Máxima verosimilitud**: el criterio de ajuste de la logística; elige los coeficientes que hacen más probable lo observado.
- **z**: el t del summary cuando la referencia es la normal; $P > |z|$ se lee igual que $P > |t|$.
- **Umbral**: la probabilidad a partir de la cual el clasificador dice sí.
- **Matriz de confusión**: la tabla de lo real contra lo predicho.
- **Falso positivo**: el modelo dijo sí y era no. **Falso negativo**: el modelo dijo no y era sí.
- **Exactitud**: fracción de aciertos sobre el total.
- **Entrenamiento y prueba**: la parte de los datos con que se ajusta el modelo y la parte, separada antes, en que se mide.

Referencias

- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2a ed.). Springer. Capítulo 4 (regresión logística) y sección 5.1 (conjunto de validación). Disponible gratis en statlearning.com.
- Diez, D., Çetinkaya-Rundel, M. y Barr, C. (2019). *OpenIntro Statistics* (4a ed.). Sección 9.5 (regresión logística). Disponible gratis en openintro.org.
- Datos: `Default`, del libro de James et al. (statlearning.com), y `Titanic`, del repositorio seaborn-data (github.com/mwaskom/seaborn-data). Ambos en `datos/clase06/`.