

Evaluación 2: Primer análisis exploratorio de datos

Diplomado en Ciencia de Datos Aplicada, Módulo 1: Introducción y fundamentos estadísticos.

Ponderación: 40% del módulo. Resultado de aprendizaje RA1.1.

El primer análisis exploratorio aplica a los datos del proyecto lo trabajado en las clases 2 a 4: describir, limpiar, relacionar y graficar, con el norte puesto en los modelos que vienen. Se evalúa con la [rúbrica publicada](#), que conviene leer antes de empezar.

Condiciones de entrega

- Equipos de dos personas; un envío por equipo, con los nombres de sus integrantes.
- Un notebook de Jupyter (.ipynb) ejecutado de principio a fin, con NumPy, Pandas y Matplotlib, por el aula virtual. Si los datos no se pueden adjuntar (por tamaño o confidencialidad), el notebook debe indicar cómo obtenerlos o incluir una muestra que permita ejecutarlo.
- Alternativa: entregar el notebook en un repositorio de GitHub. En ese caso, el equipo debe dar acceso de lectura a los ayudantes del curso y subir al aula virtual un PDF con el link al repositorio.
- Si el preprocesamiento de los datos es extenso, el notebook puede partir de un punto intermedio (por ejemplo, de una tabla ya limpia), siempre que el resultado sea reproducible: se adjunta esa tabla intermedia junto con el código o una descripción de cómo se obtuvo. Si los datos son confidenciales y no se pueden compartir, debe declararse en el notebook.
- NumPy, Pandas y Matplotlib son la base que pide el programa, no un límite: se pueden usar además otras bibliotecas de ciencia de datos (seaborn, SciPy y similares), sin penalización.
- Fecha de entrega: martes 15 de septiembre de 2026.

Qué debe contener el notebook

El notebook se organiza en cinco secciones, una por criterio de la rúbrica. Antes de cada análisis, declare su objetivo en una línea: qué se quiere relacionar o revisar, y por qué.

1. **Los datos y su calidad.** La carga desde su fuente (declarada), el tamaño de las tablas y los tipos de variables. La revisión de calidad de la clase 2: valores faltantes (incluidos los disfrazados, como códigos 999 o valores -1), duplicados y valores imposibles según el dominio; si hay merges, verificados con conteos antes y después. Cada decisión de limpieza se documenta en una línea.
2. **Estadística descriptiva.** Tendencia central, dispersión y forma de las variables relevantes, con su interpretación en el contexto del problema. Si sus datos traen factores de expansión o pesos de muestreo, úselos.
3. **Análisis bivariado.** Las relaciones que apuntan a su pregunta: correlaciones (Pearson, y Spearman cuando hay atípicos o curvas), la matriz de correlación si hay varias cuantitativas, y

grupos o tablas de contingencia si hay categóricas. Interprete lo que los datos muestran, no más que eso.

4. **Visualización.** Al menos tres gráficos de tipos distintos, elegidos según la variable y la pregunta (histograma, boxplot, dispersión, barras, línea de tendencia u otros). Todo gráfico lleva título y ejes nombrados con claridad, con sus unidades. El overplotting y las colas largas se tratan cuando aparecen (transparencia, hexbin, escala logarítmica).
5. **Hallazgos y siguientes pasos.** De 3 a 5 hallazgos escritos en frases completas, y qué modelo imaginan ajustar en el avance del proyecto.

Uso de inteligencia artificial

Se aplica la regla del módulo: el uso de IA generativa está permitido con declaración (qué herramienta se usó y para qué). Debe entender y poder explicar cualquier parte de lo que entregue.