

Rúbrica: Primer análisis exploratorio de datos

Diplomado en Ciencia de Datos Aplicada, Módulo 1: Introducción y fundamentos estadísticos.

Ponderación: 40% del módulo. Resultado de aprendizaje RA1.1.

Entrega

- Equipos de dos personas; un envío por equipo, con los nombres de sus integrantes.
- Un notebook de Jupyter (.ipynb) ejecutado de principio a fin, con NumPy, Pandas y Matplotlib, por el aula virtual.
- Alternativa: un repositorio de GitHub con el notebook, con acceso de lectura para los ayudantes del curso y un PDF con el link subido al aula virtual.
- Si el preprocesamiento es extenso, el notebook puede partir de una tabla intermedia, siempre que sea reproducible (tabla adjunta y cómo se obtuvo). Los datos confidenciales que no se pueden compartir deben declararse.
- Fecha de entrega: martes 15 de septiembre de 2026.

Qué se evalúa

Según el programa de la asignatura, esta evaluación mide el desarrollo de código en el ecosistema Python (NumPy, Pandas y Matplotlib) para explorar los datos del propio proyecto. El notebook debe cubrir los cinco criterios de la tabla; el [enunciado](#) detalla qué va en cada sección.

Criterio	Logrado	Parcialmente logrado	No logrado	Puntaje
1. Los datos y su calidad	Carga desde una fuente declarada, tipos revisados; faltantes (incluidos los disfrazados), duplicados y valores imposibles detectados y resueltos, con cada decisión documentada; merges verificados (17 a 20 pts)	Revisión parcial: detecta problemas pero no documenta decisiones, o pasa por alto faltantes disfrazados y rangos del dominio (9 a 16 pts)	Los datos se usan tal cual, sin revisión de calidad (0 a 8 pts)	20
2. Estadística descriptiva	Centro, dispersión y forma de las variables relevantes, interpretados en el	Resúmenes calculados pero poco interpretados, o resúmenes sensibles (media,	Resúmenes ausentes o sin relación con la pregunta del proyecto (0 a 8 pts)	20

Criterio	Logrado	Parcialmente logrado	No logrado	Puntaje
	contexto del problema; usa los pesos o factores de expansión cuando los datos los traen (17 a 20 pts)	desviación) donde los robustos correspondían (9 a 16 pts)		
3. Análisis bivariado	Cada análisis declara su objetivo; correlaciones bien elegidas (Pearson y Spearman) e interpretadas por lo que los datos muestran; matriz, grupos o tablas de contingencia según los tipos de variables, apuntando a la pregunta del proyecto (21 a 25 pts)	Relaciones calculadas pero sin objetivo declarado, o con interpretaciones que van más allá de lo que los datos muestran (11 a 20 pts)	Sin análisis de relaciones, o relaciones ajenas a la pregunta (0 a 10 pts)	25
4. Visualización	Al menos tres gráficos de tipos distintos (histograma, boxplot, dispersión, barras, línea u otros), elegidos según la variable y la pregunta; todos con título y ejes nombrados con claridad (con unidad); overplotting y colas largas tratados cuando aparecen; cada gráfico se interpreta por lo que muestra (17 a 20 pts)	Gráficos correctos pero de menos de tres tipos, con títulos o rótulos incompletos, o sin interpretación; saturación o colas largas sin tratar (9 a 16 pts)	Gráficos ilegibles, sin título ni rótulos, o ausentes (0 a 8 pts)	20

Criterio	Logrado	Parcialmente logrado	No logrado	Puntaje
5. Hallazgos, código y reproducibilidad	El notebook corre de principio a fin; código legible sobre el ecosistema Python (NumPy, Pandas y Matplotlib como base); cierra con 3 a 5 hallazgos en frases completas y el modelo que se imagina ajustar (13 a 15 pts)	Corre con ajustes menores, o los hallazgos son una lista de números sin lectura (7 a 12 pts)	El notebook no corre, o no hay síntesis de hallazgos (0 a 6 pts)	15

Puntaje total: 100 puntos. La nota se calcula de forma lineal sobre el puntaje; la calificación mínima de aprobación del módulo es 60%.

Sobre la ponderación: si sus datos traen factores de expansión o pesos de muestreo, los análisis que hablen de la población deben usarlos, como se trabajó en las clases 2 a 4. Si no los traen, no corresponde inventarlos.

Sobre las bibliotecas: NumPy, Pandas y Matplotlib son la base que pide el programa, no un límite. Usar otras bibliotecas de ciencia de datos (seaborn, SciPy y similares) es válido y no se penaliza.

Uso de inteligencia artificial

Se aplica la regla del módulo: el uso de IA generativa está permitido con declaración (qué herramienta se usó y para qué). Debe entender y poder explicar cualquier parte de lo que entregue.