

# Fundamentos de la ciencia de datos

**Clase 1 · Módulo 1 del diplomado**

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 25 de agosto, 2026

# Contenidos de la clase

- ▶ 1. Un caso para partir: la Encuesta Origen Destino de Santiago.
- ▶ 2. Qué es la ciencia de datos y de dónde viene.
- ▶ 3. El ciclo de vida de un proyecto de ciencia de datos.
- ▶ 4. Tipos de datos y tipos de variables.
- ▶ 5. El ecosistema Python: NumPy, Pandas y Matplotlib.
- ▶ 6. Puesta en marcha del entorno de trabajo.

# La idea que ordena esta clase

- ▶ **Un proyecto de datos empieza en la pregunta, no en los datos.**
- ▶ Las herramientas cambian (hoy Python, hace 20 años planillas), pero la lógica del trabajo con datos se mantiene.
- ▶ Al final de la clase volveremos sobre esta idea con un caso completo a la vista.

# Un caso para partir

La Encuesta Origen Destino de Santiago 2012

# La pregunta: ¿cómo se mueve Santiago?


- ▶ Planificar el Metro, las ciclovías o los paraderos exige saber cómo viaja la gente: en qué se mueve, cuánto demora, a qué hora.
- ▶ La intuición no basta: quien planifica mirando el tráfico ve autos, no personas.
- ▶ **La decisión pública se juega en una pregunta que solo los datos pueden responder.**
- ▶ Para responderla, el Estado levanta cada cierto tiempo una encuesta de movilidad: la Encuesta Origen Destino (EOD).

# Los datos: la tabla de viajes, tal como llega

| Hogar  | Persona  | ComunaOrigen | ComunaDestino | TiempoViaje |
|--------|----------|--------------|---------------|-------------|
| 173431 | 17343102 | 94           | 94            | 70.0        |
| 173441 | 17344101 | 94           | 71            | 105.0       |
| 173441 | 17344101 | 71           | 94            | 90.0        |
| 173441 | 17344103 | 94           | 91            | 55.0        |
| 173441 | 17344103 | 91           | 94            | 150.0       |
| 173451 | 17345101 | 94           | 70            | 60.0        |

EOD Santiago 2012: 18.264 hogares, 60.054 personas y 113.591 viajes registrados. Cada fila es un viaje; los códigos se resuelven contra tablas de parámetros.

# Un primer hallazgo



Uno de cada tres viajes en un día laboral es a pie. El tráfico que se ve en la calle no es un buen retrato de cómo se mueve la ciudad.

# Un detalle que importa: ¿de quién habla este número?

- ▶ La encuesta entrevistó a 60.054 personas, pero Santiago tiene millones de habitantes.
- ▶ Cada persona encuestada representa a muchas otras: su factor de expansión.
- ▶ El 33,9% de caminata está ponderado por esos factores: habla de la ciudad, no solo de los encuestados.
- ▶ **Pregunta guía para todo el módulo: ¿de quién habla este número?**
- ▶ Los factores de expansión se trabajan en detalle en las clases 2 y 3.



# Lo que acabamos de hacer

- ▶ Partimos de una pregunta concreta: ¿cómo se mueve Santiago?
- ▶ Buscamos datos capaces de responderla: la EOD 2012.
- ▶ Los exploramos y encontramos algo que corrige la intuición.
- ▶ Lo comunicamos con un gráfico y una frase.
- ▶ **Ese recorrido, hecho con cuidado y método, es la ciencia de datos.**

# ¿Qué es la ciencia de datos?

Una definición y cuatro episodios

# Una definición de trabajo

- ▶ **Ciencia de datos: extraer conocimiento útil de los datos, combinando estadística, computación y conocimiento del dominio.**
- ▶ La estadística aporta el rigor: qué se puede afirmar y con cuánta confianza.
- ▶ La computación aporta la escala: volúmenes y formatos que el papel no resiste.
- ▶ El dominio aporta el sentido: qué pregunta vale la pena y qué respuesta es plausible.
- ▶ Dos grandes objetivos, que retomaremos en el módulo: inferencia (entender relaciones) y predicción (anticipar valores nuevos).

# 1854: una pregunta antes que una teoría

- ▶ Londres, brote de cólera en el barrio de Soho: unas 600 muertes en pocas semanas.
- ▶ La teoría dominante culpaba al aire (los miasmas).
- ▶ El médico John Snow preguntó otra cosa: ¿dónde vivían los muertos?
- ▶ Marcó cada muerte en un mapa: se concentraban alrededor de la bomba de agua de Broad Street.
- ▶ **Los datos, bien preguntados, contradijeron a la teoría dominante: el agua, no el aire.**

# 1962-2001: la estadística se ensancha

- ▶ John Tukey, “The Future of Data Analysis” (1962): el análisis de datos es más que probar hipótesis; explorar los datos es trabajo científico serio.
- ▶ De ahí nace el análisis exploratorio de datos (EDA), que veremos en la clase 3.
- ▶ William Cleveland, “Data Science: An Action Plan” (2001): propone ampliar la estadística con la computación y llama a esa área “data science”.
- ▶ **El nombre es reciente; la práctica lleva décadas madurando.**

# 2008-2012: la industria le pone nombre

- ▶ En 2008, los equipos de datos de LinkedIn y Facebook (DJ Patil y Jeff Hammerbacher) acuñan el cargo “data scientist”.
- ▶ Davenport y Patil lo popularizan en Harvard Business Review (2012).
- ▶ ¿Qué cambió? Internet: por primera vez las empresas acumulan más datos de los que saben usar.
- ▶ La ciencia de datos pasa de los laboratorios a las decisiones de negocio.

# 2009-2014: la lección de Google Flu Trends

- ▶ Google Flu Trends (Ginsberg et al., Nature, 2009): estimar la influenza en tiempo real a partir de las búsquedas en Google.
- ▶ Al principio funcionó; después falló: llegó a más que duplicar la prevalencia que medía el CDC (Lazer et al., Science, 2014).
- ▶ El modelo confundía correlación con relevancia y nadie revisaba qué medían de verdad las búsquedas.
- ▶ **Más datos no es mejor ciencia: sin pregunta clara ni validación, el volumen solo agranda el error.**

# Qué nos dejan los cuatro episodios

- ▶ Snow: la pregunta correcta vale más que la teoría de moda.
- ▶ Tukey y Cleveland: explorar los datos es ciencia, no un trámite previo.
- ▶ La industria: los datos abundan; el criterio para usarlos, no.
- ▶ Google Flu Trends: el volumen no reemplaza al método.
- ▶ **Cuatro épocas, una constante: primero la pregunta, después los datos.**



# El ciclo de vida de un proyecto

De la pregunta a la decisión, y de vuelta

# Las etapas de un proyecto de ciencia de datos



No es una línea de montaje: los hallazgos de una etapa devuelven el proyecto a etapas anteriores.

# El ciclo, aplicado al caso que abrió la clase

- ▶ Pregunta: ¿cómo se mueve Santiago?
- ▶ Obtención: la EOD 2012, publicada por el Observatorio de Transporte.
- ▶ Limpieza y exploración: resolver códigos contra tablas, aplicar factores de expansión, revisar valores extremos.
- ▶ Análisis: reparto modal ponderado por modo de transporte.
- ▶ Comunicación: un gráfico de barras y una frase que corrige la intuición.
- ▶ **En 20 minutos recorrimos el ciclo completo, en miniatura.**

# Tres advertencias sobre el ciclo

- ▶ La mayor parte del tiempo se va en obtener, limpiar y entender los datos, no en modelar: conviene planificar con eso en mente.
- ▶ El ciclo se recorre varias veces: un hallazgo cambia la pregunta, una limpieza revela problemas nuevos.
- ▶ La etapa más barata de arreglar es la primera: una pregunta mal planteada invalida todo lo que sigue.

# El proyecto final del módulo

- ▶ El módulo se evalúa con un proyecto aplicado sobre datos reales, que recorre el ciclo completo: pregunta, datos, exploración, análisis y comunicación.
- ▶ Puede usar datos de su propio trabajo o un conjunto de datos público.
- ▶ **Desde hoy: anote las preguntas de su trabajo que le gustaría responder con datos.**
- ▶ El enunciado y la pauta se publican en las próximas clases.


# Tipos de datos y tipos de variables

Qué análisis admite cada columna

# Datos estructurados y no estructurados

- ▶ Estructurados: tablas con filas y columnas (la EOD, una base de ventas, un registro de sensores). Son el foco de este módulo.
- ▶ No estructurados: texto libre, imágenes, audio. Se trabajan en los módulos de machine learning y deep learning del diplomado.
- ▶ Frontera práctica: casi todo análisis termina convirtiendo lo no estructurado en una tabla.

# Tipos de variables



La misma tabla mezcla los cuatro tipos; cada columna se analiza según el suyo.



# Cuidado con los números que no son números

- ▶ En la tabla de viajes, ComunaOrigen vale 94, 71, 13... pero es una variable nominal: los números son códigos de comuna.
- ▶ Promediar códigos de comuna no significa nada; contar viajes por comuna, sí.
- ▶ **El tipo de la variable define qué resumen y qué gráfico son válidos: es lo primero que se revisa al abrir una tabla.**
- ▶ En la clase 2 esto se vuelve operativo: cada resumen de la estadística descriptiva aplica a ciertos tipos de variables.


# Recreo

10 minutos y volvemos con Python

# El ecosistema Python

NumPy, Pandas y Matplotlib, más Jupyter y uv

# El mapa de las herramientas del módulo



Python trae la sintaxis; NumPy, Pandas y Matplotlib traen el trabajo con datos. Jupyter y uv son el entorno donde todo corre.

# NumPy: cálculo sobre arreglos completos

```
import numpy as np
tiempos = np.array([70, 105, 90, 25, 40])
tiempos.mean()          # 66.0, sin escribir un ciclo
```


- La operación se aplica al arreglo completo (vectorización): menos código y mucho más rápido que iterar en Python puro. Es la base sobre la que se construye todo lo demás.

# Pandas: la tabla como objeto de trabajo

```
import pandas as pd
viajes = pd.read_csv(URL_VIAJES, sep=";", decimal=",")
viajes.head()
```

- El DataFrame es una tabla con columnas etiquetadas, cada una de su propio tipo. Con esas tres líneas se abre la EOD completa: lo haremos en vivo en el notebook de hoy.

# Matplotlib: del DataFrame al gráfico



Este histograma sale de la tabla de viajes con unas seis líneas de código; el notebook de la clase las muestra completas.

# Jupyter y uv: el entorno de trabajo

- ▶ Jupyter: notebooks que mezclan texto, código y resultados; el formato en que trabajaremos todas las clases.
- ▶ uv: administra Python, los paquetes y sus versiones, para que todo el curso trabaje con el mismo entorno.
- ▶ Alternativa sin instalar nada: Google Colab ejecuta los mismos notebooks en la nube.
- ▶ Todo el material queda en el repositorio del módulo:  
[github.com/daniopitz/diplomado-cdd](https://github.com/daniopitz/diplomado-cdd)



# Puesta en marcha del entorno

```
uv init --bare --python 3.12
uv add numpy pandas matplotlib seaborn scipy
uv add statsmodels scikit-learn jupyterlab
uv run jupyter lab
```

- La guía de instalación del repositorio detalla estos pasos por sistema operativo y los problemas frecuentes. Lo hacemos juntos ahora; debe quedar funcionando antes de la clase 2.

# Manos al teclado: el notebook de hoy

- ▶ Abrimos el notebook 01 del repositorio (o en Colab, con el enlace del README).
- ▶ Leeremos la tabla de viajes de la EOD desde una URL: shape, head, info.
- ▶ Variables cualitativas: contar con value\_counts, resolver códigos contra las tablas de parámetros y recalcular el reparto modal en vivo.
- ▶ Variables cuantitativas: describe y el histograma de duración de los viajes; y una discreta, los viajes por persona.
- ▶ **El hilo es el de la clase: el tipo de cada variable define qué análisis es válido.**

# Antes de cerrar: su turno

- ▶ **Escriba en el chat una decisión de su trabajo que hoy se toma por intuición y que podría tomarse con datos.**
- ▶ Comentaremos dos o tres: cuál sería la pregunta, qué datos harían falta, qué etapa del ciclo sería la difícil.
- ▶ Guarde la suya: puede ser el germen de su proyecto final.

# Síntesis

- ▶ **Un proyecto de datos empieza en la pregunta, no en los datos.**
- ▶ La ciencia de datos une estadística, computación y dominio; el nombre es nuevo, el método lleva más de un siglo madurando.
- ▶ El ciclo de vida ordena el trabajo y se recorre más de una vez.
- ▶ El tipo de cada variable define qué análisis es válido.
- ▶ Próxima clase (jueves 27): estadística descriptiva, con el entorno ya funcionando.