

Fundamentos de la ciencia de datos

Clase 1 · Módulo 1 del diplomado

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 25 de agosto, 2026

Contenidos de la clase

- ▶ 1. Qué es la ciencia de datos: definiciones y el episodio de Snow.
- ▶ 2. El ciclo de vida de un proyecto de ciencia de datos.
- ▶ 3. Tipos de datos y tipos de variables.
- ▶ 4. El ecosistema Python: NumPy, Pandas y Matplotlib.
- ▶ 5. Puesta en marcha del entorno y práctica con datos reales: la Encuesta Origen Destino de Santiago.

El concepto central de la clase

- ▶ **El tipo de cada variable determina qué resúmenes, gráficos y análisis son válidos.**
- ▶ Primero se presenta como marco (tipos de datos y tipos de variables) y luego se aplica columna a columna sobre una encuesta real, en el notebook.
- ▶ Es el criterio de partida de todo el módulo: la estadística descriptiva (clase 2) y el EDA (clase 3) se organizan según el tipo de variable.


¿Qué es la ciencia de datos?

Definición, componentes y objetivos

Una definición formal

- ▶ **“Data science is the study of the generalizable extraction of knowledge from data” (Dhar, 2013, CACM).**
- ▶ Es decir: el estudio de la extracción generalizable de conocimiento a partir de los datos.
- ▶ Generalizable: las conclusiones deben ser válidas fuera de los datos usados para obtenerlas. Este requisito define los dos objetivos del análisis, inferencia y predicción (clases 5 a 8).
- ▶ Cleveland (2001) propuso el área como una ampliación técnica de la estadística; Donoho (2017) revisa su desarrollo durante los últimos 50 años.

Tres componentes en intersección



La literatura describe la disciplina en la intersección de estadística, computación y conocimiento del dominio (Cleveland, 2001; Donoho, 2017).

Dos objetivos: inferencia y predicción

Inferencia: entender la relación

¿los viajes largos se asocian al ingreso?
el interés está en la flecha $X \rightarrow Y$

Predicción: anticipar el valor

¿cuánto demorará este viaje?
el interés está en el valor de salida $\hat{y}$

Ambas exigen que lo aprendido generalice más allá de los datos disponibles

Los dos grandes objetivos del trabajo con datos; estructuran las clases 5 a 8 del módulo.

El episodio de John Snow (1854)

- ▶ Londres, brote de cólera en el barrio de Soho: unas 600 muertes en pocas semanas.
- ▶ La teoría dominante culpaba al aire (los miasmas).
- ▶ El médico John Snow preguntó otra cosa: ¿dónde vivían los muertos?
- ▶ Marcó cada muerte en un mapa: se concentraban alrededor de la bomba de agua de Broad Street (Snow, 1855).
- ▶ **La evidencia contradijo la teoría dominante: el agua, no el aire.**
- ▶ El análisis partió de una pregunta concreta, no de la teoría disponible.

El ciclo de vida de un proyecto

Etapas, iteración y planificación

Las etapas de un proyecto de ciencia de datos



El ciclo tiene dos entradas: una necesidad del dominio o datos ya disponibles. Los hallazgos de una etapa pueden devolver el proyecto a etapas anteriores.

Tres advertencias sobre el ciclo

- ▶ Cargar y limpiar datos consume en promedio el 45% del tiempo de trabajo, más que el modelamiento (Anaconda, 2020; encuesta a 2.360 profesionales).
- ▶ El ciclo se recorre varias veces: un hallazgo cambia la pregunta y una limpieza revela problemas nuevos.
- ▶ Un error en la formulación del problema invalida las etapas posteriores; conviene revisarla antes de invertir en el resto.

El proyecto final del módulo

- ▶ El módulo se evalúa con un proyecto aplicado sobre datos reales, que recorre el ciclo completo: pregunta, datos, exploración, análisis y comunicación.
- ▶ Puede usar datos de su propio trabajo o un conjunto de datos público.
- ▶ **Desde hoy: anote las preguntas de su trabajo que le gustaría responder con datos.**
- ▶ El enunciado y la pauta se publican en las próximas clases.


Tipos de datos y tipos de variables

Qué análisis admite cada columna

Datos estructurados y no estructurados

- ▶ Estructurados: tablas con filas y columnas (la EOD, una base de ventas, un registro de sensores). Son el foco de este módulo.
- ▶ No estructurados: texto libre, imágenes, audio. Se trabajan en los módulos de machine learning y deep learning del diplomado.
- ▶ En la práctica, analizar datos no estructurados suele requerir convertirlos primero en representaciones tabulares o numéricas.

Tipos de variables



La misma tabla mezcla los cuatro tipos; cada columna se analiza según el suyo.

Códigos numéricos: variables nominales

- ▶ En la encuesta de viajes que exploraremos hoy en el notebook, la columna ComunaOrigen vale 94, 71, 13... pero es una variable nominal: los números son códigos de comuna.
- ▶ Promediar códigos de comuna no significa nada; contar viajes por comuna, sí.
- ▶ **El tipo de la variable define qué resumen y qué gráfico son válidos: es lo primero que se revisa al abrir una tabla.**
- ▶ En la clase 2 esto se vuelve operativo: cada resumen de la estadística descriptiva aplica a ciertos tipos de variables.


Recreo

10 minutos

El ecosistema Python

NumPy, Pandas y Matplotlib, más Jupyter y uv

Las herramientas del módulo



Python trae la sintaxis; NumPy, Pandas y Matplotlib traen el trabajo con datos. Jupyter y uv son el entorno donde todo corre.

NumPy: cálculo sobre arreglos completos

```
import numpy as np
tiempos = np.array([70, 105, 90, 25, 40])
tiempos.mean()          # 66.0, sin escribir un ciclo
```

- La operación se aplica al arreglo completo (vectorización): menos código y mucho más rápido que iterar en Python puro. Es la base sobre la que se construye todo lo demás.

Pandas: la tabla como objeto de trabajo

```
import pandas as pd
viajes = pd.read_csv(URL_VIAJES, sep=";", decimal=",")
viajes.head()
```

- El DataFrame es una tabla con columnas etiquetadas, cada una de su propio tipo. Con esas tres líneas se abre la EOD completa: lo haremos en vivo en el notebook de hoy.

La Encuesta Origen Destino de Santiago 2012

Hogar	Persona	ComunaOrigen	ComunaDestino	TiempoViaje
173431	17343102	94	94	70.0
173441	17344101	94	71	105.0
173441	17344101	71	94	90.0
173441	17344103	94	91	55.0
173441	17344103	91	94	150.0
173451	17345101	94	70	60.0


EOD Santiago 2012: 18.264 hogares, 60.054 personas y 113.591 viajes registrados. Cada fila es un viaje; los códigos se resuelven contra tablas de parámetros.

Pandas: unir tablas con merge

```
comunas = pd.read_csv(URL_COMUNAS)    # Id, Comuna  
viajes.merge(comunas, left_on="ComunaOrigen", right_on="Id")
```

- Los códigos de una tabla se traducen uniéndola con su tabla de parámetros: merge empareja filas por una columna común. En el notebook lo usamos para ponerle nombre a comunas y modos de viaje.

Matplotlib: del DataFrame al gráfico




Este histograma sale de la tabla de viajes con unas seis líneas de código; el notebook de la clase las muestra completas.

Puesta en marcha del entorno

```
uv init --bare --python 3.12
uv add numpy pandas matplotlib seaborn scipy
uv add statsmodels scikit-learn jupyterlab
uv run jupyter lab
```

- La guía de instalación del repositorio (github.com/daniopitz/diplomado-cdd) detalla estos pasos por sistema operativo y los problemas frecuentes. Lo hacemos juntos ahora; debe quedar funcionando antes de la clase 2. Alternativa sin instalar nada: Google Colab, con los enlaces del repositorio.

Reparto modal de Santiago, EOD 2012



Uno de cada tres viajes es a pie. Esta versión está ponderada por factores de expansión, así que habla de la ciudad; en el notebook calcularemos la versión muestral, y la diferencia entre ambas abre las clases 2 y 3.

Actividad de cierre

- ▶ **Escriba en el chat una decisión de su trabajo que hoy se toma por intuición y podría tomarse con datos, o un conjunto de datos que su organización acumula y no analiza.**
- ▶ Comentaremos dos o tres: cuál sería la pregunta, qué datos harían falta, qué etapa del ciclo sería la difícil.
- ▶ Guarde la suya: puede ser el germen de su proyecto final.

Síntesis

- ▶ **El tipo de cada variable determina qué resúmenes, gráficos y análisis son válidos.**
- ▶ Ciencia de datos: extracción generalizable de conocimiento a partir de los datos (Dhar, 2013); combina estadística, computación y dominio.
- ▶ El ciclo de vida tiene dos entradas (una necesidad del dominio o datos disponibles) y se recorre de forma iterativa.
- ▶ La preparación de datos consume cerca de la mitad del tiempo de un proyecto (Anaconda, 2020).
- ▶ Próxima clase (jueves 27): estadística descriptiva, con el entorno ya funcionando.

Referencias

Snow, J. (1855). On the Mode of Communication of Cholera (2ª edición). Londres: John Churchill.

Anaconda (2020). 2020 State of Data Science. Reporte de encuesta (n=2.360).

anaconda.com/resources/whitepaper/state-of-data-science-2020

Cleveland, W. S. (2001). Data Science: An Action Plan for Expanding the Technical Areas of the Field of Statistics. International Statistical Review, 69(1), 21-26.

Dhar, V. (2013). Data Science and Prediction. Communications of the ACM, 56(12), 64-73.

Donoho, D. (2017). 50 Years of Data Science. Journal of Computational and Graphical Statistics, 26(4), 745-766.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Versión en línea:

jakevdp.github.io/PythonDataScienceHandbook