

Introducción y fundamentos estadísticos

Clase 1 • Introducción

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada • Departamento de Informática • UTFSM • martes 25 de agosto, 2026

Contenidos de la clase

- ▶ 1. Qué es la ciencia de datos.
- ▶ 2. El ciclo de vida de un proyecto de ciencia de datos.
- ▶ 3. Tipos de datos y tipos de variables.
- ▶ 4. El ecosistema Python: NumPy, Pandas y Matplotlib.
- ▶ 5. Puesta en marcha del entorno y ejemplo con Pandas.


¿Qué es la ciencia de datos?

Definición, componentes y objetivos

Una definición formal

- ▶ **“Data science is the study of the generalizable extraction of knowledge from data” (Dhar, 2013, CACM).**
- ▶ Es decir: el estudio de la extracción generalizable de conocimiento a partir de los datos.
- ▶ Generalizable: las conclusiones deben ser válidas fuera de los datos usados para obtenerlas. Este requisito define los dos objetivos del análisis, inferencia y predicción (clases 5 a 8).
- ▶ Cleveland (2001) propuso el área como una ampliación técnica de la estadística; Donoho (2017) revisa su desarrollo durante los últimos 50 años.

Tres componentes en intersección



La literatura describe la disciplina en la intersección de estadística, computación y conocimiento del dominio (Cleveland, 2001; Donoho, 2017).

Dos objetivos: inferencia y predicción

Inferencia: entender la relación

¿los viajes largos se asocian al ingreso?
el interés está en la flecha $X \rightarrow Y$

Predicción: anticipar el valor

¿cuánto demorará este viaje?
el interés está en el valor de salida $\hat{y}$

Ambas exigen que lo aprendido generalice más allá de los datos disponibles

Los dos grandes objetivos del trabajo con datos; estructuran las clases 5 a 8 del módulo.

El ciclo de vida de un proyecto

Etapas, iteración y planificación

Las etapas de un proyecto de ciencia de datos



El ciclo tiene dos entradas: una necesidad del dominio o datos ya disponibles. Los hallazgos de una etapa pueden devolver el proyecto a etapas anteriores.

Los datos disponibles condicionan la pregunta

Caso ideal: encuesta o experimento a la medida



Caso frecuente: los datos no fueron recolectados para la pregunta que terminan respondiendo

La encuesta de viajes de hoy es el caso ideal: se diseñó para estudiar la movilidad. El caso frecuente: los registros de telefonía móvil, generados para operar la red, se usan para estimar matrices de viaje y planificar transporte. Por eso el ciclo dedica tanto trabajo a limpieza y validación.

Tres advertencias sobre el ciclo

- ▶ Cargar y limpiar datos consume en promedio el 45% del tiempo de trabajo, más que el modelamiento (Anaconda, 2020; encuesta a 2.360 profesionales).
- ▶ El ciclo se recorre varias veces: un hallazgo cambia la pregunta y una limpieza revela problemas nuevos.
- ▶ Un error en la formulación del problema invalida las etapas posteriores; conviene revisarla antes de invertir en el resto.

Evaluación del módulo

Actividad	Pond.	Hitos
Formulación del proyecto Capstone	30%	Entrega: lu 07-sep Rúbrica: ju 27-ago Presentación de la idea: ju 03-sep
Primer análisis exploratorio de datos (NumPy, Pandas y Matplotlib)	40%	Entrega: lu 15-sep Rúbrica: ju 03-sep
Informe de avance del proyecto	25%	Informe escrito: vi 25-sep Presentación oral: ma 22-sep

Tres actividades asociadas al proyecto Capstone (programa oficial). Calificación mínima de aprobación: 60%. Fechas por confirmar en el aula virtual.

Tipos de datos y tipos de variables

Qué análisis admite cada columna

Datos estructurados y no estructurados

Estructurados


Hogar	Comuna	Tiempo
173431	94	70
173441	94	105
173441	71	90
173441	94	55

tablas: filas y columnas
(el foco de este módulo)

No estructurados



texto libre




imágenes



audio

Los no estructurados se trabajan en los módulos de machine learning y deep learning; en la práctica, analizarlos suele requerir convertirlos primero en representaciones tabulares o numéricas.

Tipos de variables



La misma tabla mezcla los cuatro tipos; cada columna se analiza según el suyo.


Recreo

10 minutos

El ecosistema Python

NumPy, Pandas y Matplotlib, más Jupyter y uv

Las herramientas del módulo



Python trae la sintaxis; NumPy, Pandas y Matplotlib traen el trabajo con datos. Jupyter y uv son el entorno donde todo corre.

Dos formas de trabajar en el curso



Opción 1 • Google Colab

- ▶ Los notebooks corren en la nube, sin instalar nada.
- ▶ Se abren con los enlaces del README del repositorio.
- ▶ Requiere una cuenta de Google.
- ▶ Guarde su copia en una carpeta de su Drive.



Opción 2 • Entorno local

- ▶ Se clona el repositorio del curso desde GitHub y uv sync instala Python y todas las librerías.
- ▶ Todo el material queda descargado: notebooks, datos y guía.
- ▶ Se trabaja en VS Code (así se dictan las clases) o en JupyterLab.

Ambas opciones usan los mismos notebooks y los mismos datos. Material en github.com/daniopitz/diplomado-cdd

Puesta en marcha del entorno local

```
git clone https://github.com/daniopitz/diplomado-cdd.git
cd diplomado-cdd
uv sync
uv run jupyter lab    # opcional, solo si no usa VS Code
```

- uv sync instala Python 3.12 y las librerías con las versiones fijadas en el repositorio; git pull trae el material nuevo cada semana (sin git: Code > Download ZIP). En las clases se trabaja en VS Code: basta abrir la carpeta y elegir el kernel de .venv, sin comandos adicionales.

NumPy: cálculo sobre arreglos completos

```
import numpy as np
tiempos = np.array([70, 105, 90, 25, 40])
tiempos.mean()          # 66.0, sin escribir un ciclo
```

- La operación se aplica al arreglo completo (vectorización): menos código y mucho más rápido que iterar en Python puro. Es la base sobre la que se construye todo lo demás.


Pandas: la tabla como objeto de trabajo

```
import pandas as pd
viajes = pd.read_csv(URL_VIAJES, sep=";", decimal=",")
viajes.head()
```

Hogar	Persona	ComunaOrigen	ComunaDestino	TiempoViaje
173431	17343102	94	94	70.0
173441	17344101	94	71	105.0
173441	17344101	71	94	90.0
173441	17344103	94	91	55.0
173441	17344103	91	94	150.0
173451	17345101	94	70	60.0

Con esas tres líneas se abre la EOD 2012 completa: 18.264 hogares, 60.054 personas y 113.591 viajes. Cada columna es una variable de su propio tipo.

La EOD: una encuesta, varias tablas






Cada tabla tiene su unidad (hogar, persona, viaje) y las llaves las conectan; las tablas de parámetros traducen los códigos. Por eso la operación clave para trabajar con la EOD es merge.

El DataFrame no es exclusivo de Pandas

- ▶ Varias herramientas usan la misma abstracción de tabla, y Pandas no siempre es la mejor opción cuando los datos crecen:
 - Polars: DataFrames implementados en Rust, más rápidos y eficientes en memoria.
 - Apache Spark: DataFrames distribuidos en un clúster, para volúmenes que no caben en una máquina.
 - Dask: paraleliza la interfaz de Pandas sobre varios núcleos o máquinas.
 - DuckDB: consultas SQL directas sobre archivos y DataFrames.
- ▶ En este módulo usamos Pandas: es el estándar para el análisis interactivo con datos de tamaño pequeño y mediano, y su interfaz es la referencia que las demás herramientas siguen.

Matplotlib: tres gráficos básicos



El gráfico depende del tipo de variable: barras para una cualitativa, histograma para una cuantitativa, dispersión para dos cuantitativas. Los tres salen de la tabla de viajes y se construyen en el notebook.

El factor de expansión

El factor de expansión: de la muestra a la ciudad

37.326 encuestados con factor laboral · la suma de factores estima 6.651.735 personas




Cada persona encuestada representa a muchas otras; su factor de expansión dice a cuántas. La suma de los factores estima la población completa.

El factor de expansión en los cálculos

- ▶ Una encuesta entrevista a una muestra: la EOD, a 60.054 personas de los 6,65 millones de habitantes que cubre.
- ▶ El factor de expansión de cada persona indica a cuántos habitantes representa; sale del diseño muestral (comuna, sexo, edad).
- ▶ La suma de los factores reproduce la población: en la EOD, Factor_LaboralNormal suma 6.651.735.
- ▶ **Todo resumen tiene dos versiones: muestral (contar filas) y ponderada (sumar factores). ¿De quién habla cada número?**
- ▶ En el notebook: 52,8% de mujeres en la muestra, 51,5% ponderado.

Reparto modal de Santiago, EOD 2012



Uno de cada tres viajes es a pie. Esta versión está ponderada por factores de expansión, así que habla de la ciudad; en el notebook calcularemos la versión muestral, y la diferencia entre ambas abre las clases 2 y 3.

Síntesis

- ▶ **El tipo de cada variable determina qué resúmenes, gráficos y análisis son válidos.**
- ▶ Ciencia de datos: extracción generalizable de conocimiento a partir de los datos (Dhar, 2013); combina estadística, computación y dominio.
- ▶ El ciclo de vida tiene dos entradas (una necesidad del dominio o datos disponibles) y se recorre de forma iterativa.
- ▶ La preparación de datos consume cerca de la mitad del tiempo de un proyecto (Anaconda, 2020).
- ▶ Próxima clase (jueves 27): estadística descriptiva, con el entorno ya funcionando.

Referencias

Anaconda (2020). 2020 State of Data Science. Reporte de encuesta (n=2.360).
anaconda.com/resources/whitepaper/state-of-data-science-2020

Cleveland, W. S. (2001). Data Science: An Action Plan for Expanding the Technical Areas of the Field of Statistics. *International Statistical Review*, 69(1), 21-26.

Dhar, V. (2013). Data Science and Prediction. *Communications of the ACM*, 56(12), 64-73.

Donoho, D. (2017). 50 Years of Data Science. *Journal of Computational and Graphical Statistics*, 26(4), 745-766.

VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly. Versión en línea:
jakevdp.github.io/PythonDataScienceHandbook