

Introducción y fundamentos estadísticos

Clase 1 • Introducción

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada • Departamento de Informática • UTFSM • martes 25 de agosto, 2026

Contenidos de la clase

- ▶ 1. Qué es la ciencia de datos.
- ▶ 2. El ciclo de vida de un proyecto de ciencia de datos.
- ▶ 3. Tipos de datos y tipos de variables.
- ▶ 4. El ecosistema Python: NumPy, Pandas y Matplotlib.
- ▶ 5. Puesta en marcha del entorno y ejemplo con Pandas.


¿Qué es la ciencia de datos?

Definición, componentes y objetivos

Una definición formal

- ▶ **“Data science is the study of the generalizable extraction of knowledge from data” (Dhar, 2013, CACM).**
- ▶ Es decir: el estudio de la extracción generalizable de conocimiento a partir de los datos.
- ▶ Generalizable: las conclusiones deben ser válidas fuera de los datos usados para obtenerlas. Este requisito define los dos objetivos del análisis, inferencia y predicción (clases 5 a 8).
- ▶ Cleveland (2001) propuso el área como una ampliación técnica de la estadística; Donoho (2017) revisa su desarrollo durante los últimos 50 años.

Tres componentes en intersección



La literatura describe la disciplina en la intersección de estadística, computación y conocimiento del dominio (Cleveland, 2001; Donoho, 2017).

Dos objetivos: inferencia y predicción

Inferencia: entender la relación

¿los viajes largos se asocian al ingreso?
el interés está en la flecha $X \rightarrow Y$

Predicción: anticipar el valor

¿cuánto demorará este viaje?
el interés está en el valor de salida $\hat{y}$

Ambas exigen que lo aprendido generalice más allá de los datos disponibles

Los dos grandes objetivos del trabajo con datos; estructuran las clases 5 a 8 del módulo.

El ciclo de vida de un proyecto

Etapas, iteración y planificación

Las etapas de un proyecto de ciencia de datos



El ciclo tiene dos entradas: una necesidad del dominio o datos ya disponibles. Los hallazgos de una etapa pueden devolver el proyecto a etapas anteriores.

Tres advertencias sobre el ciclo

- ▶ Cargar y limpiar datos consume en promedio el 45% del tiempo de trabajo, más que el modelamiento (Anaconda, 2020; encuesta a 2.360 profesionales).
- ▶ El ciclo se recorre varias veces: un hallazgo cambia la pregunta y una limpieza revela problemas nuevos.
- ▶ Un error en la formulación del problema invalida las etapas posteriores; conviene revisarla antes de invertir en el resto.

Evaluación del módulo

- ▶ Tres actividades, asociadas al proyecto Capstone del diplomado (programa oficial de la asignatura):
 - Formulación del proyecto y de la innovación propuesta (30%): pauta el ju 27-ago, presentación breve de la idea el ju 03-sep, entrega el lu 07-sep.
 - Primer análisis exploratorio de datos, en código con NumPy, Pandas y Matplotlib sobre datos del proyecto (40%): pauta el ju 03-sep, entrega el lu 15-sep.
 - Informe de avance (25%): presentación oral el ma 22-sep e informe escrito el vi 25-sep.
- ▶ **El proyecto Capstone parte en este módulo: defina un problema de su contexto profesional abordable con datos.**
- ▶ Calificación mínima de aprobación: 60%. Fechas por confirmar en el aula virtual.

Tipos de datos y tipos de variables

Qué análisis admite cada columna

Datos estructurados y no estructurados

Estructurados


Hogar	Comuna	Tiempo
173431	94	70
173441	94	105
173441	71	90
173441	94	55

tablas: filas y columnas
(el foco de este módulo)

No estructurados



texto libre




imágenes



audio

Los no estructurados se trabajan en los módulos de machine learning y deep learning; en la práctica, analizarlos suele requerir convertirlos primero en representaciones tabulares o numéricas.

Tipos de variables



La misma tabla mezcla los cuatro tipos; cada columna se analiza según el suyo.

Códigos numéricos: variables nominales

- ▶ En la encuesta de viajes que exploraremos hoy en el notebook, la columna ComunaOrigen vale 94, 71, 13... pero es una variable nominal: los números son códigos de comuna.
- ▶ Promediar códigos de comuna no significa nada; contar viajes por comuna, sí.
- ▶ **El tipo de la variable define qué resumen y qué gráfico son válidos: es lo primero que se revisa al abrir una tabla.**
- ▶ En la clase 2 esto se vuelve operativo: cada resumen de la estadística descriptiva aplica a ciertos tipos de variables.


Recreo

10 minutos

El ecosistema Python

NumPy, Pandas y Matplotlib, más Jupyter y uv

Las herramientas del módulo



Python trae la sintaxis; NumPy, Pandas y Matplotlib traen el trabajo con datos. Jupyter y uv son el entorno donde todo corre.

NumPy: cálculo sobre arreglos completos

```
import numpy as np
tiempos = np.array([70, 105, 90, 25, 40])
tiempos.mean()          # 66.0, sin escribir un ciclo
```

- La operación se aplica al arreglo completo (vectorización): menos código y mucho más rápido que iterar en Python puro. Es la base sobre la que se construye todo lo demás.

Pandas: la tabla como objeto de trabajo

```
import pandas as pd
viajes = pd.read_csv(URL_VIAJES, sep=";", decimal=",")
viajes.head()
```

- El DataFrame es una tabla con columnas etiquetadas, cada una de su propio tipo. Con esas tres líneas se abre la EOD completa: lo haremos en vivo en el notebook de hoy.

La Encuesta Origen Destino de Santiago 2012

Hogar	Persona	ComunaOrigen	ComunaDestino	TiempoViaje
173431	17343102	94	94	70.0
173441	17344101	94	71	105.0
173441	17344101	71	94	90.0
173441	17344103	94	91	55.0
173441	17344103	91	94	150.0
173451	17345101	94	70	60.0


EOD Santiago 2012: 18.264 hogares, 60.054 personas y 113.591 viajes registrados. Cada fila es un viaje; los códigos se resuelven contra tablas de parámetros.

Pandas: unir tablas con merge

```
comunas = pd.read_csv(URL_COMUNAS)    # Id, Comuna  
viajes.merge(comunas, left_on="ComunaOrigen", right_on="Id")
```

- Los códigos de una tabla se traducen uniéndola con su tabla de parámetros: merge empareja filas por una columna común. En el notebook lo usamos para ponerle nombre a comunas y modos de viaje.

Matplotlib: del DataFrame al gráfico




Este histograma sale de la tabla de viajes con unas seis líneas de código; el notebook de la clase las muestra completas.

Puesta en marcha del entorno

```
uv init --bare --python 3.12
uv add numpy pandas matplotlib seaborn scipy
uv add statsmodels scikit-learn jupyterlab
uv run jupyter lab
```

- La guía de instalación del repositorio (github.com/daniopitz/diplomado-cdd) detalla estos pasos por sistema operativo y los problemas frecuentes. Lo hacemos juntos ahora; debe quedar funcionando antes de la clase 2. Alternativa sin instalar nada: Google Colab, con los enlaces del repositorio.

Reparto modal de Santiago, EOD 2012



Uno de cada tres viajes es a pie. Esta versión está ponderada por factores de expansión, así que habla de la ciudad; en el notebook calcularemos la versión muestral, y la diferencia entre ambas abre las clases 2 y 3.

Síntesis

- ▶ **El tipo de cada variable determina qué resúmenes, gráficos y análisis son válidos.**
- ▶ Ciencia de datos: extracción generalizable de conocimiento a partir de los datos (Dhar, 2013); combina estadística, computación y dominio.
- ▶ El ciclo de vida tiene dos entradas (una necesidad del dominio o datos disponibles) y se recorre de forma iterativa.
- ▶ La preparación de datos consume cerca de la mitad del tiempo de un proyecto (Anaconda, 2020).
- ▶ Próxima clase (jueves 27): estadística descriptiva, con el entorno ya funcionando.

Referencias

Anaconda (2020). 2020 State of Data Science. Reporte de encuesta (n=2.360).
anaconda.com/resources/whitepaper/state-of-data-science-2020

Cleveland, W. S. (2001). Data Science: An Action Plan for Expanding the Technical Areas of the Field of Statistics. *International Statistical Review*, 69(1), 21-26.

Dhar, V. (2013). Data Science and Prediction. *Communications of the ACM*, 56(12), 64-73.

Donoho, D. (2017). 50 Years of Data Science. *Journal of Computational and Graphical Statistics*, 26(4), 745-766.

VanderPlas, J. (2016). *Python Data Science Handbook*. O'Reilly. Versión en línea:
jakevdp.github.io/PythonDataScienceHandbook