

Fundamentos de la ciencia de datos

Clase 1 · Módulo 1 del diplomado

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 25 de agosto, 2026

Contenidos de la clase

- ▶ 1. Qué es la ciencia de datos y de dónde viene.
- ▶ 2. Un caso completo: la Encuesta Origen Destino de Santiago.
- ▶ 3. El ciclo de vida de un proyecto de ciencia de datos.
- ▶ 4. Tipos de datos y tipos de variables.
- ▶ 5. El ecosistema Python: NumPy, Pandas y Matplotlib.
- ▶ 6. Puesta en marcha del entorno de trabajo.

La idea que ordena esta clase

- ▶ **Un proyecto de datos empieza en la pregunta, no en los datos.**
- ▶ Las herramientas cambian (hoy Python, hace 20 años planillas), pero la lógica del trabajo con datos se mantiene.
- ▶ Al final de la clase volveremos sobre esta idea con un caso completo a la vista.

¿Qué es la ciencia de datos?

Definiciones con respaldo y cuatro episodios

Una definición formal

- ▶ **“Data science is the study of the generalizable extraction of knowledge from data” (Dhar, 2013, CACM).**
- ▶ Es decir: el estudio de la extracción generalizable de conocimiento a partir de los datos.
- ▶ La palabra clave es generalizable: lo aprendido en estos datos debe sostenerse más allá de ellos. Ahí viven la inferencia y la predicción, que estructuran la segunda mitad del módulo.
- ▶ No es una definición de la industria: Cleveland (2001) propuso el área como una ampliación técnica de la estadística, y Donoho (2017) la sistematiza como heredera de 50 años de análisis de datos.

Tres componentes, dos objetivos

- ▶ La literatura describe la disciplina en la intersección de tres componentes (Cleveland, 2001; Donoho, 2017):
 - estadística: qué se puede afirmar y con cuánta confianza,
 - computación: volúmenes y formatos que el papel no resiste,
 - conocimiento del dominio: qué pregunta vale la pena y qué respuesta es plausible.
- ▶ Y dos grandes objetivos, que retomaremos en las clases 5 a 8:
 - inferencia: entender relaciones (¿los viajes largos se asocian al ingreso?),
 - predicción: anticipar valores nuevos (¿cuánto demorará este viaje?).

1854: una pregunta antes que una teoría

- ▶ Londres, brote de cólera en el barrio de Soho: unas 600 muertes en pocas semanas.
- ▶ La teoría dominante culpaba al aire (los miasmas).
- ▶ El médico John Snow preguntó otra cosa: ¿dónde vivían los muertos?
- ▶ Marcó cada muerte en un mapa: se concentraban alrededor de la bomba de agua de Broad Street.
- ▶ **Los datos, bien preguntados, contradijeron a la teoría dominante: el agua, no el aire.**

1962-2017: la estadística se ensancha

- ▶ Tukey (1962): el análisis de datos es más que probar hipótesis; explorar los datos es trabajo científico serio. De ahí nace el análisis exploratorio de datos (EDA), que veremos en la clase 3.
- ▶ Cleveland (2001): un plan de acción para ampliar la estadística con la computación; le da al área el nombre “data science”.
- ▶ Donoho (2017): revisa medio siglo de esa tradición y ordena el campo en actividades que van de la preparación de datos a la presentación de resultados.
- ▶ **El nombre es reciente; la práctica lleva décadas madurando.**

2008-2012: la industria le pone nombre al cargo

- ▶ En 2008, los equipos de datos de LinkedIn y Facebook (DJ Patil y Jeff Hammerbacher) acuñan el cargo “data scientist”.
- ▶ Davenport y Patil lo popularizan en Harvard Business Review (2012).
- ▶ ¿Qué cambió? Internet: por primera vez las empresas acumulan más datos de los que saben usar.
- ▶ La ciencia de datos pasa de los laboratorios a las decisiones de negocio.

2009-2014: la lección de Google Flu Trends

- ▶ Google Flu Trends (Ginsberg et al., Nature, 2009): estimar la influenza en tiempo real a partir de las búsquedas en Google.
- ▶ Al principio funcionó; después falló: llegó a más que duplicar la prevalencia que medía el CDC (Lazer et al., Science, 2014).
- ▶ El modelo confundía correlación con relevancia y nadie revisaba qué medían de verdad las búsquedas.
- ▶ **Más datos no es mejor ciencia: sin pregunta clara ni validación, el volumen solo agranda el error.**

Qué nos dejan los cuatro episodios

- ▶ Snow: la pregunta correcta vale más que la teoría de moda.
- ▶ Tukey, Cleveland y Donoho: explorar los datos es ciencia, no un trámite previo.
- ▶ La industria: los datos abundan; el criterio para usarlos, no.
- ▶ Google Flu Trends: el volumen no reemplaza al método.
- ▶ **Cuatro épocas, una constante: primero la pregunta, después los datos.**

Un caso completo

La definición, puesta a trabajar: la EOD de Santiago 2012

La pregunta: ¿cómo se mueve Santiago?


- ▶ Planificar el Metro, las ciclovías o los paraderos exige saber cómo viaja la gente: en qué se mueve, cuánto demora, a qué hora.
- ▶ La intuición no basta: quien planifica mirando el tráfico ve autos, no personas.
- ▶ **La decisión pública se juega en una pregunta que solo los datos pueden responder.**
- ▶ Para responderla, el Estado levanta cada cierto tiempo una encuesta de movilidad: la Encuesta Origen Destino (EOD).

Los datos: la tabla de viajes, tal como llega

Hogar	Persona	ComunaOrigen	ComunaDestino	TiempoViaje
173431	17343102	94	94	70.0
173441	17344101	94	71	105.0
173441	17344101	71	94	90.0
173441	17344103	94	91	55.0
173441	17344103	91	94	150.0
173451	17345101	94	70	60.0

EOD Santiago 2012: 18.264 hogares, 60.054 personas y 113.591 viajes registrados. Cada fila es un viaje; los códigos se resuelven contra tablas de parámetros.

Un primer hallazgo



Uno de cada tres viajes en un día laboral es a pie. El tráfico que se ve en la calle no es un buen retrato de cómo se mueve la ciudad.

Un detalle que importa: ¿de quién habla este número?

- ▶ La encuesta entrevistó a 60.054 personas, pero Santiago tiene millones de habitantes.
- ▶ Cada persona encuestada representa a muchas otras: su factor de expansión.
- ▶ El 33,9% de caminata está ponderado por esos factores: habla de la ciudad, no solo de los encuestados.
- ▶ **Pregunta guía para todo el módulo: ¿de quién habla este número?**
- ▶ Los factores de expansión se trabajan en detalle en las clases 2 y 3.

Lo que acabamos de hacer

- ▶ Partimos de una pregunta concreta: ¿cómo se mueve Santiago?
- ▶ Buscamos datos capaces de responderla: la EOD 2012.
- ▶ Los exploramos y encontramos algo que corrige la intuición.
- ▶ Lo comunicamos con un gráfico y una frase.
- ▶ **Ese recorrido es la definición de Dhar en acto: conocimiento generalizable extraído de los datos.**

El ciclo de vida de un proyecto

De la pregunta a la decisión, y de vuelta

Las etapas de un proyecto de ciencia de datos



No es una línea de montaje: los hallazgos de una etapa devuelven el proyecto a etapas anteriores.

El ciclo, aplicado al caso que acabamos de ver

- ▶ Pregunta: ¿cómo se mueve Santiago?
- ▶ Obtención: la EOD 2012, publicada por el Observatorio de Transporte.
- ▶ Limpieza y exploración: resolver códigos contra tablas, aplicar factores de expansión, revisar valores extremos.
- ▶ Análisis: reparto modal ponderado por modo de transporte.
- ▶ Comunicación: un gráfico de barras y una frase que corrige la intuición.
- ▶ **En 20 minutos recorrimos el ciclo completo, en miniatura.**

Tres advertencias sobre el ciclo

- ▶ La mayor parte del tiempo se va en obtener, limpiar y entender los datos, no en modelar: conviene planificar con eso en mente.
- ▶ El ciclo se recorre varias veces: un hallazgo cambia la pregunta, una limpieza revela problemas nuevos.
- ▶ La etapa más barata de arreglar es la primera: una pregunta mal planteada invalida todo lo que sigue.

El proyecto final del módulo

- ▶ El módulo se evalúa con un proyecto aplicado sobre datos reales, que recorre el ciclo completo: pregunta, datos, exploración, análisis y comunicación.
- ▶ Puede usar datos de su propio trabajo o un conjunto de datos público.
- ▶ **Desde hoy: anote las preguntas de su trabajo que le gustaría responder con datos.**
- ▶ El enunciado y la pauta se publican en las próximas clases.


Tipos de datos y tipos de variables

Qué análisis admite cada columna

Datos estructurados y no estructurados

- ▶ Estructurados: tablas con filas y columnas (la EOD, una base de ventas, un registro de sensores). Son el foco de este módulo.
- ▶ No estructurados: texto libre, imágenes, audio. Se trabajan en los módulos de machine learning y deep learning del diplomado.
- ▶ Frontera práctica: casi todo análisis termina convirtiendo lo no estructurado en una tabla.

Tipos de variables



La misma tabla mezcla los cuatro tipos; cada columna se analiza según el suyo.

Cuidado con los números que no son números

- ▶ En la tabla de viajes, ComunaOrigen vale 94, 71, 13... pero es una variable nominal: los números son códigos de comuna.
- ▶ Promediar códigos de comuna no significa nada; contar viajes por comuna, sí.
- ▶ **El tipo de la variable define qué resumen y qué gráfico son válidos: es lo primero que se revisa al abrir una tabla.**
- ▶ En la clase 2 esto se vuelve operativo: cada resumen de la estadística descriptiva aplica a ciertos tipos de variables.


Recreo

10 minutos y volvemos con Python

El ecosistema Python

NumPy, Pandas y Matplotlib, más Jupyter y uv

El mapa de las herramientas del módulo



Python trae la sintaxis; NumPy, Pandas y Matplotlib traen el trabajo con datos. Jupyter y uv son el entorno donde todo corre.

NumPy: cálculo sobre arreglos completos

```
import numpy as np
tiempos = np.array([70, 105, 90, 25, 40])
tiempos.mean()           # 66.0, sin escribir un ciclo
```

- La operación se aplica al arreglo completo (vectorización): menos código y mucho más rápido que iterar en Python puro. Es la base sobre la que se construye todo lo demás.

Pandas: la tabla como objeto de trabajo

```
import pandas as pd
viajes = pd.read_csv(URL_VIAJES, sep=";", decimal=",")
viajes.head()
```


- El DataFrame es una tabla con columnas etiquetadas, cada una de su propio tipo. Con esas tres líneas se abre la EOD completa: lo haremos en vivo en el notebook de hoy.

Pandas: unir tablas con merge

```
comunas = pd.read_csv(URL_COMUNAS)    # Id, Comuna  
viajes.merge(comunas, left_on="ComunaOrigen", right_on="Id")
```

- Los códigos de una tabla se traducen uniéndola con su tabla de parámetros: merge empareja filas por una columna común. En el notebook lo usamos para ponerle nombre a comunas y modos de viaje.

Matplotlib: del DataFrame al gráfico



Este histograma sale de la tabla de viajes con unas seis líneas de código; el notebook de la clase las muestra completas.

Jupyter y uv: el entorno de trabajo

- ▶ Jupyter: notebooks que mezclan texto, código y resultados; el formato en que trabajaremos todas las clases.
- ▶ uv: administra Python, los paquetes y sus versiones, para que todo el curso trabaje con el mismo entorno.
- ▶ Alternativa sin instalar nada: Google Colab ejecuta los mismos notebooks en la nube.
- ▶ Todo el material queda en el repositorio del módulo:
github.com/daniopitz/diplomado-cdd

Puesta en marcha del entorno

```
uv init --bare --python 3.12
uv add numpy pandas matplotlib seaborn scipy
uv add statsmodels scikit-learn jupyterlab
uv run jupyter lab
```

- La guía de instalación del repositorio detalla estos pasos por sistema operativo y los problemas frecuentes. Lo hacemos juntos ahora; debe quedar funcionando antes de la clase 2.

Manos al teclado: el notebook de hoy

- ▶ Notebook 01, del repositorio o en Colab: la tabla de viajes de la EOD por URL, con shape, head e info.
- ▶ Cualitativas: contar con value_counts y traducir códigos con merge (comunas y modos), recalculando el reparto modal en vivo.
- ▶ Cuantitativas: describe y el histograma de duración; y una discreta, los viajes por persona.
- ▶ Cruce de ambas: la duración media por comuna, con groupby.
- ▶ **El hilo es el de la clase: el tipo de cada variable define qué análisis es válido.**

Antes de cerrar: su turno

- ▶ **Escriba en el chat una decisión de su trabajo que hoy se toma por intuición y que podría tomarse con datos.**
- ▶ Comentaremos dos o tres: cuál sería la pregunta, qué datos harían falta, qué etapa del ciclo sería la difícil.
- ▶ Guarde la suya: puede ser el germen de su proyecto final.

Síntesis

- ▶ **Un proyecto de datos empieza en la pregunta, no en los datos.**
- ▶ La ciencia de datos es la extracción generalizable de conocimiento desde los datos (Dhar, 2013), y una estadística, computación y dominio.
- ▶ El ciclo de vida ordena el trabajo y se recorre más de una vez.
- ▶ El tipo de cada variable define qué análisis es válido.
- ▶ Próxima clase (jueves 27): estadística descriptiva, con el entorno ya funcionando.

Referencias

Tukey, J. W. (1962). The Future of Data Analysis. The Annals of Mathematical Statistics, 33(1), 1-67.

Cleveland, W. S. (2001). Data Science: An Action Plan for Expanding the Technical Areas of the Field of Statistics. International Statistical Review, 69(1), 21-26.

Ginsberg, J., Mohebbi, M., Patel, R., Brammer, L., Smolinski, M. y Brilliant, L. (2009). Detecting influenza epidemics using search engine query data. Nature, 457, 1012-1014.

Davenport, T. H. y Patil, D. J. (2012). Data Scientist: The Sexiest Job of the 21st Century. Harvard Business Review, octubre de 2012.

Dhar, V. (2013). Data Science and Prediction. Communications of the ACM, 56(12), 64-73.

Lazer, D., Kennedy, R., King, G. y Vespignani, A. (2014). The Parable of Google Flu: Traps in Big Data Analysis. Science, 343(6176), 1203-1205.

Donoho, D. (2017). 50 Years of Data Science. Journal of Computational and Graphical Statistics, 26(4), 745-766.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Versión en línea: jakevdp.github.io/PythonDataScienceHandbook