

Introducción y fundamentos estadísticos

Clase 2 · Análisis exploratorio de datos I

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 27 de agosto, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Contenidos de la clase

- ▶ 1. Formular la pregunta y la hipótesis del proyecto.
- ▶ 2. Rúbrica de la formulación del Capstone.
- ▶ 3. Qué es el análisis exploratorio de datos.
- ▶ 4. Tendencia central: media, mediana y moda.
- ▶ 5. Dispersión y forma: desviación estándar, percentiles y boxplot.
- ▶ 6. Calidad y limpieza de datos.

La pregunta y la hipótesis

Formular el proyecto antes de analizarlo

Seis tipos de pregunta

Complejidad creciente de la pregunta (1 a 6)

1. Descriptiva

resumir una característica
de los datos

2. Exploratoria

buscar patrones;
genera hipótesis

3. Inferencial

¿el patrón se sostiene
más allá de la muestra?

4. Predictiva

anticipar valores
para casos nuevos

5. Causal

¿qué cambia si
intervenimos X?

6. Mecanicista

¿cómo exactamente
X produce Y?

El módulo cubre los cuatro primeros tipos. El error más común de un análisis es responder un tipo de pregunta creyendo que se responde otro (Leek y Peng, 2015).

Qué hace buena a una pregunta

- ▶ De interés real: una audiencia concreta usaría la respuesta (Peng y Matsui, 2015).
- ▶ Se pueden retomar preguntas que otros ya estudiaron; lo que no se acepta es copiar la solución: el análisis debe ser propio y sobre sus datos.
- ▶ Plausible: la respuesta esperada tiene un mecanismo creíble.
- ▶ Respondible: los datos necesarios existen y son obtenibles.
- ▶ Específica: nombra variables y población, no generalidades.

¿Qué tiene de malo esta pregunta? (1 de 3)

¿Cómo mejorar las ventas?

Discutamos antes de ver la reparación.

¿Qué tiene de malo esta pregunta? (2 de 3)

¿Sirve la IA para mi empresa?

Discutamos antes de ver la reparación.

¿Qué tiene de malo esta pregunta? (3 de 3)

¿Por qué renuncian los empleados?

Discutamos antes de ver la reparación.

Malas preguntas, reparadas

La pregunta	El problema	Una versión que funciona
¿Cómo mejorar las ventas?	No dice qué medir ni dónde	¿Qué categorías de producto caen en invierno en las sucursales del sur?
¿Sirve la IA para mi empresa?	Sin variables ni población definidas	¿Cuántas horas de revisión manual ahorra clasificar los reclamos automáticamente?
¿Por qué renuncian los empleados?	Causal; los datos solo permiten explorar	¿Qué características comparten quienes renunciaron durante 2025?

La reparación típica: nombrar la variable, la población y el periodo, y bajar la ambición causal al tipo de pregunta que los datos permiten.

De la pregunta a la hipótesis


- ▶ **Hipótesis: una afirmación sobre la relación entre variables medibles, que los datos pueden confirmar o refutar.**
- ▶ Si ningún resultado posible podría refutarla, no es una hipótesis.
- ▶ Pregunta: ¿la duración del viaje depende del modo de transporte?
- ▶ Hipótesis: los viajes en transporte público duran en promedio más que en auto. Variables: ModoAgrupado y TiempoViaje; el contraste, una comparación de medias (clase 5).

Malas hipótesis, reparadas

La hipótesis	El problema	Una versión verificable
El marketing influye en las ventas	No dice qué marketing ni qué ventas	Las semanas con campaña activa venden más que las semanas sin campaña, en la misma sucursal
Los reclamos muestran patrones interesantes	No es falsable: cualquier cosa la confirma	Los reclamos aumentan en los meses de mayor demanda
Los viajes largos son culpa del transporte público	Atribuye causa donde solo hay asociación	Los viajes en transporte público duran en promedio más que los viajes en auto

Una hipótesis verificable nombra variables medibles y una comparación concreta; la tercera es la que contrastaremos con la EOD.

El ciclo PPDAC



Problema, plan, datos, análisis y conclusión (Wild y Pfannkuch, 1999): la formulación del Capstone es la etapa de problema y plan de este ciclo.

La formulación del proyecto Capstone

- ▶ Se publica hoy la rúbrica, con seis criterios: problema (20 pts), datos y metadatos (20), estrategia de obtención (15), novedad (15), viabilidad técnica (15) e impacto esperado (15).
- ▶ Documento de 2 a 3 páginas, un envío por equipo (máximo 2 personas), por el aula virtual.
- ▶ **Entrega: lunes 7 de septiembre. Presentación breve de la idea: jueves 3, con retroalimentación y sin nota.**
- ▶ Quienes no usen datos de su trabajo pueden partir de la lista de datos sugeridos del repositorio.

El análisis exploratorio de datos


Qué es y por qué se hace primero

Qué es el EDA

- ▶ **Examinar los datos antes de modelar: resumirlos, graficarlos y detectar sus problemas.**
- ▶ El término viene de Tukey (1977): explorar es trabajo estadístico serio, no un trámite previo.
- ▶ Hoy: una variable a la vez, más calidad de los datos. El martes: relaciones entre variables.
- ▶ Es lo que exige el entregable del 40%: el análisis exploratorio del proyecto.

Los datos de la clase: iris y la EOD

- ▶ **iris para aprender los conceptos; la EOD para aplicarlos a datos reales.**
- ▶ iris: 150 flores de tres especies, con el largo y el ancho del pétalo y del sépalo en centímetros. Publicado por Fisher (1936).
- ▶ Chico y ordenado: los resúmenes se pueden verificar a mano.
- ▶ La EOD ya la conocen: 113.591 viajes, con faltantes, colas y códigos.



Las tres especies

setosa



versicolor



virginica



Fotografías: Radomil, D. Gordon E. Robertson y Frank Mayfield, Wikimedia Commons, licencias CC BY-SA.

Cargar iris

```
from sklearn.datasets import load_iris
iris = load_iris()
iris_df = pd.DataFrame(iris.data, columns=iris.feature_names)
nombres = {0: "setosa", 1: "versicolor", 2: "virginica"}
iris_df["species"] = pd.Series(iris.target).map(nombres)
```

- Viene incluido en scikit-learn, así que no requiere descarga. La especie llega como códigos 0, 1 y 2; un diccionario los traduce con map().

iris_df: las primeras filas

sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)	species
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa
4.6	3.1	1.5	0.2	setosa
5.0	3.6	1.4	0.2	setosa
5.4	3.9	1.7	0.4	setosa

150 filas y 5 columnas: cuatro medidas numéricas y la especie como variable categórica.

Tendencia central

Un número para el centro de la variable

Frecuencia y moda


- ▶ Para una variable cualitativa, el resumen básico es la frecuencia de cada categoría: `value_counts()`, y en porcentaje con `normalize=True`.
- ▶ En iris: 50 flores de cada especie (un diseño balanceado).
- ▶ La moda es el valor más frecuente; es el único resumen de tendencia central que existe para variables cualitativas.
- ▶ En la EOD, la moda de la duración es 30 minutos: la gente declara tiempos redondeados.

Media, mediana y moda

Medida	Definición	iris: largo de sépalo	EOD: duración
Media	El promedio: la suma de los valores dividida por el número de datos.	5,84 cm	36,9 min
Mediana	El valor central: deja el 50% de los datos a cada lado.	5,80 cm	30 min
Moda	El valor más frecuente; el único resumen posible para variables cualitativas.	5,0 cm (10 flores)	30 min


En iris, media y mediana casi coinciden: la distribución es simétrica. Cuando difieren, la media queda arrastrada hacia la cola.

Iris: el caso simétrico



En una distribución simétrica, media y mediana cuentan la misma historia.

La EOD: el caso asimétrico




Ingresos de los hogares de la EOD: mediana \$0,51 millones, media \$0,69 millones. La cola de ingresos altos arrastra la media; por eso el ingreso se reporta con la mediana.

La media, con factor de expansión

```
datos = viajes[["TiempoViaje", "FactorLaboralNormal"]].dropna()
tiempo = datos["TiempoViaje"]
factor = datos["FactorLaboralNormal"]
media_muestra = tiempo.mean()
media_ponderada = (tiempo * factor).sum() / factor.sum()
```

- En la muestra cada viaje pesa 1; con el factor, cada viaje pesa lo que representa en la ciudad: 37,2 contra 34,7 minutos.

Muestra y ponderada, comparadas



La ponderación sube los viajes cortos y baja los largos: la media cae de 37,2 a 34,7 minutos. Cuando la conclusión es sobre la ciudad, se pondera.


Recreo

10 minutos

Dispersión y forma


Cuánto varían los datos alrededor del centro

Percentiles y cuartiles



El percentil p es el valor bajo el cual queda el $p\%$ de los datos. Los cuartiles son los percentiles 25, 50 y 75: cortan los datos ordenados en cuatro partes con la misma cantidad de observaciones cada una.

Los cuartiles de la duración



Los mismos cortes en la EOD: cada tramo tiene la misma cantidad de viajes, pero anchos muy distintos. La asimetría, contada por los percentiles.

Medir la dispersión

Rango

$$\text{máx} - \text{mín}$$

simple, pero dominado por los extremos

Varianza

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Desviación estándar

$$s = \sqrt{s^2} \quad (\text{unidades originales})$$

iris: 0,83 cm · EOD: 36,1 min


IQR

$$IQR = Q_3 - Q_1 \quad (\text{el 50\% central})$$

EOD: de 15 a 50 min


Los percentiles completan el cuadro: $\text{quantile}([0, 0.25, 0.5, 0.75, 1])$ entrega el mínimo, los cuartiles y el máximo (en iris: 4,3 · 5,1 · 5,8 · 6,4 · 7,9).

El IQR en iris




Entre Q1 y Q3 queda el 50% central de las flores. El IQR es el ancho de ese tramo: $6,4 - 5,1 = 1,3$ cm.

El IQR en la duración




El 50% central de los viajes cabe en 35 minutos. La mitad central es angosta; lo que se estira es la cola, y al IQR eso no lo afecta.

La media no basta



Providencia y Talagante tienen la misma duración media de viaje (40,7 minutos), pero la desviación estándar de Talagante es el doble: dos realidades distintas detrás del mismo promedio.

El boxplot




Cinco números en un solo gráfico: mediana, cuartiles, bigotes y valores atípicos. La regla de los bigotes (1,5 veces el IQR) es una convención para marcar valores inusuales, no un veredicto.


Valores atípicos (outliers)

- ▶ **Un valor atípico es una observación que se aleja notoriamente del resto.**
- ▶ Convención de Tukey: fuera de $Q1 - 1,5 \cdot IQR$ y de $Q3 + 1,5 \cdot IQR$.
- ▶ Atípico no significa error: puede ser un caso real e informativo. Distinguirlo exige criterio del dominio.
- ▶ No hay una regla universal para excluirllos: es materia de la estadística robusta.

iris: ancho de sépalo (150 flores)




EOD: duración del viaje



Otros criterios para marcar atípicos


- ▶ **La regla de Tukey es una convención entre varias; marcar no es eliminar.**
- ▶ Tres sigmas: a más de 3 desviaciones estándar de la media. El clásico, pero los propios atípicos inflan la vara con que se mide.
- ▶ Z-score modificado: la misma idea con mediana y MAD, que resisten los extremos; corte sugerido en 3,5 (Iglewicz y Hoaglin, 1993).
- ▶ Criterio del dominio: rangos de validez del problema. Un viaje de 22 horas en Santiago no es raro: es imposible. El más defendible.
- ▶ En modelos: residuos en regresión y detección de anomalías. Los veremos en las próximas clases; hoy bastan Tukey y el dominio.

Boxplots para comparar grupos: iris



El largo del pétalo separa casi perfectamente a las tres especies: centros y dispersiones distintas en una sola figura.

Boxplots para comparar grupos: la EOD



La duración del viaje según el modo: centros y dispersiones distintas en una sola figura. Es el gráfico estándar para comparar una variable cuantitativa entre categorías.

Calidad y limpieza de datos

Los resúmenes valen lo que valen los datos

iris viene casi limpio; los datos reales, no

- ▶ iris: cero faltantes en sus 150 filas... y aun así tiene una fila duplicada. Hasta el dataset más famoso trae un problema de calidad.
- ▶ La EOD: 278 duraciones faltantes, códigos que traducir, colas sospechosas y factores que son NaN por diseño.
- ▶ **Por eso el checklist de calidad se aplica siempre, también al dataset del proyecto.**


Valores faltantes

- ▶ Detección: `isna().sum()`, o el count de `describe()` contra `len`.
- ▶ En la EOD: `TiempoViaje` tiene 278 faltantes entre 113.591 viajes.
- ▶ **Un NaN no siempre es error: en los factores de expansión significa "no aplica".**
- ▶ Opciones: eliminar, imputar o dejar que cada cálculo los excluya. Lo obligatorio: decidir y documentar.

Duplicados

- ▶ `duplicate()` marca filas repetidas; `drop_duplicates()` las elimina.
- ▶ Dos niveles: la fila completa y la llave que debería ser única.
- ▶ En la EOD ambos chequeos dan cero; un cero también es un hallazgo.
- ▶ El riesgo típico: un merge con llaves repetidas multiplica filas.

Valores sospechosos



116 viajes declaran más de 5 horas y el máximo es de 22 horas. ¿Error de registro o viaje real? La respuesta exige criterio del dominio; la decisión (mantener, corregir o excluir) se toma en el código y se documenta.

Tapar valores con mask

```
# donde la condición se cumple, reemplaza (aquí, por NaN)
viajes["TiempoViaje"] = viajes["TiempoViaje"].mask(
    viajes["TiempoViaje"] > 300)
```

- ▶ mask reemplaza donde la condición es verdadera; where, su espejo, conserva donde es verdadera y reemplaza el resto. Regla nemotécnica: mask es dónde tapar, where es dónde quedarse.

Revisar cada merge

- ▶ Comparar el número de filas antes y después: un inner descarta las filas sin pareja; en la clase 1, 113.591 viajes quedaron en 111.393.
- ▶ Contar los NaN de las columnas nuevas cuando se usa how="left": ahí quedan visibles las filas sin correspondencia (2.198 comunas).
- ▶ Verificar que la llave sea única en la tabla de parámetros: si está repetida, el merge multiplica filas.

Checklist de calidad antes de analizar

Revisión	Con qué
Dimensiones y tipos	shape, info()
Faltantes por columna relevante	isna().sum(), count contra len
Duplicados	duplicated(): fila completa y llave única
Rangos válidos de cada variable	min, max, describe(), valores sospechosos
Merges verificados	filas antes y después, NaN nuevos, llaves únicas

Cada decisión de limpieza queda escrita en el código, con su justificación.

Síntesis

- ▶ Describir una variable exige tres miradas: centro (media, mediana), dispersión (desviación, IQR) y forma (histograma, boxplot).
- ▶ Con asimetría, la mediana acompaña o reemplaza a la media.
- ▶ La limpieza es parte del análisis: faltantes, duplicados, rangos válidos y merges verificados, con decisiones documentadas.
- ▶ La pregunta del proyecto debe ser específica y la hipótesis, verificable con variables medibles.
- ▶ Próxima clase (martes 01-sep): EDA II, relaciones entre variables y correlación.

Referencias

Fisher, R. A. (1936). The Use of Multiple Measurements in Taxonomic Problems. *Annals of Eugenics*, 7(2), 179-188.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

Iglewicz, B. y Hoaglin, D. C. (1993). *How to Detect and Handle Outliers*. ASQC Quality Press.

Leek, J. T. y Peng, R. D. (2015). What is the question? *Science*, 347(6228), 1314-1315.

Peng, R. D. y Matsui, E. (2015). *The Art of Data Science*. Versión en línea:
bookdown.org/rdpeng/artofdatascience

Wild, C. J. y Pfannkuch, M. (1999). Statistical Thinking in Empirical Enquiry. *International Statistical Review*, 67(3), 223-248.

Anaconda (2020). 2020 State of Data Science. Reporte de encuesta (n=2.360).
anaconda.com/resources/whitepaper/state-of-data-science-2020