

# Introducción y fundamentos estadísticos

## Clase 2 · Análisis exploratorio de datos I

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 27 de agosto, 2026



UNIVERSIDAD TECNICA  
FEDERICO SANTA MARIA

DEPARTAMENTO  
DE INFORMÁTICA

# Contenidos de la clase

- ▶ 1. Formular la pregunta y la hipótesis del proyecto.
- ▶ 2. Rúbrica de la formulación del Capstone.
- ▶ 3. Qué es el análisis exploratorio de datos.
- ▶ 4. Tendencia central: media, mediana y moda.
- ▶ 5. Dispersión y forma: desviación estándar, percentiles y boxplot.
- ▶ 6. Calidad y limpieza de datos.

# La pregunta y la hipótesis

Formular el proyecto antes de analizarlo

# Seis tipos de pregunta

## Complejidad creciente de la pregunta (1 a 6)

### 1. Descriptiva

resumir una característica  
de los datos

### 2. Exploratoria

buscar patrones;  
genera hipótesis

### 3. Inferencial

¿el patrón se sostiene  
más allá de la muestra?

### 4. Predictiva

anticipar valores  
para casos nuevos

### 5. Causal

¿qué cambia si  
intervenimos X?

### 6. Mecanicista

¿cómo exactamente  
X produce Y?

El módulo cubre los cuatro primeros tipos. El error más común de un análisis es responder un tipo de pregunta creyendo que se responde otro (Leek y Peng, 2015).

# Qué hace buena a una pregunta

- ▶ De interés real: una audiencia concreta usaría la respuesta (Peng y Matsui, 2015).
- ▶ Se pueden retomar preguntas que otros ya estudiaron; lo que no se acepta es copiar la solución: el análisis debe ser propio y sobre sus datos.
- ▶ Plausible: la respuesta esperada tiene un mecanismo creíble.
- ▶ Respondible: los datos necesarios existen y son obtenibles.
- ▶ Específica: nombra variables y población, no generalidades.

# ¿Qué tiene de malo esta pregunta? (1 de 3)

**¿Cómo mejorar las ventas?**

Discutamos antes de ver la reparación.

## **¿Qué tiene de malo esta pregunta? (2 de 3)**

**¿Sirve la IA para mi empresa?**

Discutamos antes de ver la reparación.

## **¿Qué tiene de malo esta pregunta? (3 de 3)**

**¿Por qué renuncian los empleados?**

Discutamos antes de ver la reparación.

# Malas preguntas, reparadas

| La pregunta                       | El problema                              | Una versión que funciona                                                          |
|-----------------------------------|------------------------------------------|-----------------------------------------------------------------------------------|
| ¿Cómo mejorar las ventas?         | No dice qué medir ni dónde               | ¿Qué categorías de producto caen en invierno en las sucursales del sur?           |
| ¿Sirve la IA para mi empresa?     | Sin variables ni población definidas     | ¿Cuántas horas de revisión manual ahorra clasificar los reclamos automáticamente? |
| ¿Por qué renuncian los empleados? | Causal; los datos solo permiten explorar | ¿Qué características comparten quienes renunciaron durante 2025?                  |

La reparación típica: nombrar la variable, la población y el periodo, y bajar la ambición causal al tipo de pregunta que los datos permiten.

# De la pregunta a la hipótesis


- ▶ **Hipótesis: una afirmación sobre la relación entre variables medibles, que los datos pueden confirmar o refutar.**
- ▶ Si ningún resultado posible podría refutarla, no es una hipótesis.
- ▶ Pregunta: ¿la duración del viaje depende del modo de transporte?
- ▶ Hipótesis: los viajes en transporte público duran en promedio más que en auto. Variables: ModoAgrupado y TiempoViaje; el contraste, una comparación de medias (clase 5).

# Malas hipótesis, reparadas

| La hipótesis                                       | El problema                                | Una versión verificable                                                                     |
|----------------------------------------------------|--------------------------------------------|---------------------------------------------------------------------------------------------|
| El marketing influye en las ventas                 | No dice qué marketing ni qué ventas        | Las semanas con campaña activa venden más que las semanas sin campaña, en la misma sucursal |
| Los reclamos muestran patrones interesantes        | No es falsable: cualquier cosa la confirma | Los reclamos aumentan en los meses de mayor demanda                                         |
| Los viajes largos son culpa del transporte público | Atribuye causa donde solo hay asociación   | Los viajes en transporte público duran en promedio más que los viajes en auto               |

Una hipótesis verificable nombra variables medibles y una comparación concreta; la tercera es la que contrastaremos con la EOD.

# El ciclo PPDAC



Problema, plan, datos, análisis y conclusión (Wild y Pfannkuch, 1999): la formulación del Capstone es la etapa de problema y plan de este ciclo.

# La formulación del proyecto Capstone

- ▶ Se publica hoy la rúbrica, con seis criterios: problema (20 pts), datos y metadatos (20), estrategia de obtención (15), novedad (15), viabilidad técnica (15) e impacto esperado (15).
- ▶ Documento de 2 a 3 páginas, un envío por equipo (máximo 2 personas), por el aula virtual.
- ▶ **Entrega: lunes 7 de septiembre. Presentación breve de la idea: jueves 3, con retroalimentación y sin nota.**
- ▶ Quienes no usen datos de su trabajo pueden partir de la lista de datos sugeridos del repositorio.

# El análisis exploratorio de datos


Qué es y por qué se hace primero

# Qué es el EDA

- ▶ **Examinar los datos antes de modelar: resumirlos, graficarlos y detectar sus problemas.**
- ▶ El término viene de Tukey (1977): explorar es trabajo estadístico serio, no un trámite previo.
- ▶ Hoy: una variable a la vez, más calidad de los datos. El martes: relaciones entre variables.
- ▶ Es lo que exige el entregable del 40%: el análisis exploratorio del proyecto.

# Los datos de la clase: iris y la EOD

- ▶ **iris para aprender los conceptos; la EOD para aplicarlos a datos reales.**
- ▶ iris: 150 flores de tres especies, con el largo y el ancho del pétalo y del sépalo en centímetros. Publicado por Fisher (1936).
- ▶ Chico y ordenado: los resúmenes se pueden verificar a mano.
- ▶ La EOD ya la conocen: 113.591 viajes, con faltantes, colas y códigos.



# Las tres especies

**setosa**



**versicolor**



**virginica**



Fotografías: Radomil, D. Gordon E. Robertson y Frank Mayfield, Wikimedia Commons, licencias CC BY-SA.

# Cargar iris

```
from sklearn.datasets import load_iris
iris = load_iris()
iris_df = pd.DataFrame(iris.data, columns=iris.feature_names)
nombres = {0: "setosa", 1: "versicolor", 2: "virginica"}
iris_df["species"] = pd.Series(iris.target).map(nombres)
```

- Viene incluido en scikit-learn, así que no requiere descarga. La especie llega como códigos 0, 1 y 2; un diccionario los traduce con map().

# iris\_df: las primeras filas

| sepal length<br>(cm) | sepal width<br>(cm) | petal length<br>(cm) | petal width<br>(cm) | species |
|----------------------|---------------------|----------------------|---------------------|---------|
| 5.1                  | 3.5                 | 1.4                  | 0.2                 | setosa  |
| 4.9                  | 3.0                 | 1.4                  | 0.2                 | setosa  |
| 4.7                  | 3.2                 | 1.3                  | 0.2                 | setosa  |
| 4.6                  | 3.1                 | 1.5                  | 0.2                 | setosa  |
| 5.0                  | 3.6                 | 1.4                  | 0.2                 | setosa  |
| 5.4                  | 3.9                 | 1.7                  | 0.4                 | setosa  |

150 filas y 5 columnas: cuatro medidas numéricas y la especie como variable categórica.

# Tendencia central

Un número para el centro de la variable

# Frecuencia y moda


- ▶ Para una variable cualitativa, el resumen básico es la frecuencia de cada categoría: `value_counts()`, y en porcentaje con `normalize=True`.
- ▶ En iris: 50 flores de cada especie (un diseño balanceado).
- ▶ La moda es el valor más frecuente; es el único resumen de tendencia central que existe para variables cualitativas.
- ▶ En la EOD, la moda de la duración es 30 minutos: la gente declara tiempos redondeados.

# Media, mediana y moda

| Medida  | Definición                                                                    | iris: largo de sépalo | EOD: duración |
|---------|-------------------------------------------------------------------------------|-----------------------|---------------|
| Media   | El promedio: la suma de los valores dividida por el número de datos.          | 5,84 cm               | 36,9 min      |
| Mediana | El valor central: deja el 50% de los datos a cada lado.                       | 5,80 cm               | 30 min        |
| Moda    | El valor más frecuente; el único resumen posible para variables cualitativas. | 5,0 cm (10 flores)    | 30 min        |


En iris, media y mediana casi coinciden: la distribución es simétrica. Cuando difieren, la media queda arrastrada hacia la cola.

# Iris: el caso simétrico



En una distribución simétrica, media y mediana cuentan la misma historia.

# La EOD: el caso asimétrico




Ingresos de los hogares de la EOD: mediana \$0,51 millones, media \$0,69 millones. La cola de ingresos altos arrastra la media; por eso el ingreso se reporta con la mediana.

# La media, con factor de expansión

```
datos = viajes[["TiempoViaje", "FactorLaboralNormal"]].dropna()
tiempo = datos["TiempoViaje"]
factor = datos["FactorLaboralNormal"]
media_muestra = tiempo.mean()
media_ponderada = np.average(tiempo, weights=factor)
```

- En la muestra cada viaje pesa 1; con el factor, cada viaje pesa lo que representa en la ciudad: 37,2 contra 34,7 minutos.

# Muestra y ponderada, comparadas



La ponderación sube los viajes cortos y baja los largos: la media cae de 37,2 a 34,7 minutos. Cuando la conclusión es sobre la ciudad, se pondera.

# Recreo

10 minutos

# Dispersión y forma

Cuánto varían los datos alrededor del centro

# Medir la dispersión

## Rango

$$\text{máx} - \text{mín}$$

simple, pero dominado por los extremos

## Varianza

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

## Desviación estándar

$$s = \sqrt{s^2} \quad (\text{unidades originales})$$

iris: 0,83 cm · EOD: 36,1 min


## IQR

$$IQR = Q_3 - Q_1 \quad (\text{el 50\% central})$$

EOD: de 15 a 50 min


Los percentiles completan el cuadro:  $\text{quantile}([0, 0.25, 0.5, 0.75, 1])$  entrega el mínimo, los cuartiles y el máximo (en iris: 4,3 · 5,1 · 5,8 · 6,4 · 7,9).

# La media no basta



Providencia y Talagante tienen la misma duración media de viaje (40,7 minutos), pero la desviación estándar de Talagante es el doble: dos realidades distintas detrás del mismo promedio.

# El boxplot




Cinco números en un solo gráfico: mediana, cuartiles, bigotes y valores atípicos. La regla de los bigotes (1,5 veces el IQR) es una convención para marcar valores inusuales, no un veredicto.

# Valores atípicos (outliers)

- ▶ **Un valor atípico es una observación que se aleja notoriamente del resto.**
- ▶ Convención de Tukey: fuera de  $Q1 - 1,5 \cdot IQR$  y de  $Q3 + 1,5 \cdot IQR$ .
- ▶ Atípico no significa error: puede ser un caso real e informativo. Distinguirlo exige criterio del dominio.
- ▶ No hay una regla universal para excluirllos: es materia de la estadística robusta.


iris: ancho de sépalo (150 flores)



EOD: duración del viaje




# Boxplots para comparar grupos: iris



El largo del pétalo separa casi perfectamente a las tres especies: centros y dispersiones distintas en una sola figura.

# Boxplots para comparar grupos: la EOD



La duración del viaje según el modo: centros y dispersiones distintas en una sola figura. Es el gráfico estándar para comparar una variable cuantitativa entre categorías.

# Calidad y limpieza de datos

Los resúmenes valen lo que valen los datos

# iris viene casi limpio; los datos reales, no

- ▶ iris: cero faltantes en sus 150 filas... y aun así tiene una fila duplicada. Hasta el dataset más famoso trae un problema de calidad.
- ▶ La EOD: 278 duraciones faltantes, códigos que traducir, colas sospechosas y factores que son NaN por diseño.
- ▶ **Por eso el checklist de calidad se aplica siempre, también al dataset del proyecto.**


# Valores faltantes

- ▶ Detección: `isna().sum()`, o el count de `describe()` contra `len`.
- ▶ En la EOD: `TiempoViaje` tiene 278 faltantes entre 113.591 viajes.
- ▶ **Un NaN no siempre es error: en los factores de expansión significa "no aplica".**
- ▶ Opciones: eliminar, imputar o dejar que cada cálculo los excluya. Lo obligatorio: decidir y documentar.

# Duplicados

- ▶ `duplicate()` marca filas repetidas; `drop_duplicates()` las elimina.
- ▶ Dos niveles: la fila completa y la llave que debería ser única.
- ▶ En la EOD ambos chequeos dan cero; un cero también es un hallazgo.
- ▶ El riesgo típico: un merge con llaves repetidas multiplica filas.

# Valores sospechosos



116 viajes declaran más de 5 horas y el máximo es de 22 horas. ¿Error de registro o viaje real? La respuesta exige criterio del dominio; la decisión (mantener, corregir o excluir) se toma en el código y se documenta.

# Tapar valores con mask

```
# donde la condición se cumple, reemplaza (aquí, por NaN)
viajes["TiempoViaje"] = viajes["TiempoViaje"].mask(
    viajes["TiempoViaje"] > 300)
```

- ▶ mask reemplaza donde la condición es verdadera; where, su espejo, conserva donde es verdadera y reemplaza el resto. Regla nemotécnica: mask es dónde tapar, where es dónde quedarse.

# Revisar cada merge

- ▶ Comparar el número de filas antes y después: un inner descarta las filas sin pareja; en la clase 1, 113.591 viajes quedaron en 111.393.
- ▶ Contar los NaN de las columnas nuevas cuando se usa how="left": ahí quedan visibles las filas sin correspondencia (2.198 comunas).
- ▶ Verificar que la llave sea única en la tabla de parámetros: si está repetida, el merge multiplica filas.

# Checklist de calidad antes de analizar

| Revisión                        | Con qué                                          |
|---------------------------------|--------------------------------------------------|
| Dimensiones y tipos             | shape, info()                                    |
| Faltantes por columna relevante | isna().sum(), count contra len                   |
| Duplicados                      | duplicated(): fila completa y llave única        |
| Rangos válidos de cada variable | min, max, describe(), valores sospechosos        |
| Merges verificados              | filas antes y después, NaN nuevos, llaves únicas |

Cada decisión de limpieza queda escrita en el código, con su justificación.

# Síntesis

- ▶ Describir una variable exige tres miradas: centro (media, mediana), dispersión (desviación, IQR) y forma (histograma, boxplot).
- ▶ Con asimetría, la mediana acompaña o reemplaza a la media.
- ▶ La limpieza es parte del análisis: faltantes, duplicados, rangos válidos y merges verificados, con decisiones documentadas.
- ▶ La pregunta del proyecto debe ser específica y la hipótesis, verificable con variables medibles.
- ▶ Próxima clase (martes 01-sep): EDA II, relaciones entre variables y correlación.

# Referencias

Fisher, R. A. (1936). The Use of Multiple Measurements in Taxonomic Problems. *Annals of Eugenics*, 7(2), 179-188.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

Leek, J. T. y Peng, R. D. (2015). What is the question? *Science*, 347(6228), 1314-1315.

Peng, R. D. y Matsui, E. (2015). *The Art of Data Science*. Versión en línea:  
[bookdown.org/rdpeng/artofdatascience](http://bookdown.org/rdpeng/artofdatascience)

Wild, C. J. y Pfannkuch, M. (1999). Statistical Thinking in Empirical Enquiry. *International Statistical Review*, 67(3), 223-248.

Anaconda (2020). 2020 State of Data Science. Reporte de encuesta (n=2.360).  
[anaconda.com/resources/whitepaper/state-of-data-science-2020](https://anaconda.com/resources/whitepaper/state-of-data-science-2020)