

Introducción y fundamentos estadísticos

Clase 2 · Análisis exploratorio de datos I

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 27 de agosto, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Contenidos de la clase

- ▶ 1. Qué es el análisis exploratorio de datos.
- ▶ 2. Tendencia central: media, mediana y moda.
- ▶ 3. Dispersión y forma: desviación estándar, percentiles y boxplot.
- ▶ 4. Calidad y limpieza de datos.
- ▶ 5. Formular la pregunta y la hipótesis del proyecto.
- ▶ 6. Rúbrica de la formulación del Capstone.

El análisis exploratorio de datos

Qué es y por qué se hace primero

Qué es el EDA

- ▶ **Examinar los datos antes de modelar: resumirlos, graficarlos y detectar sus problemas y patrones.**
- ▶ El término y el enfoque vienen de Tukey (1977): el análisis exploratorio es trabajo estadístico serio, no un trámite previo.
- ▶ Hoy, EDA I: describir una variable a la vez (univariado) y revisar la calidad de los datos.
- ▶ El martes, EDA II: relaciones entre variables (bivariado), correlación y visualización.
- ▶ Es exactamente lo que exige el primer entregable evaluado del módulo: el análisis exploratorio del proyecto (40%).


Tendencia central

Un número para el centro de la variable

Tres resúmenes del centro

- ▶ Media: la suma dividida por el número de observaciones. En la EOD, la duración media de un viaje es 36,9 minutos.
- ▶ Mediana: el valor que deja la mitad de los datos a cada lado. En la EOD, 30 minutos.
- ▶ Moda: el valor más frecuente; útil también en variables cualitativas. En la EOD, 30 minutos.
- ▶ **Cuando media y mediana difieren, la distribución es asimétrica: la media queda arrastrada hacia la cola.**

Media contra mediana: el ingreso de los hogares



Ingresos de la muestra de la EOD: la mediana es \$0,51 millones y la media \$0,69 millones. La cola de ingresos altos arrastra la media; por eso el ingreso se reporta con la mediana.


Dispersión y forma

Cuánto varían los datos alrededor del centro

Medir la dispersión


- ▶ Rango: máximo menos mínimo; simple pero dominado por los extremos.
- ▶ Varianza: el promedio de las desviaciones al cuadrado respecto de la media. Su raíz es la desviación estándar, en las unidades originales.
- ▶ En la EOD, la duración tiene desviación estándar de 36,1 minutos, casi tan grande como su media: los viajes son muy heterogéneos.
- ▶ Percentiles: el valor bajo el cual queda un porcentaje de los datos. El rango intercuartílico $IQR = Q3 - Q1$ concentra el 50% central: en la EOD, de 15 a 50 minutos.

La media no basta




Providencia y Talagante tienen la misma duración media de viaje (40,7 minutos), pero la desviación estándar de Talagante es el doble: dos realidades distintas detrás del mismo promedio.

El boxplot



Cinco números en un solo gráfico: mediana, cuartiles, bigotes y valores atípicos. La regla de los bigotes (1,5 veces el IQR) es una convención para marcar valores inusuales, no un veredicto.

Boxplots para comparar grupos



La duración del viaje según el modo: centros y dispersiones distintas en una sola figura. Es el gráfico estándar para comparar una variable cuantitativa entre categorías.

Recreo

10 minutos

Calidad y limpieza de datos

Los resúmenes valen lo que valen los datos


Valores faltantes

- ▶ Se detectan con `isna().sum()` por columna, o comparando el count de `describe()` con el largo de la tabla.
- ▶ En la EOD, `TiempoViaje` tiene 278 faltantes entre 113.591 viajes.
- ▶ **Un NaN no siempre es un error: en los factores de expansión significa "no aplica" (cada persona respondió por un solo tipo de día).**
- ▶ Opciones: eliminar las filas, imputar un valor, o dejarlos y que cada cálculo los excluya. Cualquiera sirve; lo obligatorio es decidirlo explícitamente y documentarlo.

Duplicados

- ▶ `uplicated()` marca filas repetidas; `drop_duplicates()` las elimina.
- ▶ Conviene revisar dos niveles: la fila completa y la llave que debería ser única (por ejemplo, el identificador del viaje).
- ▶ En la EOD ambas revisiones dan cero. Un chequeo que da cero también es un hallazgo: queda descartada una fuente de error.
- ▶ Los duplicados aparecen sobre todo al combinar tablas: un merge con llaves repetidas multiplica filas.

Valores sospechosos



116 viajes declaran más de 5 horas y el máximo es de 22 horas. ¿Error de registro o viaje real? La respuesta exige criterio del dominio; la decisión (mantener, corregir o excluir) se toma en el código y se documenta.

Tapar valores con mask

```
# donde la condición se cumple, reemplaza (aquí, por NaN)
viajes["TiempoViaje"] = viajes["TiempoViaje"].mask(
    viajes["TiempoViaje"] > 300)
```

- ▶ mask reemplaza donde la condición es verdadera; where, su espejo, conserva donde es verdadera y reemplaza el resto. Regla nemotécnica: mask es dónde tapar, where es dónde quedarse.

Revisar cada merge

- ▶ Comparar el número de filas antes y después: un inner descarta las filas sin pareja; en la clase 1, 113.591 viajes quedaron en 111.393.
- ▶ Contar los NaN de las columnas nuevas cuando se usa how="left": ahí quedan visibles las filas sin correspondencia (2.198 comunas).
- ▶ Verificar que la llave sea única en la tabla de parámetros: si está repetida, el merge multiplica filas.

Checklist de calidad antes de analizar

- ▶ Dimensiones y tipos: `shape`, `info()`.
- ▶ Faltantes por columna relevante: `isna().sum()`, `count` contra `len`.
- ▶ Duplicados: fila completa y llave única.
- ▶ Rangos válidos de cada variable cuantitativa: `min`, `max`, valores sospechosos.
- ▶ Merges verificados: filas, NaN nuevos, llaves únicas.
- ▶ **Cada decisión de limpieza queda escrita en el código, con su justificación.**

La pregunta y la hipótesis

Formular el proyecto antes de analizarlo

Seis tipos de pregunta

Complejidad creciente de la pregunta (1 a 6)

1. Descriptiva

resumir una característica
de los datos

2. Exploratoria

buscar patrones;
genera hipótesis

3. Inferencial

¿el patrón se sostiene
más allá de la muestra?

4. Predictiva

anticipar valores
para casos nuevos

5. Causal

¿qué cambia si
intervenimos X?

6. Mecanicista


¿cómo exactamente
X produce Y?

El módulo cubre los cuatro primeros tipos. El error más común de un análisis es responder un tipo de pregunta creyendo que se responde otro (Leek y Peng, 2015).

Qué hace buena a una pregunta

- ▶ De interés real para alguien: una audiencia concreta que usaría la respuesta (Peng y Matsui, 2015).
- ▶ No respondida ya: revisar qué existe antes de empezar.
- ▶ Plausible: la respuesta esperada tiene un mecanismo creíble.
- ▶ Respondible: los datos necesarios existen y son obtenibles.
- ▶ Específica: nombra variables y población, no generalidades.
- ▶ **Contraste: "¿cómo mejorar las ventas?" no cumple; "¿qué categorías de producto caen en invierno en las sucursales del sur?" sí.**

El ciclo PPDAC



Problema, plan, datos, análisis y conclusión (Wild y Pfannkuch, 1999): la formulación del Capstone es la etapa de problema y plan de este ciclo.

De la pregunta a la hipótesis

- ▶ Una hipótesis es una afirmación verificable: nombra variables medibles y la relación esperada entre ellas.
- ▶ Pregunta: ¿la duración del viaje depende del modo de transporte?
- ▶ Hipótesis: los viajes en transporte público duran en promedio más que los viajes en auto.
- ▶ Variables: ModoAgrupado (cualitativa) y TiempoViaje (continua); el contraste es una comparación de medias, que la clase 5 formaliza.
- ▶ **Si la hipótesis no dice qué medir ni qué comparar, todavía es una intuición, no una hipótesis.**

La formulación del proyecto Capstone

- ▶ Se publica hoy la rúbrica, con seis criterios: problema (20 pts), datos y metadatos (20), estrategia de obtención (15), novedad (15), viabilidad técnica (15) e impacto esperado (15).
- ▶ Documento de 2 a 3 páginas, un envío por equipo (máximo 2 personas), por el aula virtual.
- ▶ **Entrega: lunes 7 de septiembre. Presentación breve de la idea: jueves 3, con retroalimentación y sin nota.**
- ▶ Quienes no usen datos de su trabajo pueden partir de la lista de datos sugeridos del repositorio.

Síntesis

- ▶ Describir una variable exige tres miradas: centro (media, mediana), dispersión (desviación, IQR) y forma (histograma, boxplot).
- ▶ Con asimetría, la mediana acompaña o reemplaza a la media.
- ▶ La limpieza es parte del análisis: faltantes, duplicados, rangos válidos y merges verificados, con decisiones documentadas.
- ▶ La pregunta del proyecto debe ser específica y la hipótesis, verificable con variables medibles.
- ▶ Próxima clase (martes 01-sep): EDA II, relaciones entre variables y correlación.

Referencias

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

Leek, J. T. y Peng, R. D. (2015). What is the question? Science, 347(6228), 1314-1315.

Peng, R. D. y Matsui, E. (2015). The Art of Data Science. Versión en línea:
bookdown.org/rdpeng/artofdatascience

Wild, C. J. y Pfannkuch, M. (1999). Statistical Thinking in Empirical Enquiry. International Statistical Review, 67(3), 223-248.

Anaconda (2020). 2020 State of Data Science. Reporte de encuesta (n=2.360).
anaconda.com/resources/whitepaper/state-of-data-science-2020