

Introducción y fundamentos estadísticos

Clase 2 · Análisis exploratorio de datos I

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 27 de agosto, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Contenidos de la clase

- ▶ 1. Qué es el análisis exploratorio de datos.
- ▶ 2. Tendencia central: media, mediana y moda.
- ▶ 3. Dispersión y forma: desviación estándar, percentiles y boxplot.
- ▶ 4. Calidad y limpieza de datos.
- ▶ 5. Formular la pregunta y la hipótesis del proyecto.
- ▶ 6. Rúbrica de la formulación del Capstone.

El análisis exploratorio de datos

Qué es y por qué se hace primero

Qué es el EDA

- ▶ **Examinar los datos antes de modelar: resumirlos, graficarlos y detectar sus problemas.**
- ▶ El término viene de Tukey (1977): explorar es trabajo estadístico serio, no un trámite previo.
- ▶ Hoy: una variable a la vez, más calidad de los datos. El martes: relaciones entre variables.
- ▶ Es lo que exige el entregable del 40%: el análisis exploratorio del proyecto.

Los datos de la clase: iris y la EOD

- ▶ **iris para aprender los conceptos; la EOD para aplicarlos a datos reales.**
- ▶ iris: 150 flores de tres especies (setosa, versicolor, virginica), con cuatro medidas en centímetros (largo y ancho de pétalo y sépalo). Publicado por Fisher (1936); el clásico de la estadística.
- ▶ Chico y ordenado: los resúmenes se pueden verificar a mano.
- ▶ La EOD ya la conocen: 113.591 viajes, con faltantes, colas y códigos. Lo que iris enseña, la EOD lo pone a prueba.

Cargar iris

```
from sklearn.datasets import load_iris
iris = load_iris()
iris_df = pd.DataFrame(iris.data, columns=iris.feature_names)
iris_df["species"] = pd.Categorical.from_codes(iris.target,
iris.target_names)
```

- Viene incluido en scikit-learn, así que no requiere descarga. La columna species queda como variable categórica de Pandas.

Tendencia central

Un número para el centro de la variable


Frecuencia y moda

- ▶ Para una variable cualitativa, el resumen básico es la frecuencia de cada categoría: `value_counts()`, y en porcentaje con `normalize=True`.
- ▶ En iris: 50 flores de cada especie (un diseño balanceado).
- ▶ La moda es el valor más frecuente; es el único resumen de tendencia central que existe para variables cualitativas.
- ▶ En la EOD, la moda de la duración es 30 minutos: la gente declara tiempos redondeados.

Media y mediana


- ▶ Media: la suma dividida por el número de observaciones.
- ▶ Mediana: el valor que deja la mitad de los datos a cada lado.
- ▶ En iris, largo del sépalo: media 5,84 y mediana 5,80. Casi iguales: la distribución es simétrica.
- ▶ **Cuando difieren, la distribución es asimétrica: la media queda arrastrada hacia la cola.**

Iris: el caso simétrico



En una distribución simétrica, media y mediana cuentan la misma historia.

La EOD: el caso asimétrico



Ingresos de los hogares de la EOD: mediana \$0,51 millones, media \$0,69 millones. La cola de ingresos altos arrastra la media; por eso el ingreso se reporta con la mediana.


Dispersión y forma

Cuánto varían los datos alrededor del centro

Medir la dispersión


- ▶ Rango: máximo menos mínimo; dominado por los extremos.
- ▶ Desviación estándar: raíz de la varianza, en las unidades originales. En iris, 0,83 cm; en la EOD, 36,1 minutos, casi tan grande como la media.
- ▶ Percentiles: el valor bajo el cual queda un porcentaje de los datos. En iris, $\text{quantile}([0, .25, .5, .75, 1])$ da 4,3 · 5,1 · 5,8 · 6,4 · 7,9.
- ▶ IQR = Q3 menos Q1: el tramo del 50% central. En la EOD, de 15 a 50 minutos.

La media no basta




Providencia y Talagante tienen la misma duración media de viaje (40,7 minutos), pero la desviación estándar de Talagante es el doble: dos realidades distintas detrás del mismo promedio.

El boxplot




Cinco números en un solo gráfico: mediana, cuartiles, bigotes y valores atípicos. La regla de los bigotes (1,5 veces el IQR) es una convención para marcar valores inusuales, no un veredicto.

Boxplots para comparar grupos: iris



El largo del pétalo separa casi perfectamente a las tres especies: centros y dispersiones distintas en una sola figura.

Boxplots para comparar grupos: la EOD



La duración del viaje según el modo: centros y dispersiones distintas en una sola figura. Es el gráfico estándar para comparar una variable cuantitativa entre categorías.

Recreo

10 minutos

Calidad y limpieza de datos

Los resúmenes valen lo que valen los datos

iris viene casi limpio; los datos reales, no

- ▶ iris: cero faltantes en sus 150 filas... y aun así tiene una fila duplicada. Hasta el dataset más famoso trae un problema de calidad.
- ▶ La EOD: 278 duraciones faltantes, códigos que traducir, colas sospechosas y factores que son NaN por diseño.
- ▶ **Por eso el checklist de calidad se aplica siempre, también al dataset del proyecto.**


Valores faltantes

- ▶ Detección: `isna().sum()`, o el count de `describe()` contra `len`.
- ▶ En la EOD: `TiempoViaje` tiene 278 faltantes entre 113.591 viajes.
- ▶ **Un NaN no siempre es error: en los factores de expansión significa "no aplica".**
- ▶ Opciones: eliminar, imputar o dejar que cada cálculo los excluya. Lo obligatorio: decidir y documentar.

Duplicados

- ▶ `duplicate()` marca filas repetidas; `drop_duplicates()` las elimina.
- ▶ Dos niveles: la fila completa y la llave que debería ser única.
- ▶ En la EOD ambos chequeos dan cero; un cero también es un hallazgo.
- ▶ El riesgo típico: un merge con llaves repetidas multiplica filas.

Valores sospechosos



116 viajes declaran más de 5 horas y el máximo es de 22 horas. ¿Error de registro o viaje real? La respuesta exige criterio del dominio; la decisión (mantener, corregir o excluir) se toma en el código y se documenta.

Tapar valores con mask

```
# donde la condición se cumple, reemplaza (aquí, por NaN)
viajes["TiempoViaje"] = viajes["TiempoViaje"].mask(
    viajes["TiempoViaje"] > 300)
```

- ▶ mask reemplaza donde la condición es verdadera; where, su espejo, conserva donde es verdadera y reemplaza el resto. Regla nemotécnica: mask es dónde tapar, where es dónde quedarse.

Revisar cada merge

- ▶ Comparar el número de filas antes y después: un inner descarta las filas sin pareja; en la clase 1, 113.591 viajes quedaron en 111.393.
- ▶ Contar los NaN de las columnas nuevas cuando se usa how="left": ahí quedan visibles las filas sin correspondencia (2.198 comunas).
- ▶ Verificar que la llave sea única en la tabla de parámetros: si está repetida, el merge multiplica filas.

Checklist de calidad antes de analizar

- ▶ Dimensiones y tipos: `shape`, `info()`.
- ▶ Faltantes por columna relevante: `isna().sum()`, `count` contra `len`.
- ▶ Duplicados: fila completa y llave única.
- ▶ Rangos válidos de cada variable cuantitativa: `min`, `max`, valores sospechosos.
- ▶ Merges verificados: filas, NaN nuevos, llaves únicas.
- ▶ **Cada decisión de limpieza queda escrita en el código, con su justificación.**

La pregunta y la hipótesis

Formular el proyecto antes de analizarlo

Seis tipos de pregunta

Complejidad creciente de la pregunta (1 a 6)

1. Descriptiva

resumir una característica
de los datos

2. Exploratoria

buscar patrones;
genera hipótesis

3. Inferencial

¿el patrón se sostiene
más allá de la muestra?

4. Predictiva

anticipar valores
para casos nuevos

5. Causal

¿qué cambia si
intervenimos X?

6. Mecanicista

¿cómo exactamente
X produce Y?

El módulo cubre los cuatro primeros tipos. El error más común de un análisis es responder un tipo de pregunta creyendo que se responde otro (Leek y Peng, 2015).

Qué hace buena a una pregunta

- ▶ De interés real: una audiencia concreta usaría la respuesta (Peng y Matsui, 2015).
- ▶ No respondida ya: revisar qué existe antes de empezar.
- ▶ Plausible: la respuesta esperada tiene un mecanismo creíble.
- ▶ Respondible: los datos necesarios existen y son obtenibles.
- ▶ Específica: nombra variables y población, no generalidades.

Malas preguntas, reparadas

La pregunta	El problema	Una versión que funciona
¿Cómo mejorar las ventas?	No dice qué medir ni dónde	¿Qué categorías de producto caen en invierno en las sucursales del sur?
¿Sirve la IA para mi empresa?	Sin variables ni población definidas	¿Cuántas horas de revisión manual ahorra clasificar los reclamos automáticamente?
¿Por qué renuncian los empleados?	Causal; los datos solo permiten explorar	¿Qué características comparten quienes renunciaron durante 2025?


La reparación típica: nombrar la variable, la población y el periodo, y bajar la ambición causal al tipo de pregunta que los datos permiten.

Malas hipótesis, reparadas

La hipótesis	El problema	Una versión verificable
El marketing influye en las ventas	No dice qué marketing ni qué ventas	Las semanas con campaña activa venden más que las semanas sin campaña, en la misma sucursal
Los datos mostrarán patrones interesantes	No es falsable: cualquier cosa la confirma	Los reclamos aumentan en los meses de mayor demanda
Los viajes largos son culpa del transporte público	Atribuye causa donde solo hay asociación	Los viajes en transporte público duran en promedio más que los viajes en auto

Una hipótesis verificable nombra variables medibles y una comparación concreta; la tercera es la que contrastaremos con la EOD.

El ciclo PPDAC



Problema, plan, datos, análisis y conclusión (Wild y Pfannkuch, 1999): la formulación del Capstone es la etapa de problema y plan de este ciclo.

De la pregunta a la hipótesis

- ▶ Hipótesis: una afirmación verificable, con variables medibles y una relación esperada.
- ▶ Pregunta: ¿la duración del viaje depende del modo de transporte?
- ▶ Hipótesis: los viajes en transporte público duran en promedio más que en auto.
- ▶ Variables: ModoAgrupado y TiempoViaje; el contraste es una comparación de medias (clase 5).
- ▶ **Sin qué medir ni qué comparar, es una intuición, no una hipótesis.**

La formulación del proyecto Capstone

- ▶ Se publica hoy la rúbrica, con seis criterios: problema (20 pts), datos y metadatos (20), estrategia de obtención (15), novedad (15), viabilidad técnica (15) e impacto esperado (15).
- ▶ Documento de 2 a 3 páginas, un envío por equipo (máximo 2 personas), por el aula virtual.
- ▶ **Entrega: lunes 7 de septiembre. Presentación breve de la idea: jueves 3, con retroalimentación y sin nota.**
- ▶ Quienes no usen datos de su trabajo pueden partir de la lista de datos sugeridos del repositorio.

Síntesis

- ▶ Describir una variable exige tres miradas: centro (media, mediana), dispersión (desviación, IQR) y forma (histograma, boxplot).
- ▶ Con asimetría, la mediana acompaña o reemplaza a la media.
- ▶ La limpieza es parte del análisis: faltantes, duplicados, rangos válidos y merges verificados, con decisiones documentadas.
- ▶ La pregunta del proyecto debe ser específica y la hipótesis, verificable con variables medibles.
- ▶ Próxima clase (martes 01-sep): EDA II, relaciones entre variables y correlación.

Referencias

Fisher, R. A. (1936). The Use of Multiple Measurements in Taxonomic Problems. *Annals of Eugenics*, 7(2), 179-188.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

Leek, J. T. y Peng, R. D. (2015). What is the question? *Science*, 347(6228), 1314-1315.

Peng, R. D. y Matsui, E. (2015). *The Art of Data Science*. Versión en línea:
bookdown.org/rdpeng/artofdatascience

Wild, C. J. y Pfannkuch, M. (1999). Statistical Thinking in Empirical Enquiry. *International Statistical Review*, 67(3), 223-248.

Anaconda (2020). 2020 State of Data Science. Reporte de encuesta (n=2.360).
anaconda.com/resources/whitepaper/state-of-data-science-2020