

Introducción y fundamentos estadísticos

Clase 3 · Análisis exploratorio de datos II

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 1 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Contenidos de la clase

- ▶ 1. Relaciones entre pares de variables.
- ▶ 2. Correlación: Pearson y Spearman.
- ▶ 3. La EOD: distancia y duración de los viajes.
- ▶ 4. Grupos y tablas de contingencia.
- ▶ 5. La primera regresión.
- ▶ 6. Buenas prácticas de visualización.

Avisos del proyecto Capstone

- ▶ **Inscriban su grupo en la planilla compartida (correo de ayer).**
- ▶ Jueves 3: presentación breve de la idea de cada equipo, alrededor de 5 minutos, sin nota. El enunciado y la rúbrica están publicados.
- ▶ Lunes 7: entrega de la formulación (30%).
- ▶ Lo de hoy alimenta directo el primer análisis exploratorio, que se entrega el martes 15.

El norte: los modelos

- ▶ **El diplomado apunta a construir modelos; la clase de hoy es su antesala directa.**
- ▶ La primera pregunta de hoy: ¿qué tan relacionadas están dos variables? Eso decide cuáles sirven para predecir.
- ▶ Y hacia el final, la primera regresión: el primer modelo del diplomado.

Relaciones entre variables


De describir una variable a cruzar dos

Tres tipos de pares, tres herramientas

cuantitativa vs cuantitativa
→ dispersión (scatter)



cuantitativa vs categórica
→ boxplot por grupo



categórica vs categórica
→ tabla de contingencia

62	38
45	55

El análisis bivariado depende del tipo de cada variable (clase 1): el par define qué gráfico y qué resumen corresponden.

Las tres especies de iris

setosa



versicolor




virginica



Las mismas 150 flores de la clase 2, 50 por especie. Fotografías: Radomil, D. Gordon E. Robertson y Frank Mayfield, Wikimedia Commons, CC BY-SA.

El gráfico de dispersión



Cada punto es una flor; los ejes son dos de sus medidas. La nube sube junta: pétalos más largos vienen con pétalos más anchos.

Correlación

Un número para la relación entre dos variables

El coeficiente de correlación de Pearson

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$


Cada punto aporta el producto de sus dos desviaciones respecto de la media: positivo si x e y se desvían para el mismo lado, negativo si se desvían al revés.

El denominador lo normaliza: r queda siempre entre -1 y 1 , sin unidades.

x_i, y_i : los valores del caso i · $\bar{x}, \bar{y}$: sus medias · la suma recorre los n casos


Mide la fuerza y el signo de la relación lineal entre dos variables cuantitativas.

La fórmula, dibujada



Las medias parten el plano en cuatro cuadrantes: los puntos de los cuadrantes verdes empujan r hacia arriba y los de los rojos, hacia abajo. En iris casi todos los aportes son positivos: $r = 0,96$.

La escala de r



$r = 1$ y $r = -1$ son rectas perfectas; $r = 0$, ausencia de relación lineal. En datos reales, los valores intermedios son la norma.


La correlación en Pandas

```
# Entre dos columnas
iris_df["petal length (cm)"].corr(iris_df["petal width (cm)"])
0.9629

# Todas contra todas: la matriz de correlación
iris_df.drop(columns="species").corr()
```


► `corr()` usa Pearson por defecto. En iris, largo y ancho del pétalo correlacionan

La matriz de correlación



Todos los pares de una vez: diagonal en 1 y matriz simétrica. El 0,96 entre largo y ancho del pétalo dice que son casi redundantes: evidencia para decidir qué variables conservar en un proyecto.

Siempre graficar: el cuarteto de Anscombe



Los cuatro conjuntos comparten medias, correlación y recta, y solo el primero es lo que el número sugiere. El resumen no reemplaza al gráfico.

El impacto de una sola fila

El impacto de una sola fila sobre la correlación (nubes de ejemplo)

Sin el punto extremo: $r = 0,21$



Con un solo punto extremo: $r = 0,82$



Cuarenta puntos sin relación ($r = 0,05$) y un solo punto extremo fabrican $r = 0,72$. La correlación de Pearson es tan sensible a los atípicos como la media.

Cómo se calculan los rangos

Cinco comunas: rango = posición al ordenar cada variable

Comuna	Ingreso (M\$)	Duración (min)	Rango ing.	Rango dur.	d	d ²
Vitacura	1,66	27,0	5	2	3	9
Providencia	1,47	25,0	4	1	3	9
Santiago	0,71	27,4	3	3	0	0
Puente Alto	0,66	40,3	2	5	-3	9
Cerro Navia	0,46	36,0	1	4	-3	9

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} = 1 - \frac{6 \cdot 36}{5(25 - 1)} = -0,80$$

ρ : la correlación de Spearman · d_i : diferencia de rangos de la comuna i · n : número de casos (aquí 5)

Cada variable se ordena por separado y cada valor recibe su posición. En la fórmula: d_i es la diferencia de rangos de la comuna i , y n el número de casos. Cinco comunas bastan para calcular un Spearman a mano.



Los rangos en Pandas: rank()

```
# rank() ordena la columna y asigna posiciones: 1 el menor
cinco_comunas["rango_ingreso"] = cinco_comunas["ingreso"].rank()
cinco_comunas["rango_duracion"] =
cinco_comunas["duracion"].rank()
```

- Con los rangos listos, Spearman es el Pearson de esas dos columnas nuevas: `corr(method="spearman")` hace todo el proceso de una vez.


Spearman: la correlación de los rangos

Spearman: reemplazar cada valor por su posición en el orden (nube de ejemplo)



Reemplazar cada valor por su posición en el orden endereza las curvas monótonas y desarma los atípicos. En Pandas: `corr(method="spearman")`. En la EOD, distancia y duración dan 0,57 con Pearson y 0,76 con Spearman: la diferencia de la curvatura y atípicos.

Correlación no es causalidad



Que dos variables se muevan juntas no dice que una cause a la otra: puede haber una tercera moviendo a ambas. Con datos observacionales reportamos asociación (recuerden las preguntas reparadas de la clase 2).

La EOD: ingreso y duración

¿Los que menos ganan viajan más tiempo?

La media ponderada, con el factor

Conclusiones sobre la ciudad: cada hogar pesa según su factor de expansión

$$\bar{x}_w = \frac{\sum_i w_i x_i}{\sum_i w_i}$$

$\bar{x}_w$: la media ponderada · x_i : el valor del hogar i · w_i : su factor de expansión (a cuántos hogares representa)

La media ponderada de la clase 2, ahora por comuna: la siguiente diapo la aplica en pandas, sumando w por x y dividiendo por la suma de w .


La tabla por comuna, ponderada

```
lab["w_ingreso"] = lab["Factor"] * lab["IngresoHogar"]
suma = lab.groupby("Comuna").sum()

# La media ponderada de la clase 2, ahora por comuna
suma["w_ingreso"] / suma["Factor"]
```


- Las conclusiones son sobre la ciudad, así que se pondera (clase 2): cada media por comuna es suma de w por x , dividida por suma de w , con el factor del día laboral

Ingreso y duración, por comuna



Cada punto es una comuna (medias ponderadas por factor). La asociación es negativa ($r = -0,34$): las comunas de menor ingreso promedian viajes más largos. Providencia, 25 minutos; Puente Alto, 40.

La matriz de las comunas



Cuatro variables, seis pares (todo ponderado): el ingreso compra autos (0,94), y la sorpresa es que el mejor acompañante de la duración no es el ingreso (-0,34) sino las personas por hogar (0,65).

Grupos y tablas de contingencia

Cuando una de las dos variables es categórica

groupby: partir, aplicar, juntar

`groupby("species")["petal length"].mean():` partir, aplicar, juntar

la tabla

setosa · 1,4
virginica · 5,5
setosa · 1,5
versicolor · 4,7
virginica · 6,0
versicolor · 4,4

1. partir por categoría

setosa · 1,4
setosa · 1,5
versicolor · 4,7
versicolor · 4,4
virginica · 5,5
virginica · 6,0

2. aplicar el resumen

media = 1,45
media = 4,55
media = 5,75

3. juntar los resultados

La versión numérica del boxplot por grupo: la tabla se parte por categoría, cada parte recibe el resumen y los resultados se juntan.

El resumen por grupo: groupby

```
# ¿Cuántos viajes diarios mueve cada modo?  
lab.groupby("ModoAgrupado")["w"].sum()
```

- ▶ groupby parte la tabla por categoría, aplica el resumen a cada parte y junta los resultados. El peso w (factor de la persona por ajuste del viaje) expande la muestra a la ciudad.

El resultado, como tabla

groupby y suma del peso w: los viajes de un día laboral

Modo	Viajes al día (millones)
Caminata	6,36
Auto	4,75
Bip! (solo o combinado)	4,62
Otros	1,14
Bicicleta	0,75
Taxi Colectivo	0,53
Taxi	0,31

La serie que devuelve groupby, ordenada: los viajes que cada modo mueve en un día laboral de Santiago.

Dos categóricas: la tabla de contingencia

- ▶ **La tabla de contingencia cuenta cuántos casos caen en cada combinación: una categórica en las filas, la otra en las columnas.**
- ▶ En pandas hay dos herramientas hermanas: `pivot_table`, la general, y `pd.crosstab`, la especialista en contar.
- ▶ La pregunta para la EOD: ¿el modo de viaje depende del sexo?

De la tabla larga al cuadro de doble entrada

Antes: una fila por viaje (78.820 filas)

SexoNombre	ModoAgrupado	w
Mujer	Bip! (solo o combinado)	142,3
Hombre	Bip! (solo o combinado)	127,3
Hombre	Bip! (solo o combinado)	127,3
Mujer	Bip! (solo o combinado)	116,7
Mujer	Bip! (solo o combinado)	109,0
Mujer	Auto	138,5
Mujer	Auto	138,5
Mujer	Auto	196,9

Después: una celda por combinación



Sexo	Caminata	Auto	Bip! (solo o combinado)	Otros	Bicicleta	Taxi Colectivo	Taxi
Hombre	8.537	9.879	12.164	3.488	1.948	718	406
Mujer	14.658	7.490	13.204	3.230	710	1.680	708

Las dos herramientas hacen la misma transformación: de una fila por viaje a una celda por combinación de sexo y modo (aquí, contando los viajes de la muestra).

pivot_table: el groupby en dos dimensiones

```
lab.pivot_table(  
    values="w",          # la columna a resumir  
    index="SexoNombre",  # define las filas  
    columns="ModoAgrupado", # define las columnas  
    aggfunc="sum")       # el resumen por celda
```

- Reordena la tabla como cuadro de doble entrada y resume cada celda: contar, sumar, promediar. Sumando el peso w, cada celda queda en viajes de la ciudad.

pd.crosstab: la especialista en contar

```
pd.crosstab(  
    lab["SexoNombre"],      # la variable de las filas  
    lab["ModoAgrupado"],    # la de las columnas  
    values=lab["w"], aggfunc="sum", # sumar w, no contar  
    normalize="index")      # proporciones por fila
```

- Sola, crosstab cuenta combinaciones; con values y aggfunc pondera igual que pivot_table, y normalize entrega las proporciones por fila.

El resultado: modo según sexo

Modo según sexo, ponderado: cada fila suma 100


Sexo (%)	Caminata	Auto	Bip! (solo o combinado)	Otros	Bicicleta	Taxi Colectivo	Taxi
Hombre	28,4	30,5	25,2	6,8	5,9	1,9	1,4
Mujer	40,2	21,2	24,9	5,6	2,3	3,8	2,0

La tabla tal como la entrega el código: el sexo en las filas (index) y el modo en las columnas. Cada fila suma 100: las mujeres caminan más (40% contra 28%); los hombres usan más el auto (31% contra 21%).

La primera regresión

El primer modelo del diplomado

Mínimos cuadrados



$$\hat{y} = a + bx$$

Mínimos cuadrados: la recta que hace mínima la suma de los errores al cuadrado.

$$b = r \frac{S_y}{S_x} \text{ y la recta pasa por } (\bar{x}, \bar{y})$$

$\hat{y}$: el valor predicho · b : pendiente · a : intercepto
 r : la correlación · S_x, S_y : las desviaciones estándar

La correlación mide la asociación; la regresión la dibuja: la recta que deja la menor suma de errores al cuadrado. La pendiente dice cuánto cambia y por cada unidad de x . Hoy es un primer contacto; en las clases 6 y 7 la profundizamos.

Las fórmulas de la recta


Mínimos cuadrados (OLS): la recta que minimiza la suma de los errores al cuadrado

$$b = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} \quad a = \bar{y} - b\bar{x}$$

b : la pendiente · a : el intercepto · x_i, y_i : los valores del caso i · $\bar{x}, \bar{y}$: sus medias


El método se llama mínimos cuadrados ordinarios (OLS): `np.polyfit` implementa exactamente esta fórmula. En las clases 6 y 7 lo harán `scikit-learn` y `statsmodels`, con diagnósticos e inferencia.

Pendiente e intercepto, dibujados



El intercepto es donde la recta corta el eje: el valor de y cuando x es 0. La pendiente es cuánto sube y por cada unidad de x . En nuestra recta: 38,3 minutos de base y $-4,8$ por cada millón de ingreso.

La recta: ingreso y duración



duración = $38,3 - 4,8 \cdot \text{ingreso}$ (ponderada por factor): por cada millón adicional, la duración media baja casi 5 minutos. Y $r^2 = 0,12$: la recta captura el 12% de la variación; la asociación es real pero moderada, y así se reporta.

La recta en NumPy

```
# La recta  $y = a + b \cdot x$ : polyfit devuelve [b, a], en ese orden
pendiente, intercepto = np.polyfit(por_comuna["ingreso"],
                                    por_comuna["duracion"], 1)

ax.plot(x, intercepto + pendiente * x)
```

- polyfit ajusta un polinomio por mínimos cuadrados; el 1 pide grado 1, una recta. En las clases 6 y 7 usaremos herramientas con más diagnósticos.

Usar la recta: predecir y medir residuos

```
# El residuo  $e = y - (a + b \cdot x)$ : lo observado menos lo predicho  
prediccion = intercepto + pendiente * ingreso  
residuo = duracion - prediccion  
  
por_comuna.nlargest(5, "residuo")
```

- La Pintana viaja 13 minutos más de lo predicho y Santiago 7 menos: el residuo revela periferia y centralidad. ¿Azar? La clase 5 responde.

El impacto de sacar una fila

- ▶ **Medirlo: recalculamos cada resumen sin la fila, y comparar.**
- ▶ Sin Lo Barnechea, r casi no se mueve (sigue en $-0,34$), pero la pendiente cambia en un quinto: de $-4,8$ a $-5,8$ minutos por millón.
- ▶ Un mismo punto puede pesar poco en un resumen y mucho en otro. El código está en el notebook.

Las fórmulas, con factor de expansión

Con factores de expansión, cada término se pesa por su w_i

$$b_w = \frac{\sum_i w_i (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_i w_i (x_i - \bar{x}_w)^2} \quad a_w = \bar{y}_w - b_w \bar{x}_w$$

w_i : el factor de expansión de la fila i · $\bar{x}_w, \bar{y}_w$: las medias ponderadas

La misma recta de mínimos cuadrados, con cada término pesado por su factor: es la que usa el modelo que sigue, y en statsmodels se llama WLS (weighted least squares).


Otro modelo: la motorización del hogar

```
x = h["IngresoHogar"] / 1e6
y, w = h["NumVeh"], h["Factor"]

# La fórmula de la pendiente ponderada, tal cual
b = (w*(x - xw)*(y - yw)).sum() / (w*(x - xw)**2).sum()
```

- 18.264 hogares reales, ponderados por su factor: vehículos = $0,20 + 0,50 \cdot$ ingreso. Medio vehículo más por cada millón.

Los atípicos de la variable a predecir



El boxplot de NumVeh (clase 2): la cerca de Tukey queda en 2,5, y los hogares de 3 autos o más son atípicos. La siguiente diapo mide qué pasa al sacarlos.

Sacar atípicos de la variable a predecir

```
q1, q3 = h["NumVeh"].quantile([0.25, 0.75])
sin_atipicos = h[h["NumVeh"] <= q3 + 1.5 * (q3 - q1)]


# El mismo modelo, sin los hogares de 3 autos o más
np.polyfit(sin_atipicos["IngresoHogar"] / 1e6,
sin_atipicos["NumVeh"], 1)
```

- Sacar 236 hogares aplanar la pendiente ponderada (0,50 a 0,44): no eran errores, eran la señal. Los atípicos de y se investigan; se eliminan solo por dominio.

Buenas prácticas de visualización


Que el gráfico diga la verdad y se entienda

Graficar 90 mil puntos: overplotting



Con todos los puntos sólidos, el scatter se satura y miente. Los remedios: transparencia (alpha), muestreo, o hexbin, donde el color cuenta los viajes (la distancia viene en la tabla DistanciaViaje.csv; sus -1 son faltantes disfrazados).


Cuándo usar escala logarítmica




La misma distancia tiene cola larga: en lineal se aplasta; en log, la forma aparece. Y transformar con log es feature engineering clásico: vuelve lineales las relaciones multiplicativas (clases de regresión).

El mismo gráfico, dos veces

Sin títulos, sin unidades, saturado



A más distancia, más duración
(30 mil viajes, EOD 2012)



Los mismos 30 mil viajes: sin rotular y saturado, contra rotulado, con transparencia y con el hallazgo en el título.

Checklist del buen gráfico

- ▶ Título que diga el hallazgo, no solo las variables.
- ▶ Ejes con nombre y unidad; ejes que parten de cero en gráficos de barras.
- ▶ Muchos puntos: alpha, muestreo o hexbin.
- ▶ Colas largas: escala logarítmica o eje recortado, declarándolo.
- ▶ **El gráfico se corrige igual que el código: se itera hasta que un tercero lo entienda sin explicación oral.**

Recreo

10 minutos · al volver: manos al teclado, con el notebook

Síntesis

- ▶ El análisis bivariado se elige según el par de tipos: scatter y correlación, groupby y boxplot, o tabla de contingencia.
- ▶ Pearson para relaciones lineales; Spearman cuando hay atípicos o curvas. Y siempre graficar: Anscombe.
- ▶ Correlación no es causalidad: reportamos asociación.
- ▶ La regresión es el primer modelo: una función que resume, predice y deja residuos que diagnostican.
- ▶ **Todo lo de hoy es exactamente lo que el primer EDA del proyecto debe mostrar (entrega: martes 15).**

Próxima clase

- ▶ **Jueves 3 de septiembre: presentaciones breves de las ideas de proyecto (5 minutos por equipo, sin nota).**
- ▶ Después: fundamentos de probabilidad, la base para la inferencia de las clases siguientes.
- ▶ Se publica la rúbrica del primer análisis exploratorio.
- ▶ Recuerden: la formulación se entrega el lunes 7 por el aula virtual.

Referencias

Anscombe, F. J. (1973). Graphs in Statistical Analysis. The American Statistician, 27(1), 17-21.

Spearman, C. (1904). The Proof and Measurement of Association between Two Things. The American Journal of Psychology, 15(1), 72-101.

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo 4 (Matplotlib).

Datos: Encuesta Origen Destino Santiago 2012 (Sectra) e iris (Fisher, 1936).