

Introducción y fundamentos estadísticos

Clase 3 · Análisis exploratorio de datos II

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 1 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Contenidos de la clase

- ▶ 1. Relaciones entre pares de variables.
- ▶ 2. Correlación: Pearson y Spearman.
- ▶ 3. La EOD: distancia y duración de los viajes.
- ▶ 4. Grupos y tablas de contingencia.
- ▶ 5. La primera regresión.
- ▶ 6. Buenas prácticas de visualización.

Avisos del proyecto Capstone

- ▶ **Inscriban su grupo en la planilla compartida (correo de ayer).**
- ▶ Jueves 3: presentación breve de la idea de cada equipo, alrededor de 5 minutos, sin nota. El enunciado y la rúbrica están publicados.
- ▶ Lunes 7: entrega de la formulación (30%).
- ▶ Lo de hoy alimenta directo el primer análisis exploratorio, que se entrega el lunes 15.


El norte: los modelos

- ▶ **El diplomado apunta a construir modelos; la clase de hoy es su antesala directa.**
- ▶ La correlación dice qué variables prometen como predictoras; la matriz ayuda a elegirirlas y a descartar redundantes.
- ▶ Crear variables nuevas desde las existentes (resúmenes por comuna, una distancia desde coordenadas) es el feature engineering: la materia prima de los modelos.
- ▶ La regresión de hoy ya ES un modelo: el primero del diplomado.
- ▶ Sus residuos son el primer diagnóstico; la validación formal (hipótesis, valor p) llega en la clase 5.

Relaciones entre variables


De describir una variable a cruzar dos

Tres tipos de pares, tres herramientas



El análisis bivariado depende del tipo de cada variable (clase 1): el par define qué gráfico y qué resumen corresponden.

El gráfico de dispersión



Cada punto es una flor; los ejes son dos de sus medidas. La nube sube junta: pétalos más largos vienen con pétalos más anchos.

Correlación

Un número para la relación entre dos variables

El coeficiente de correlación de Pearson


$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$

Cada punto aporta el producto de sus dos desviaciones respecto de la media: positivo si x e y se desvían para el mismo lado, negativo si se desvían al revés.

El denominador lo normaliza: r queda siempre entre -1 y 1, sin unidades.


Mide la fuerza y el signo de la relación lineal entre dos variables cuantitativas.

La fórmula, dibujada



Las medias parten el plano en cuatro cuadrantes: los puntos de los cuadrantes verdes empujan r hacia arriba y los de los rojos, hacia abajo. En iris casi todos los aportes son positivos: $r = 0,96$.

La escala de r



$r = 1$ y $r = -1$ son rectas perfectas; $r = 0$, ausencia de relación lineal. En datos reales, los valores intermedios son la norma.


La correlación en Pandas

```
# Entre dos columnas
iris_df["petal length (cm)"].corr(iris_df["petal width (cm)"])

# Todas contra todas: la matriz de correlación
iris_df.drop(columns="species").corr()
```


- `corr()` usa Pearson por defecto. En iris, largo y ancho del pétalo correlacionan 0,96.

La matriz de correlación



Todos los pares de una vez: diagonal en 1 y matriz simétrica. El 0,96 entre largo y ancho del pétalo dice que son casi redundantes: evidencia para decidir qué variables conservar en un proyecto.

Siempre graficar: el cuarteto de Anscombe



Los cuatro conjuntos comparten medias, correlación y recta, y solo el primero es lo que el número sugiere. El resumen no reemplaza al gráfico.

El impacto de una sola fila

El impacto de una sola fila sobre la correlación (nubes de ejemplo)

Sin el punto extremo: $r = 0,21$



Con un solo punto extremo: $r = 0,82$



Cuarenta puntos sin relación ($r = 0,05$) y un solo punto extremo fabrican $r = 0,72$. La correlación de Pearson es tan sensible a los atípicos como la media.

Cómo se calculan los rangos

Cinco comunas: rango = posición al ordenar cada variable



Comuna	Ingreso (M\$)	Duración (min)	Rango ing.	Rango dur.	d	d ²
Vitacura	1,66	27,0	5	2	3	9
Providencia	1,47	25,0	4	1	3	9
Santiago	0,71	27,4	3	3	0	0
Puente Alto	0,66	40,3	2	5	-3	9
Cerro Navia	0,46	36,0	1	4	-3	9

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} = 1 - \frac{6 \cdot 36}{5(25 - 1)} = -0,80$$

Cada variable se ordena por separado y cada valor recibe su posición; d compara las posiciones de una misma comuna. Con la fórmula de los rangos, cinco comunas bastan para calcular un Spearman a mano.


Spearman: la correlación de los rangos

Spearman: reemplazar cada valor por su posición en el orden (nube de ejemplo)



Reemplazar cada valor por su posición en el orden endereza las curvas monótonas y desarma los atípicos. En Pandas: `corr(method="spearman")`. En la EOD, distancia y duración dan 0,54 con Pearson y 0,70 con Spearman: la diferencia delata curvatura y atípicos.

Correlación no es causalidad



Que dos variables se muevan juntas no dice que una cause a la otra: puede haber una tercera moviendo a ambas. Con datos observacionales reportamos asociación (recuerden las preguntas reparadas de la clase 2).

Recreo

10 minutos

La EOD: ingreso y duración

¿Los que menos ganan viajan más tiempo?


La tabla por comuna, ponderada

```
lab["w_ingreso"] = lab["Factor"] * lab["IngresoHogar"]
suma = lab.groupby("Comuna").sum()

# La media ponderada de la clase 2, ahora por comuna
suma["w_ingreso"] / suma["Factor"]
```


- Las conclusiones son sobre la ciudad, así que se pondera (clase 2): cada media por comuna es suma de w por x , dividida por suma de w , con el factor del día laboral

Ingreso y duración, por comuna



Cada punto es una comuna (medias ponderadas por factor). La asociación es negativa ($r = -0,34$): las comunas de menor ingreso promedian viajes más largos. Providencia, 25 minutos; Puente Alto, 40.

La matriz de las comunas




Cuatro variables, seis pares (todo ponderado): el ingreso compra autos (0,94), y la sorpresa es que el mejor acompañante de la duración no es el ingreso (-0,34) sino las personas por hogar (0,65).

Grupos y tablas de contingencia

Cuando una de las dos variables es categórica

groupby: partir, aplicar, juntar

`groupby("species")["petal length"].mean():` partir, aplicar, juntar



La versión numérica del boxplot por grupo: la tabla se parte por categoría, cada parte recibe el resumen y los resultados se juntan.

La media por grupo: groupby

```
iris_df.groupby("species")["petal length (cm)"].mean()  
  
# El mismo resumen que construimos a mano con loc y el for,  
# ahora en una línea
```

- ▶ groupby parte la tabla por categoría, aplica el resumen a cada parte y junta los resultados: 1,46 / 4,26 / 5,55 cm. Es la versión numérica del boxplot por grupo.

Dos categóricas: la tabla de contingencia


```
pd.crosstab(datos["Sexo"], datos["ModoAgrupado"],  
            normalize="index")  
# Para la ciudad: sumar factores en vez de contar viajes  
datos.pivot_table(values="Factor", index="Sexo",  
                  columns="ModoAgrupado", aggfunc="sum")
```

- Ponderado por factor, en día laboral: las mujeres caminan más (40% contra 27%) y los hombres usan más el auto (28% contra 19%).

La primera regresión

El primer modelo del diplomado

Mínimos cuadrados



$$\hat{y} = a + b x$$

Mínimos cuadrados: la recta que hace mínima la suma de los errores al cuadrado.

$$b = r \frac{s_y}{s_x} \text{ y la recta pasa por } (\bar{x}, \bar{y})$$

La correlación mide la asociación; la regresión la dibuja: la recta que deja la menor suma de errores al cuadrado. La pendiente dice cuánto cambia y por cada unidad de x. Hoy es un primer contacto; en las clases 6 y 7 la profundizamos.


Las fórmulas de la recta

Mínimos cuadrados (OLS): la recta que minimiza la suma de los errores al cuadrado

$$b = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} \quad a = \bar{y} - b\bar{x}$$


El método se llama mínimos cuadrados ordinarios (OLS): `np.polyfit` implementa exactamente esta fórmula. En las clases 6 y 7 lo harán `scikit-learn` y `statsmodels`, con diagnósticos e inferencia.

Pendiente e intercepto, dibujados



El intercepto es donde la recta corta el eje: el valor de y cuando x es 0. La pendiente es cuánto sube y por cada unidad de x . En nuestra recta: 38,3 minutos de base y -4,8 por cada millón de ingreso.

La recta: ingreso y duración



$\text{duración} = 38,3 - 4,8 \cdot \text{ingreso}$ (ponderada por factor): por cada millón adicional, la duración media baja casi 5 minutos. Y $r^2 = 0,12$: la recta captura el 12% de la variación; la asociación es real pero moderada, y así se reporta.

La recta en NumPy

```
pendiente, intercepto = np.polyfit(por_comuna["ingreso"],  
                                   por_comuna["duracion"], 1)  
  
# La recta evaluada, para dibujarla sobre el scatter  
ax.plot(x, intercepto + pendiente * x)
```

- `polyfit` ajusta un polinomio por mínimos cuadrados; el 1 pide grado 1, una recta. En las clases 6 y 7 usaremos herramientas con más diagnósticos.

Usar la recta: predecir y medir residuos

```
prediccion = intercepto + pendiente * ingreso  
residuo = duracion - prediccion  
  
# ¿Qué comunas viajan más de lo que su ingreso predice?  
por_comuna.nlargest(5, "residuo")
```

- La Pintana viaja 13 minutos más de lo predicho y Santiago 7 menos: el residuo revela periferia y centralidad. ¿Azar? La clase 5 responde.

El impacto de sacar una fila

```
sin_lb = por_comuna[por_comuna["Comuna"] != "LO BARNECHEA"]  
  
# Todo se recalcula sin la fila, y se compara  
sin_lb["ingreso"].corr(sin_lb["duracion"])  
np.polyfit(sin_lb["ingreso"] / 1e6, sin_lb["duracion"], 1)
```

- Sacar 1 comuna de 45 no mueve r (-0,34) pero cambia la pendiente en un quinto (-4,8 a -5,8): el impacto se mide con y sin, sobre todos los resúmenes en uso.

Las fórmulas, con factor de expansión

Con factores de expansión, cada término se pesa por su w_i

$$b_w = \frac{\sum_i w_i (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_i w_i (x_i - \bar{x}_w)^2} \quad a_w = \bar{y}_w - b_w \bar{x}_w$$

La misma recta de mínimos cuadrados, con cada término pesado por su factor: es la que usa el modelo que sigue, y en statsmodels se llama WLS (weighted least squares).

Otro modelo: la motorización del hogar

```
x = h["IngresoHogar"] / 1e6
y, w = h["NumVeh"], h["Factor"]

# La fórmula de la pendiente ponderada, tal cual
b = (w*(x - xw)*(y - yw)).sum() / (w*(x - xw)**2).sum()
```

- 18.264 hogares reales, ponderados por su factor: vehículos = $0,20 + 0,50 \cdot$ ingreso. Medio vehículo más por cada millón.

Sacar atípicos de la variable a predecir

```
q1, q3 = h["NumVeh"].quantile([0.25, 0.75])
sin_atipicos = h[h["NumVeh"] <= q3 + 1.5 * (q3 - q1)]


# El mismo modelo, sin los hogares de 3 autos o más
np.polyfit(sin_atipicos["IngresoHogar"] / 1e6,
sin_atipicos["NumVeh"], 1)
```

- Sacar 236 hogares aplanar la pendiente ponderada (0,50 a 0,44): no eran errores, eran la señal. Los atípicos de y se investigan; se eliminan solo por dominio.

Buenas prácticas de visualización


Que el gráfico diga la verdad y se entienda

Graficar 90 mil puntos: overplotting




Con todos los puntos sólidos, el scatter se satura y miente. Los remedios: transparencia (alpha), muestreo, o hexbin, donde el color cuenta los viajes (la distancia se calcula con las coordenadas; el notebook muestra el cálculo).

Cuándo usar escala logarítmica



Con colas largas como el ingreso, la escala lineal aplasta el 99% de los datos contra el borde; la logarítmica reparte el espacio y la forma aparece.

El mismo gráfico, dos veces



Los mismos 30 mil viajes: sin rotular y saturado, contra rotulado, con transparencia y con el hallazgo en el título.

Checklist del buen gráfico

- ▶ Título que diga el hallazgo, no solo las variables.
- ▶ Ejes con nombre y unidad; ejes que parten de cero en gráficos de barras.
- ▶ Muchos puntos: alpha, muestreo o hexbin.
- ▶ Colas largas: escala logarítmica o eje recortado, declarándolo.
- ▶ **El gráfico se corrige igual que el código: se itera hasta que un tercero lo entienda sin explicación oral.**

Síntesis

- ▶ El análisis bivariado se elige según el par de tipos: scatter y correlación, groupby y boxplot, o tabla de contingencia.
- ▶ Pearson para relaciones lineales; Spearman cuando hay atípicos o curvas. Y siempre graficar: Anscombe.
- ▶ Correlación no es causalidad: reportamos asociación.
- ▶ La regresión es el primer modelo: una función que resume, predice y deja residuos que diagnostican.
- ▶ **Todo lo de hoy es exactamente lo que el primer EDA del proyecto debe mostrar (entrega: lunes 15).**

Próxima clase

- ▶ **Jueves 3 de septiembre: presentaciones breves de las ideas de proyecto (5 minutos por equipo, sin nota).**
- ▶ Después: fundamentos de probabilidad, la base para la inferencia de las clases siguientes.
- ▶ Se publica la rúbrica del primer análisis exploratorio.
- ▶ Recuerden: la formulación se entrega el lunes 7 por el aula virtual.

Referencias

Anscombe, F. J. (1973). Graphs in Statistical Analysis. The American Statistician, 27(1), 17-21.

Spearman, C. (1904). The Proof and Measurement of Association between Two Things. The American Journal of Psychology, 15(1), 72-101.

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo 4 (Matplotlib).

Datos: Encuesta Origen Destino Santiago 2012 (Sectra) e iris (Fisher, 1936).