

Introducción y fundamentos estadísticos

Clase 3 · Análisis exploratorio de datos II

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 1 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Contenidos de la clase

- ▶ 1. Relaciones entre pares de variables.
- ▶ 2. Correlación: Pearson y Spearman.
- ▶ 3. La EOD: distancia y duración de los viajes.
- ▶ 4. Grupos y tablas de contingencia.
- ▶ 5. La primera regresión.
- ▶ 6. Buenas prácticas de visualización.


Avisos del proyecto Capstone

- ▶ **Inscriban su grupo en la planilla compartida (correo de ayer).**
- ▶ Jueves 3: presentación breve de la idea de cada equipo, alrededor de 5 minutos, sin nota. El enunciado y la rúbrica están publicados.
- ▶ Lunes 7: entrega de la formulación (30%).
- ▶ Lo de hoy alimenta directo el primer análisis exploratorio, que se entrega el lunes 15.

Relaciones entre variables


De describir una variable a cruzar dos

Tres tipos de pares, tres herramientas



El análisis bivariado depende del tipo de cada variable (clase 1): el par define qué gráfico y qué resumen corresponden.

El gráfico de dispersión



Cada punto es una flor; los ejes son dos de sus medidas. La nube sube junta: pétalos más largos vienen con pétalos más anchos.

Correlación

Un número para la relación entre dos variables

El coeficiente de correlación de Pearson


$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$

Cada punto aporta el producto de sus dos desviaciones respecto de la media: positivo si x e y se desvían para el mismo lado, negativo si se desvían al revés.

El denominador lo normaliza: r queda siempre entre -1 y 1, sin unidades.

Mide la fuerza y el signo de la relación lineal entre dos variables cuantitativas.

La escala de r



$r = 1$ y $r = -1$ son rectas perfectas; $r = 0$, ausencia de relación lineal. En datos reales, los valores intermedios son la norma.


La correlación en Pandas

```
# Entre dos columnas
iris_df["petal length (cm)"].corr(iris_df["petal width (cm)"])

# Todas contra todas: la matriz de correlación
iris_df.drop(columns="species").corr()
```


- `corr()` usa Pearson por defecto. En iris, largo y ancho del pétalo correlacionan 0,96.

La matriz de correlación



Todos los pares de una vez: diagonal en 1 y matriz simétrica. El 0,96 entre largo y ancho del pétalo dice que son casi redundantes: evidencia para decidir qué variables conservar en un proyecto.

Siempre graficar: el cuarteto de Anscombe



Los cuatro conjuntos comparten medias, correlación y recta, y solo el primero es lo que el número sugiere. El resumen no reemplaza al gráfico.

El impacto de una sola fila

El impacto de una sola fila sobre la correlación (nubes de ejemplo)

Sin el punto extremo: $r = 0,21$



Con un solo punto extremo: $r = 0,82$



Cuarenta puntos sin relación ($r = 0,05$) y un solo punto extremo fabrican $r = 0,72$. La correlación de Pearson es tan sensible a los atípicos como la media.

Spearman: la correlación robusta

- ▶ **Spearman calcula el Pearson de los rangos: reemplaza cada valor por su posición en el orden (1°, 2°, 3° ...).**
- ▶ Por eso resiste atípicos y captura relaciones monótonas aunque no sean rectas.
- ▶ En Pandas: `corr(method="spearman")`.
- ▶ En la EOD: distancia y duración dan 0,54 con Pearson y 0,70 con Spearman. La diferencia delata atípicos y curvatura: hay que mirar el gráfico.

Correlación no es causalidad

- ▶ **Que dos variables se muevan juntas no dice que una cause a la otra.**
- ▶ Puede haber una tercera variable moviendo a ambas: los meses de calor suben los helados y los ahogados, sin que uno cause el otro.
- ▶ Puede ser al revés de lo que se piensa, o pura coincidencia.
- ▶ Con datos observacionales reportamos asociación; el lenguaje causal exige diseños que este módulo no cubre (recuerden la tabla de preguntas reparadas de la clase 2).

Recreo

10 minutos

La EOD: distancia y duración

Calcular una variable nueva y cruzarla


La distancia de cada viaje

```
dx = viajes["DestinoCoordX"] - viajes["OrigenCoordX"]
dy = viajes["DestinoCoordY"] - viajes["OrigenCoordY"]

# Pitágoras, vectorizado: 90 mil distancias de una vez
viajes["DistKm"] = np.sqrt(dx**2 + dy**2) / 1000
```

- Distancia en línea recta entre origen y destino (las coordenadas vienen en metros). Antes hay que filtrar 4.122 filas con coordenada 0: faltantes disfrazados, como los códigos 000 de la clase 2.

Graficar 90 mil puntos: overplotting



Con todos los puntos sólidos, el scatter se satura y miente. Los remedios: transparencia (alpha), muestreo, o hexbin, donde el color cuenta los viajes.

Grupos y tablas de contingencia

Cuando una de las dos variables es categórica

La media por grupo: groupby

```
iris_df.groupby("species")["petal length (cm)"].mean()  
  
# El mismo resumen que construimos a mano con loc y el for,  
# ahora en una línea
```

- ▶ groupby parte la tabla por categoría, aplica el resumen a cada parte y junta los resultados: 1,46 / 4,26 / 5,55 cm. Es la versión numérica del boxplot por grupo.

Dos categóricas: la tabla de contingencia

```
pd.crosstab(datos["Sexo"], datos["ModoAgrupado"],  
            normalize="index")  
# Para la ciudad: sumar factores en vez de contar viajes  
datos.pivot_table(values="Factor", index="Sexo",  
                  columns="ModoAgrupado", aggfunc="sum")
```

- Ponderado por factor, en día laboral: las mujeres caminan más (40% contra 27%) y los hombres usan más el auto (28% contra 19%).


La primera regresión

La recta que resume la relación

De la correlación a la recta

- ▶ **La correlación dice cuánto se asocian dos variables; la regresión dibuja la recta que mejor resume esa asociación.**
- ▶ "Mejor" tiene definición: la recta de mínimos cuadrados, la que deja la menor suma de errores al cuadrado.
- ▶ Sus dos números se interpretan: la pendiente (cuánto cambia y por cada unidad de x) y el intercepto (el valor de y cuando x es 0).
- ▶ Hoy es un primer contacto; en las clases 6 y 7 la profundizamos.

La recta en la EOD



tiempo = $25,4 + 2,5 \cdot \text{km}$: cada kilómetro agrega 2,5 minutos, y el viaje parte costando unos 25 (caminatas, esperas, transbordos).

La recta en NumPy

```
pendiente, intercepto = np.polyfit(distancia, tiempo, 1)


# La recta evaluada, para dibujarla sobre el scatter
ax.plot(x, intercepto + pendiente * x)
```

- polyfit ajusta un polinomio por mínimos cuadrados; el 1 pide grado 1, una recta. En las clases 6 y 7 usaremos herramientas con más diagnósticos.

Buenas prácticas de visualización

Que el gráfico diga la verdad y se entienda

Cuándo usar escala logarítmica



Con colas largas como el ingreso, la escala lineal aplasta el 99% de los datos contra el borde; la logarítmica reparte el espacio y la forma aparece.

Checklist del buen gráfico

- ▶ Título que diga el hallazgo, no solo las variables.
- ▶ Ejes con nombre y unidad; ejes que parten de cero en gráficos de barras.
- ▶ Muchos puntos: alpha, muestreo o hexbin.
- ▶ Colas largas: escala logarítmica o eje recortado, declarándolo.
- ▶ **El gráfico se corrige igual que el código: se itera hasta que un tercero lo entienda sin explicación oral.**

Síntesis

- ▶ El análisis bivariado se elige según el par de tipos: scatter y correlación, groupby y boxplot, o tabla de contingencia.
- ▶ Pearson para relaciones lineales; Spearman cuando hay atípicos o curvas. Y siempre graficar: Anscombe.
- ▶ Correlación no es causalidad: reportamos asociación.
- ▶ La regresión da la recta interpretable: pendiente e intercepto.
- ▶ **Todo lo de hoy es exactamente lo que el primer EDA del proyecto debe mostrar (entrega: lunes 15).**

Próxima clase

- ▶ **Jueves 3 de septiembre: presentaciones breves de las ideas de proyecto (5 minutos por equipo, sin nota).**
- ▶ Después: fundamentos de probabilidad, la base para la inferencia de las clases siguientes.
- ▶ Se publica la rúbrica del primer análisis exploratorio.
- ▶ Recuerden: la formulación se entrega el lunes 7 por el aula virtual.

Referencias

Anscombe, F. J. (1973). Graphs in Statistical Analysis. The American Statistician, 27(1), 17-21.

Spearman, C. (1904). The Proof and Measurement of Association between Two Things. The American Journal of Psychology, 15(1), 72-101.

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo 4 (Matplotlib).

Datos: Encuesta Origen Destino Santiago 2012 (Sectra) e iris (Fisher, 1936).