

# Introducción y fundamentos estadísticos

## Clase 3 · Análisis exploratorio de datos II

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 1 de septiembre, 2026



UNIVERSIDAD TECNICA  
FEDERICO SANTA MARIA

DEPARTAMENTO  
DE INFORMÁTICA

# Contenidos de la clase

- ▶ 1. Relaciones entre pares de variables.
- ▶ 2. Correlación: Pearson y Spearman.
- ▶ 3. La EOD: distancia y duración de los viajes.
- ▶ 4. Grupos y tablas de contingencia.
- ▶ 5. La primera regresión.
- ▶ 6. Buenas prácticas de visualización.

# Avisos del proyecto Capstone

- ▶ **Inscriban su grupo en la planilla compartida (correo de ayer).**
- ▶ Jueves 3: presentación breve de la idea de cada equipo, alrededor de 5 minutos, sin nota. El enunciado y la rúbrica están publicados.
- ▶ Lunes 7: entrega de la formulación (30%).
- ▶ Lo de hoy alimenta directo el primer análisis exploratorio, que se entrega el lunes 15.


# El norte: los modelos

- ▶ **El diplomado apunta a construir modelos; la clase de hoy es su antesala directa.**
- ▶ La correlación dice qué variables prometen como predictoras; la matriz ayuda a elegirirlas y a descartar redundantes.
- ▶ Crear variables nuevas desde las existentes, como los resúmenes por comuna, es el feature engineering: la materia prima de los modelos.
- ▶ La regresión de hoy ya ES un modelo: el primero del diplomado.
- ▶ Sus residuos son el primer diagnóstico; la validación formal (hipótesis, valor  $p$ ) llega en la clase 5.

# Relaciones entre variables


De describir una variable a cruzar dos

# Tres tipos de pares, tres herramientas



El análisis bivariado depende del tipo de cada variable (clase 1): el par define qué gráfico y qué resumen corresponden.

# El gráfico de dispersión



Cada punto es una flor; los ejes son dos de sus medidas. La nube sube junta: pétalos más largos vienen con pétalos más anchos.

# Correlación

Un número para la relación entre dos variables



# El coeficiente de correlación de Pearson

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}}$$


Cada punto aporta el producto de sus dos desviaciones respecto de la media: positivo si x e y se desvían para el mismo lado, negativo si se desvían al revés.

El denominador lo normaliza: r queda siempre entre -1 y 1, sin unidades.

$x_i, y_i$ : los valores del caso  $i$  ·  $\bar{x}, \bar{y}$ : sus medias · la suma recorre los  $n$  casos


Mide la fuerza y el signo de la relación lineal entre dos variables cuantitativas.

# La fórmula, dibujada



Las medias parten el plano en cuatro cuadrantes: los puntos de los cuadrantes verdes empujan  $r$  hacia arriba y los de los rojos, hacia abajo. En iris casi todos los aportes son positivos:  $r = 0,96$ .

# La escala de r



$r = 1$  y  $r = -1$  son rectas perfectas;  $r = 0$ , ausencia de relación lineal. En datos reales, los valores intermedios son la norma.


# La correlación en Pandas

```
# Entre dos columnas
iris_df["petal length (cm)"].corr(iris_df["petal width (cm)"])

# Todas contra todas: la matriz de correlación
iris_df.drop(columns="species").corr()
```


- `corr()` usa Pearson por defecto. En iris, largo y ancho del pétalo correlacionan 0,96.

# La matriz de correlación



Todos los pares de una vez: diagonal en 1 y matriz simétrica. El 0,96 entre largo y ancho del pétalo dice que son casi redundantes: evidencia para decidir qué variables conservar en un proyecto.

# Siempre graficar: el cuarteto de Anscombe



Los cuatro conjuntos comparten medias, correlación y recta, y solo el primero es lo que el número sugiere. El resumen no reemplaza al gráfico.

# El impacto de una sola fila

El impacto de una sola fila sobre la correlación (nubes de ejemplo)

Sin el punto extremo:  $r = 0,21$



Con un solo punto extremo:  $r = 0,82$



Cuarenta puntos sin relación ( $r = 0,05$ ) y un solo punto extremo fabrican  $r = 0,72$ . La correlación de Pearson es tan sensible a los atípicos como la media.

# Cómo se calculan los rangos

Cinco comunas: rango = posición al ordenar cada variable

| Comuna      | Ingreso (M\$) | Duración (min) | Rango ing. | Rango dur. | d  | d <sup>2</sup> |
|-------------|---------------|----------------|------------|------------|----|----------------|
| Vitacura    | 1,66          | 27,0           | 5          | 2          | 3  | 9              |
| Providencia | 1,47          | 25,0           | 4          | 1          | 3  | 9              |
| Santiago    | 0,71          | 27,4           | 3          | 3          | 0  | 0              |
| Puente Alto | 0,66          | 40,3           | 2          | 5          | -3 | 9              |
| Cerro Navia | 0,46          | 36,0           | 1          | 4          | -3 | 9              |

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} = 1 - \frac{6 \cdot 36}{5(25 - 1)} = -0,80$$

Cada variable se ordena por separado y cada valor recibe su posición. En la fórmula:  $d_i$  es la diferencia de rangos de la comuna  $i$ , y  $n$  el número de casos. Cinco comunas bastan para calcular un Spearman a mano.



# Los rangos en Pandas: rank()



```
# rank() ordena la columna y asigna posiciones: 1 el menor
cinco["rango_ingreso"] = cinco["ingreso"].rank()
cinco["rango_duracion"] = cinco["duracion"].rank()

cinco[["Comuna", "rango_ingreso", "rango_duracion"]]
```

- Con los rangos listos, Spearman es el Pearson de esas dos columnas nuevas: `corr(method="spearman")` hace todo el proceso de una vez.


# Spearman: la correlación de los rangos

Spearman: reemplazar cada valor por su posición en el orden (nube de ejemplo)



Reemplazar cada valor por su posición en el orden endereza las curvas monótonas y desarma los atípicos. En Pandas: `corr(method="spearman")`. En la EOD, distancia y duración dan 0,57 con Pearson y 0,76 con Spearman: la diferencia delata curvatura y atípicos.

# Correlación no es causalidad



Que dos variables se muevan juntas no dice que una cause a la otra: puede haber una tercera moviendo a ambas. Con datos observacionales reportamos asociación (recuerden las preguntas reparadas de la clase 2).

# La EOD: ingreso y duración

¿Los que menos ganan viajan más tiempo?


# La tabla por comuna, ponderada

```
lab["w_ingreso"] = lab["Factor"] * lab["IngresoHogar"]
suma = lab.groupby("Comuna").sum()

# La media ponderada de la clase 2, ahora por comuna
suma["w_ingreso"] / suma["Factor"]
```


- Las conclusiones son sobre la ciudad, así que se pondera (clase 2): cada media por comuna es suma de  $w$  por  $x$ , dividida por suma de  $w$ , con el factor del día laboral

# Ingreso y duración, por comuna



Cada punto es una comuna (medias ponderadas por factor). La asociación es negativa ( $r = -0,34$ ): las comunas de menor ingreso promedian viajes más largos. Providencia, 25 minutos; Puente Alto, 40.

# La matriz de las comunas



Cuatro variables, seis pares (todo ponderado): el ingreso compra autos (0,94), y la sorpresa es que el mejor acompañante de la duración no es el ingreso (-0,34) sino las personas por hogar (0,65).


# Grupos y tablas de contingencia

Cuando una de las dos variables es categórica



# groupby: partir, aplicar, juntar

`groupby("species")["petal length"].mean():` partir, aplicar, juntar



La versión numérica del boxplot por grupo: la tabla se parte por categoría, cada parte recibe el resumen y los resultados se juntan.

# La media por grupo: groupby

```
iris_df.groupby("species")["petal length (cm)"].mean()  
  
# El mismo resumen que construimos a mano con loc y el for,  
# ahora en una línea
```

- ▶ groupby parte la tabla por categoría, aplica el resumen a cada parte y junta los resultados: 1,46 / 4,26 / 5,55 cm. Es la versión numérica del boxplot por grupo.

# Dos categóricas: la tabla de contingencia


```
pd.crosstab(datos["Sexo"], datos["ModoAgrupado"],  
            normalize="index")  
# Para la ciudad: sumar factores en vez de contar viajes  
datos.pivot_table(values="Factor", index="Sexo",  
                  columns="ModoAgrupado", aggfunc="sum")
```

- Ponderado por factor, en día laboral: las mujeres caminan más (40% contra 27%) y los hombres usan más el auto (28% contra 19%).

# La primera regresión

El primer modelo del diplomado

# Mínimos cuadrados



$$\hat{y} = a + bx$$

Mínimos cuadrados: la recta que hace mínima la suma de los errores al cuadrado.

$$b = r \frac{s_y}{s_x} \text{ y la recta pasa por } (\bar{x}, \bar{y})$$

$\hat{y}$ : el valor predicho ·  $b$ : pendiente ·  $a$ : intercepto  
 $r$ : la correlación ·  $s_x, s_y$ : las desviaciones estándar

La correlación mide la asociación; la regresión la dibuja: la recta que deja la menor suma de errores al cuadrado. La pendiente dice cuánto cambia y por cada unidad de  $x$ . Hoy es un primer contacto; en las clases 6 y 7 la profundizamos.

# Las fórmulas de la recta


Mínimos cuadrados (OLS): la recta que minimiza la suma de los errores al cuadrado

$$b = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} \quad a = \bar{y} - b\bar{x}$$

$b$ : la pendiente ·  $a$ : el intercepto ·  $x_i, y_i$ : los valores del caso  $i$  ·  $\bar{x}, \bar{y}$ : sus medias


El método se llama mínimos cuadrados ordinarios (OLS): `np.polyfit` implementa exactamente esta fórmula. En las clases 6 y 7 lo harán `scikit-learn` y `statsmodels`, con diagnósticos e inferencia.

# Pendiente e intercepto, dibujados



El intercepto es donde la recta corta el eje: el valor de  $y$  cuando  $x$  es 0. La pendiente es cuánto sube  $y$  por cada unidad de  $x$ . En nuestra recta: 38,3 minutos de base y -4,8 por cada millón de ingreso.

# La recta: ingreso y duración



$\text{duración} = 38,3 - 4,8 \cdot \text{ingreso}$  (ponderada por factor): por cada millón adicional, la duración media baja casi 5 minutos. Y  $r^2 = 0,12$ : la recta captura el 12% de la variación; la asociación es real pero moderada, y así se reporta.



# La recta en NumPy

```
pendiente, intercepto = np.polyfit(por_comuna["ingreso"],  
                                   por_comuna["duracion"], 1)  
  
# La recta evaluada, para dibujarla sobre el scatter  
ax.plot(x, intercepto + pendiente * x)
```

- polyfit ajusta un polinomio por mínimos cuadrados; el 1 pide grado 1, una recta. En las clases 6 y 7 usaremos herramientas con más diagnósticos.

# Usar la recta: predecir y medir residuos

```
prediccion = intercepto + pendiente * ingreso  
residuo = duracion - prediccion  
  
# ¿Qué comunas viajan más de lo que su ingreso predice?  
por_comuna.nlargest(5, "residuo")
```

- La Pintana viaja 13 minutos más de lo predicho y Santiago 7 menos: el residuo revela periferia y centralidad. ¿Azar? La clase 5 responde.

# El impacto de sacar una fila

```
sin_lb = por_comuna[por_comuna["Comuna"] != "LO BARNECHEA"]  
  
# Todo se recalcula sin la fila, y se compara  
sin_lb["ingreso"].corr(sin_lb["duracion"])  
np.polyfit(sin_lb["ingreso"] / 1e6, sin_lb["duracion"], 1)
```

- Sacar 1 comuna de 45 no mueve  $r$  (-0,34) pero cambia la pendiente en un quinto (-4,8 a -5,8): el impacto se mide con y sin, sobre todos los resúmenes en uso.

# Las fórmulas, con factor de expansión

Con factores de expansión, cada término se pesa por su  $w_i$

$$b_w = \frac{\sum_i w_i (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_i w_i (x_i - \bar{x}_w)^2} \quad a_w = \bar{y}_w - b_w \bar{x}_w$$

$w_i$ : el factor de expansión de la fila  $i$  ·  $\bar{x}_w, \bar{y}_w$ : las medias ponderadas

La misma recta de mínimos cuadrados, con cada término pesado por su factor: es la que usa el modelo que sigue, y en statsmodels se llama WLS (weighted least squares).

# Otro modelo: la motorización del hogar

```
x = h["IngresoHogar"] / 1e6
y, w = h["NumVeh"], h["Factor"]

# La fórmula de la pendiente ponderada, tal cual
b = (w*(x - xw)*(y - yw)).sum() / (w*(x - xw)**2).sum()
```

- 18.264 hogares reales, ponderados por su factor: vehículos =  $0,20 + 0,50 \cdot$  ingreso. Medio vehículo más por cada millón.

# Sacar atípicos de la variable a predecir

```
q1, q3 = h["NumVeh"].quantile([0.25, 0.75])
sin_atipicos = h[h["NumVeh"] <= q3 + 1.5 * (q3 - q1)]


# El mismo modelo, sin los hogares de 3 autos o más
np.polyfit(sin_atipicos["IngresoHogar"] / 1e6,
sin_atipicos["NumVeh"], 1)
```

- Sacar 236 hogares aplanar la pendiente ponderada (0,50 a 0,44): no eran errores, eran la señal. Los atípicos de  $y$  se investigan; se eliminan solo por dominio.

# Buenas prácticas de visualización

Que el gráfico diga la verdad y se entienda


# Graficar 90 mil puntos: overplotting



Con todos los puntos sólidos, el scatter se satura y miente. Los remedios: transparencia (alpha), muestreo, o hexbin, donde el color cuenta los viajes (la distancia viene en la tabla DistanciaViaje.csv; sus -1 son faltantes disfrazados).




# Cuándo usar escala logarítmica



Con colas largas como el ingreso, la escala lineal aplasta el 99% de los datos contra el borde; la logarítmica reparte el espacio y la forma aparece.

# El mismo gráfico, dos veces



Los mismos 30 mil viajes: sin rotular y saturado, contra rotulado, con transparencia y con el hallazgo en el título.

# Checklist del buen gráfico

- ▶ Título que diga el hallazgo, no solo las variables.
- ▶ Ejes con nombre y unidad; ejes que parten de cero en gráficos de barras.
- ▶ Muchos puntos: alpha, muestreo o hexbin.
- ▶ Colas largas: escala logarítmica o eje recortado, declarándolo.
- ▶ **El gráfico se corrige igual que el código: se itera hasta que un tercero lo entienda sin explicación oral.**

# Recreo

10 minutos

# Síntesis

- ▶ El análisis bivariado se elige según el par de tipos: scatter y correlación, groupby y boxplot, o tabla de contingencia.
- ▶ Pearson para relaciones lineales; Spearman cuando hay atípicos o curvas. Y siempre graficar: Anscombe.
- ▶ Correlación no es causalidad: reportamos asociación.
- ▶ La regresión es el primer modelo: una función que resume, predice y deja residuos que diagnostican.
- ▶ **Todo lo de hoy es exactamente lo que el primer EDA del proyecto debe mostrar (entrega: lunes 15).**

# Próxima clase

- ▶ **Jueves 3 de septiembre: presentaciones breves de las ideas de proyecto (5 minutos por equipo, sin nota).**
- ▶ Después: fundamentos de probabilidad, la base para la inferencia de las clases siguientes.
- ▶ Se publica la rúbrica del primer análisis exploratorio.
- ▶ Recuerden: la formulación se entrega el lunes 7 por el aula virtual.

# Referencias

Anscombe, F. J. (1973). Graphs in Statistical Analysis. The American Statistician, 27(1), 17-21.

Spearman, C. (1904). The Proof and Measurement of Association between Two Things. The American Journal of Psychology, 15(1), 72-101.

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo 4 (Matplotlib).

Datos: Encuesta Origen Destino Santiago 2012 (Sectra) e iris (Fisher, 1936).