

# Introducción y fundamentos estadísticos

**Clase 4 · Cierre del EDA y regresión múltiple**

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 3 de septiembre, 2026



UNIVERSIDAD TECNICA  
FEDERICO SANTA MARIA

DEPARTAMENTO  
DE INFORMÁTICA

# Avisos del proyecto Capstone

- ▶ **Hoy, en el segundo bloque: presentación de la idea de cada equipo, de 5 a 7 minutos, sin nota.**
- ▶ La formulación se entrega el lunes 7; el primer análisis exploratorio, el lunes 15.
- ▶ El enunciado y la rúbrica del primer análisis exploratorio ya están publicados en el repositorio.


# Contenidos de la clase

- ▶ 1. Visualización: muchos puntos y colas largas.
- ▶ 2. El impacto de sacar filas y atípicos.
- ▶ 3. La regresión ponderada (WLS).
- ▶ 4. Regresión múltiple: varias variables a la vez.
- ▶ 5. Presentaciones de las ideas de proyecto Capstone (segundo bloque).

# Visualización


Muchos puntos y colas largas

# Graficar 90 mil puntos: overplotting





Con todos los puntos sólidos, el scatter se satura y miente. Los remedios: transparencia (alpha), muestreo, o hexbin, donde el color cuenta los viajes (la distancia viene en la tabla DistanciaViaje.csv; sus -1 son faltantes disfrazados).

# Cuándo usar escala logarítmica



La misma distancia tiene cola larga: en lineal se aplasta; en log, la forma aparece. Y transformar con log es feature engineering clásico: vuelve lineales las relaciones multiplicativas.

# El mismo gráfico, dos veces



Los mismos 30 mil viajes: sin rotular y saturado, contra rotulado, con transparencia y con el hallazgo en el título.

# Checklist del buen gráfico

- ▶ Título adecuado: dice qué muestra el gráfico.
- ▶ Ejes con nombre y unidad; ejes que parten de cero en gráficos de barras.
- ▶ Muchos puntos: alpha, muestreo o hexbin.
- ▶ Colas largas: escala logarítmica o eje recortado, declarándolo.




# Lo pendiente de la clase 3

Del impacto de una fila a la regresión ponderada

# ¿Las comunas de mayor ingreso viajan menos tiempo?

El modelo inicial (clase 3): explicar la duración media del viaje por comuna con el ingreso medio del hogar, 45 comunas ponderadas. Recta:  $38,3 - 4,8 \cdot \text{ingreso}$

# El impacto de sacar una fila



# Las fórmulas, con factor de expansión

Con factores de expansión, cada término se pesa por su  $w_i$

$$b_w = \frac{\sum_i w_i (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_i w_i (x_i - \bar{x}_w)^2} \quad a_w = \bar{y}_w - b_w \bar{x}_w$$

$w_i$ : el factor de expansión de la fila  $i$  ·  $\bar{x}_w, \bar{y}_w$ : las medias ponderadas

La misma recta de mínimos cuadrados, con cada término pesado por su factor: es la que usa el modelo que sigue, y en statsmodels se llama WLS (weighted least squares).

# ¿Cuántos vehículos tiene un hogar según su ingreso?

Explicar los vehículos del hogar con el ingreso: 18.264 hogares, ponderados por su factor


# Otro modelo: la motorización del hogar

```
x = h["IngresoHogar"] / 1e6
y, w = h["NumVeh"], h["Factor"]

# La fórmula de la pendiente ponderada, tal cual
b = (w*(x - xw)*(y - yw)).sum() / (w*(x - xw)**2).sum()
```

- 18.264 hogares reales, ponderados por su factor: vehículos =  $0,20 + 0,50 \cdot$  ingreso. Medio vehículo más por cada millón.

# Los atípicos de la variable a predecir



El boxplot de NumVeh (clase 2): la cerca de Tukey queda en 2,5, y los hogares de 3 autos o más son atípicos. La siguiente diapo mide qué pasa al sacarlos.


# Sacar atípicos de la variable a predecir

```
q1, q3 = h["NumVeh"].quantile([0.25, 0.75])  
sin_atipicos = h[h["NumVeh"] <= q3 + 1.5 * (q3 - q1)] # = 2.5  
  
# El mismo modelo, sin los hogares de 3 autos o más  
np.polyfit(sin_atipicos["IngresoHogar"] / 1e6,  
sin_atipicos["NumVeh"], 1)
```

- Sin esos 236 hogares la pendiente baja de 0,50 a 0,44: eran la señal, no errores. Los atípicos se investigan y solo se eliminan por una razón del dominio.



# El impacto, dibujado: las dos rectas



Al perder los puntos dorados de arriba, la recta punteada gira hacia abajo: de 0,50 a 0,44 vehículos por millón. El modelo queda ciego justo a los hogares más motorizados, el fenómeno que quería capturar.

# Regresión múltiple

El primer modelo con varias variables

# La fórmula de la regresión múltiple

El mismo método de mínimos cuadrados, con varias variables a la vez

$$\hat{y} = a + b_1 x_1 + b_2 x_2 + \dots + b_k x_k$$


$\hat{y}$ : el valor predicho ·  $x_j$ : cada variable explicativa ·  $b_j$ : cambio de  $\hat{y}$  por unidad de  $x_j$ , con las demás constantes ·  $a$ : intercepto

Cada coeficiente aísla el efecto de su variable: cuánto cambia la predicción por una unidad de esa  $x$ , manteniendo las demás constantes.

# ¿Y si agregamos más variables al modelo de vehículos?

Explicar los vehículos con el ingreso y algo más: ¿qué candidatas trae la tabla de hogares, y cómo se elige? La primera regresión múltiple

# El mapa para elegir variables



La fila de NumVeh es el mapa: ingreso 0,47 es el motor; las personas (0,13) son la única candidata con algo; las bicicletas casi nada (0,06) y redundantes entre sí (0,83). Decisión: agregar las personas.

# La motorización, con dos variables

```
# Explicar los vehículos del hogar con el ingreso y las personas
X = sm.add_constant(pd.DataFrame({
    "ingreso": h["IngresoHogar"] / 1e6,
    "personas": h["NumPer"]}))
modelo = sm.WLS(h["NumVeh"], X, weights=h["Factor"]).fit()
```

- Ponderado: 0,48 vehículos por millón (era 0,50 a solas) y 0,03 por persona extra. El  $R^2$  sube apenas, de 0,261 a 0,266: agregar variables no siempre aporta.

# El summary: los coeficientes y el valor p

| los coeficientes |        |         |        | el valor p |        |        |
|------------------|--------|---------|--------|------------|--------|--------|
|                  | coef   | std err | t      | P> t       | [0.025 | 0.975] |
| const            | 0.1058 | 0.011   | 9.537  | 0.000      | 0.084  | 0.128  |
| ingreso          | 0.4839 | 0.006   | 75.243 | 0.000      | 0.471  | 0.496  |
| personas         | 0.0330 | 0.003   | 10.725 | 0.000      | 0.027  | 0.039  |

coef es el modelo ajustado: de ahí sale la ecuación que sigue.  $P>|t|$  responde, por variable: si en la ciudad el ingreso (o las personas) no tuviera efecto sobre los vehículos, ¿qué tan raro sería este coeficiente por azar de la muestra? Ambos dan 0,000.

# La ecuación ajustada y su lectura

El modelo ajustado, con los números de los 18.264 hogares

$$\widehat{\text{vehículos}} = 0,106 + 0,484 \cdot \text{ingreso} + 0,033 \cdot \text{personas}$$

0,484: vehículos extra por cada millón de ingreso, con las personas fijas

0,033: vehículos extra por cada persona del hogar, con el ingreso fijo

0,106: el punto de partida (intercepto), con ingreso 0 y hogar de 0 personas

La fórmula de la múltiple con nuestros números: cada coeficiente se lee con las demás variables fijas.



# Leer el modelo: $R^2$


Cuánta de la variabilidad de  $y$  explica el modelo

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

$y_i$ : lo observado ·  $\hat{y}_i$ : lo que predice el modelo ·  $\bar{y}$ : la media de  $y$  · 0 = no explica nada, 1 = predice exacto

Nuestro 0,266: ingreso y personas explican un cuarto de la variabilidad de los vehículos entre hogares. Agregar variables nunca baja el  $R^2$ ; por eso no basta con mirarlo.

# Los coeficientes al agregar variables




El ingreso apenas se mueve (0,50 a 0,48) al agregar personas y bicicletas: es un efecto robusto. Las variables nuevas entran con coeficientes minúsculos y el  $R^2$  casi no cambia.

# ¿De qué depende la duración de un viaje?

Lo que ya sabemos (clase 3): correlaciona con la distancia,  $r = 0,57$  y Spearman  $0,76$ . Primera decisión: partir por la distancia, 102 mil viajes de la EOD

# La misma regresión, tres veces




Decisión 1: transformar con log, porque las dos variables tienen cola larga y en log la nube se endereza:  $R^2$  de 0,32 a 0,53. Y queda claro que la distancia sola no basta.

# ¿Y si agregamos más variables?


Volvemos a la duración: la distancia explica el 53%. ¿Qué más podría explicarla, y cómo se decide?

# El mapa, también para la duración



Igual que en vehículos, primero el mapa. La distancia (en log) es el motor: 0,73. El ingreso da 0,00 por viaje: el -0,34 de la clase 3 era entre comunas, y un promedio esconde a los individuos. Al modo, que es texto, el mapa no lo ve.

# ¿Qué más podría explicar la duración?



Las categóricas se miran con groupby: el modo sí importa, Bip! 62 min contra 15 de caminata. Pero Bip! también va más lejos (7,5 km contra 0,4): hay que comparar a igual distancia.

## Decisión 2: agregar el modo

- ▶ **El modo es la candidata de mayor contraste y responde una pregunta de equidad: ¿cuánto más tarda un viaje según el modo, a igual distancia?**
- ▶ Comparar duraciones a secas mezcla el modo con la distancia; la regresión múltiple controla la distancia y aísla el modo.
- ▶ Como el modo es texto, no puede entrar tal cual a la fórmula: primero hay que convertirlo en números.
- ▶ El período del día es la otra candidata fuerte (punta mañana 60 min, fuera de punta 32): queda para el ejercicio.



# Una categórica, convertida en columnas 0/1

Antes: una columna de texto

Después: una columna 0/1 por modo (dummies)

`pd.get_dummies`

| Viaje      | ModoAgrupado (texto)    |
|------------|-------------------------|
| 1734510101 | Auto                    |
| 1734310202 | Bip! (solo o combinado) |
| 1734620301 | Caminata                |
| 1001800101 | Bicicleta               |
| 1735020302 | Taxi Colectivo          |
| 1734710101 | Taxi                    |
| 1734620501 | Otros                   |



| Auto<br>(referencia) | Bip!<br>(solo o comb.) | Caminata | Bicicleta | Taxi<br>Colectivo | Taxi | Otros |
|----------------------|------------------------|----------|-----------|-------------------|------|-------|
| 1                    | 0                      | 0        | 0         | 0                 | 0    | 0     |
| 0                    | 1                      | 0        | 0         | 0                 | 0    | 0     |
| 0                    | 0                      | 1        | 0         | 0                 | 0    | 0     |
| 0                    | 0                      | 0        | 1         | 0                 | 0    | 0     |
| 0                    | 0                      | 0        | 0         | 1                 | 0    | 0     |
| 0                    | 0                      | 0        | 0         | 0                 | 1    | 0     |
| 0                    | 0                      | 0        | 0         | 0                 | 0    | 1     |

Cada viaje tiene un solo 1, en la columna de su modo. El auto es la referencia: su columna se saca y un viaje en auto queda con todo en 0.

El modo es texto y la fórmula solo suma números: `pd.get_dummies` crea una columna por categoría. Cada viaje tiene un solo 1, en la de su modo; el auto se saca y queda de referencia.


# Las dummies, en código

```
# Una columna 0/1 por modo; el auto queda de referencia
dummies = pd.get_dummies(viajes["ModoAgrupado"])
dummies = dummies.drop(columns=["Auto"])

# Explicar la duración (log) con la distancia (log) y el modo
```

- Las dummies se agregan a la X junto al log de la distancia. Cada coeficiente se lee comparado con la referencia: ese modo frente al auto, a igual distancia.

# Qué hace una dummy dentro del modelo



La dummy suma su coeficiente al intercepto de su modo: rectas paralelas, con la misma pendiente en la distancia. En log, sumar 0,27 es multiplicar el tiempo por 1,87.

# El resultado: distancia y modo

$$\log_{10}(\text{duración}) \sim \log_{10}(\text{distancia}) + \text{modo} \cdot R^2 = 0,60$$

| Modo (vs. auto)         | Coeficiente | Tiempo, a igual distancia |
|-------------------------|-------------|---------------------------|
| Bip! (solo o combinado) | 0,27        | × 1,87                    |
| Otros                   | 0,20        | × 1,57                    |
| Taxi Colectivo          | 0,13        | × 1,35                    |
| Bicicleta               | 0,07        | × 1,16                    |
| Caminata                | 0,03        | × 1,08                    |
| Taxi                    | 0,01        | × 1,03                    |

A igual distancia, un viaje en Bip! tarda 1,87 veces lo que uno en auto; taxi y caminata quedan casi iguales al auto. El  $R^2$  sube de 0,53 a 0,60.

# La ecuación de la duración, leída

El modelo ajustado, sobre los 102 mil viajes


$$\log_{10}(\text{duración}) = 1,15 + 0,37 \cdot \log_{10}(\text{dist}) + 0,27 \cdot \text{Bip!} + \dots$$

en log, los efectos multiplican: distancia  $\times 10$  multiplica la duración por  $10^{0,37} \approx 2,3$   
cada dummy vale 1 solo en su modo: Bip! = 1 multiplica por  $10^{0,27} \approx 1,87$  frente al auto  
los puntos suspensivos son las demás dummies (caminata, taxi, bicicleta y otros)

La misma tabla de coeficientes, escrita como ecuación: en escala log los efectos multiplican en vez de sumar.

# Cómo se lee la dummy, con el logaritmo

La ecuación completa, y el mismo viaje de 5 km ( $\log_{10} 5 = 0,70$ ) en auto y en Bip!

$$\log_{10}(\text{dur}) = 1,15 + 0,37 \cdot \log_{10}(\text{dist}) + 0,07 \cdot \text{Bici} + 0,27 \cdot \text{Bip!} + 0,03 \cdot \text{Cam} + 0,20 \cdot \text{Otros} + 0,01 \cdot \text{Taxi} + 0,13 \cdot \text{Colect}$$

**En auto, todas las dummies valen 0:**

$$\log_{10}(\text{dur}) = 1,15 + 0,37 \cdot 0,70 + 0,07 \cdot 0 + 0,27 \cdot 0 + 0,03 \cdot 0 + 0,20 \cdot 0 + 0,01 \cdot 0 + 0,13 \cdot 0 = 1,41$$

$$\text{dur} = 10^{1,41} = \mathbf{25,6 \text{ min}}$$

**En Bip!, solo la dummy de Bip! vale 1:**

$$\log_{10}(\text{dur}) = 1,15 + 0,37 \cdot 0,70 + 0,07 \cdot 0 + 0,27 \cdot 1 + 0,03 \cdot 0 + 0,20 \cdot 0 + 0,01 \cdot 0 + 0,13 \cdot 0 = 1,68$$

$$\text{dur} = 10^{1,68} = \mathbf{47,8 \text{ min}}$$

$$\mathbf{47,8 / 25,6 = 1,87 = 10^{0,27}: \text{ sumar 0,27 en log es multiplicar el tiempo por 1,87}}$$

La dummy suma 0,27 al log de la duración, y sumar en log es multiplicar: el mismo viaje de 5 km pasa de 26 a 48 minutos. Por eso el coeficiente se lee como  $\times 1,87$  frente al auto, a igual distancia.

# La regla para leer una dummy

- ▶ **La dummy vale 0 en la referencia (auto) y 1 en su modo: su coeficiente se suma solo cuando vale 1.**
- ▶ Con el modelo en log, ese coeficiente se suma al log de la duración, y sumar en log es multiplicar en la escala original: 10 elevado a 0,27 = 1,87.
- ▶ Lectura: cuántas veces más ( $\times 1,87$ ) frente a la referencia, a igual valor de las demás variables (aquí, la distancia).
- ▶ ¿Por qué dividir los dos tiempos y no restarlos? Porque restar en log es dividir en la escala original:  $\log(a) - \log(b) = \log(a/b)$ . La resta en minutos cambia con la distancia; la razón 1,87, no.
- ▶ Sin log, la lectura sería aditiva: tantos minutos más, a igual distancia.

# Síntesis

- ▶ Muchos puntos: alpha o hexbin. Colas largas: log.
- ▶ El impacto de filas y atípicos se mide con y sin, sobre todos los resúmenes en uso.
- ▶ Cuando la conclusión es sobre la ciudad, se pondera: WLS.
- ▶ La múltiple aísla el efecto de cada variable (categóricas como dummies);  $R^2$  dice cuánto explica y el valor p si un coeficiente se distingue del azar.
- ▶ **El primer EDA del proyecto usa exactamente estas herramientas (entrega: lunes 15).**



# Recreo

10 minutos · al volver: las presentaciones de ideas

# Presentaciones de ideas

De 5 a 7 minutos por equipo, y preguntas de todos

# El formato

- ▶ **Esta instancia no lleva nota: es para recibir retroalimentación temprano, cuando corregir cuesta poco.**
- ▶ Después de cada equipo, preguntas y comentarios del curso.

# Próxima clase

- ▶ Martes 8: fundamentos de probabilidad y nociones de inferencia estadística.
- ▶ La pregunta pendiente desde la clase 3: ¿qué significa el valor  $p$  que statsmodels ya nos mostró?
- ▶ **La formulación se entrega el lunes 7; el primer análisis exploratorio, el lunes 15.**

# Referencias

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

Seabold, S. y Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. Proceedings of the 9th Python in Science Conference.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo 5 (regresión lineal).

Datos: Encuesta Origen Destino Santiago 2012 (Sectra).