

Introducción y fundamentos estadísticos

Clase 4 · Cierre del EDA y regresión múltiple

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 3 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Avisos del proyecto Capstone

- ▶ **Hoy, en el segundo bloque: presentación de la idea de cada equipo, de 5 a 7 minutos, sin nota.**
- ▶ La formulación se entrega el lunes 7; el primer análisis exploratorio, el martes 15.
- ▶ El enunciado y la rúbrica del primer análisis exploratorio ya están publicados en el repositorio.


Contenidos de la clase

- ▶ 1. Visualización: muchos puntos y colas largas.
- ▶ 2. El impacto de sacar filas y atípicos.
- ▶ 3. La regresión ponderada (WLS).
- ▶ 4. Regresión múltiple: varias variables a la vez.
- ▶ 5. Presentaciones de las ideas de proyecto Capstone (segundo bloque).

Visualización


Muchos puntos y colas largas

Graficar 90 mil puntos: overplotting



Con todos los puntos sólidos, el scatter se satura y miente. Los remedios: transparencia (alpha), muestreo, o hexbin, donde el color cuenta los viajes (la distancia viene en la tabla DistanciaViaje.csv; sus -1 son faltantes disfrazados).


Cuándo usar escala logarítmica




La misma distancia tiene cola larga: en lineal se aplasta; en log, la forma aparece. Y transformar con log es feature engineering clásico: vuelve lineales las relaciones multiplicativas.

El mismo gráfico, dos veces

Sin títulos, sin unidades, saturado



A más distancia, más duración
(30 mil viajes, EOD 2012)



Los mismos 30 mil viajes: sin rotular y saturado, contra rotulado, con transparencia y con el hallazgo en el título.

Checklist del buen gráfico

- ▶ Título adecuado: dice qué muestra el gráfico.
- ▶ Ejes con nombre y unidad; ejes que parten de cero en gráficos de barras.
- ▶ Muchos puntos: alpha, muestreo o hexbin.
- ▶ Colas largas: escala logarítmica o eje recortado, declarándolo.


Lo pendiente de la clase 3

Del impacto de una fila a la regresión ponderada

¿Las comunas de mayor ingreso viajan menos tiempo?

El modelo inicial (clase 3): explicar la duración media del viaje por comuna con el ingreso medio del hogar, 45 comunas ponderadas. Recta: $38,3 - 4,8 \cdot \text{ingreso}$

El impacto de sacar una fila



Medirlo es recalcular con y sin: r casi no se mueve ($-0,34$), pero la pendiente cambia en un quinto, de $-4,8$ a $-5,8$ minutos por millón. Cada resumen tiene su propia sensibilidad.

Las fórmulas, con factor de expansión

Con factores de expansión, cada término se pesa por su w_i

$$b_w = \frac{\sum_i w_i (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_i w_i (x_i - \bar{x}_w)^2} \quad a_w = \bar{y}_w - b_w \bar{x}_w$$

w_i : el factor de expansión de la fila i · $\bar{x}_w, \bar{y}_w$: las medias ponderadas

La misma recta de mínimos cuadrados, con cada término pesado por su factor: es la que usa el modelo que sigue, y en statsmodels se llama WLS (weighted least squares).

¿Cuántos vehículos tiene un hogar según su ingreso?

Explicar los vehículos del hogar con el ingreso: 18.264 hogares, ponderados por su factor


Otro modelo: la motorización del hogar

```
x = h["IngresoHogar"] / 1e6
y, w = h["NumVeh"], h["Factor"]

# La fórmula de la pendiente ponderada, tal cual
b = (w*(x - xw)*(y - yw)).sum() / (w*(x - xw)**2).sum()
```

- 18.264 hogares reales, ponderados por su factor: vehículos = $0,20 + 0,50 \cdot$ ingreso. Medio vehículo más por cada millón.

Los atípicos de la variable a predecir




El boxplot de NumVeh (clase 2): la cerca de Tukey queda en 2,5, y los hogares de 3 autos o más son atípicos. La siguiente diapo mide qué pasa al sacarlos.

Sacar atípicos de la variable a predecir

```
q1, q3 = h["NumVeh"].quantile([0.25, 0.75])  
sin_atipicos = h[h["NumVeh"] <= q3 + 1.5 * (q3 - q1)] # = 2.5  
  
# El mismo modelo, sin los hogares de 3 autos o más  
np.polyfit(sin_atipicos["IngresoHogar"] / 1e6,  
sin_atipicos["NumVeh"], 1)
```

- Sin esos 236 hogares la pendiente baja de 0,50 a 0,44: eran la señal, no errores. Los atípicos se investigan y solo se eliminan por una razón del dominio.

El impacto, dibujado: las dos rectas



Al perder los puntos dorados de arriba, la recta punteada gira hacia abajo: de 0,50 a 0,44 vehículos por millón. El modelo queda ciego justo a los hogares más motorizados, el fenómeno que quería capturar.

Regresión múltiple

El primer modelo con varias variables

La fórmula de la regresión múltiple

El mismo método de mínimos cuadrados, con varias variables a la vez

$$\hat{y} = a + b_1 x_1 + b_2 x_2 + \dots + b_k x_k$$


$\hat{y}$: el valor predicho · x_j : cada variable explicativa · b_j : cambio de $\hat{y}$ por unidad de x_j , con las demás constantes · a : intercepto

Cada coeficiente aísla el efecto de su variable: cuánto cambia la predicción por una unidad de esa x , manteniendo las demás constantes.

¿Y si agregamos más variables al modelo de vehículos?

Explicar los vehículos con el ingreso y algo más: ¿qué candidatas trae la tabla de hogares, y cómo se elige? La primera regresión múltiple

El mapa para elegir variables



La fila de NumVeh es el mapa: ingreso 0,47 es el motor; las personas (0,13) son la única candidata con algo; las bicicletas casi nada (0,06) y redundantes entre sí (0,83). Decisión: agregar las personas.

La motorización, con dos variables

```
# Explicar los vehículos del hogar con el ingreso y las personas
X = sm.add_constant(pd.DataFrame({
    "ingreso": h["IngresoHogar"] / 1e6,
    "personas": h["NumPer"]}))
modelo = sm.WLS(h["NumVeh"], X, weights=h["Factor"]).fit()
```

- Ponderado: 0,48 vehículos por millón (era 0,50 a solas) y 0,03 por persona extra. El R^2 sube apenas, de 0,261 a 0,266: agregar variables no siempre aporta.

El summary: los coeficientes y el valor p

los coeficientes				el valor p		
	coef	std err	t	P> t	[0.025	0.975]
const	0.1058	0.011	9.537	0.000	0.084	0.128
ingreso	0.4839	0.006	75.243	0.000	0.471	0.496
personas	0.0330	0.003	10.725	0.000	0.027	0.039

coef es el modelo ajustado: de ahí sale la ecuación que sigue. $P>|t|$ responde, por variable: si en la ciudad el ingreso (o las personas) no tuviera efecto sobre los vehículos, ¿qué tan raro sería este coeficiente por azar de la muestra? Ambos dan 0,000.

La ecuación ajustada y su lectura

El modelo ajustado, con los números de los 18.264 hogares

$$\widehat{\text{vehículos}} = 0,106 + 0,484 \cdot \text{ingreso} + 0,033 \cdot \text{personas}$$

0,484: vehículos extra por cada millón de ingreso, con las personas fijas

0,033: vehículos extra por cada persona del hogar, con el ingreso fijo

0,106: el punto de partida (intercepto), con ingreso 0 y hogar de 0 personas

La fórmula de la múltiple con nuestros números: cada coeficiente se lee con las demás variables fijas.

Leer el modelo: R^2


Cuánta de la variabilidad de y explica el modelo

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

y_i : lo observado · $\hat{y}_i$: lo que predice el modelo · $\bar{y}$: la media de y · 0 = no explica nada, 1 = predice exacto

Nuestro 0,266: ingreso y personas explican un cuarto de la variabilidad de los vehículos entre hogares. Agregar variables nunca baja el R^2 ; por eso no basta con mirarlo.

Los coeficientes al agregar variables




El ingreso apenas se mueve (0,50 a 0,48) al agregar personas y bicicletas: es un efecto robusto. Las variables nuevas entran con coeficientes minúsculos y el R^2 casi no cambia.

¿De qué depende la duración de un viaje?

Lo que ya sabemos (clase 3): correlaciona con la distancia, $r = 0,57$ y Spearman $0,76$. Primera decisión: partir por la distancia, 102 mil viajes de la EOD

La misma regresión, tres veces




Decisión 1: transformar con log, porque las dos variables tienen cola larga y en log la nube se endereza: R^2 de 0,32 a 0,53. Y queda claro que la distancia sola no basta.

¿Y si agregamos más variables?

Volvemos a la duración: la distancia explica el 53%. ¿Qué más podría explicarla, y cómo se decide?


El mapa, también para la duración



Igual que en vehículos, primero el mapa. La distancia (en log) es el motor: 0,73. El ingreso da 0,00 por viaje: el -0,34 de la clase 3 era entre comunas, y un promedio esconde a los individuos. Al modo, que es texto, el mapa no lo ve.

¿Qué más podría explicar la duración?

Por modo: los viajes en Bip! tardan más, y también van más lejos



Las categóricas se miran con groupby: el modo sí importa, Bip! 62 min contra 15 de caminata. Pero Bip! también va más lejos (7,5 km contra 0,4): hay que comparar a igual distancia.

Decisión 2: agregar el modo

- ▶ **El modo es la candidata de mayor contraste y responde una pregunta de equidad: ¿cuánto más tarda un viaje según el modo, a igual distancia?**
- ▶ Comparar duraciones a secas mezcla el modo con la distancia; la regresión múltiple controla la distancia y aísla el modo.
- ▶ Como el modo es texto, no puede entrar tal cual a la fórmula: primero hay que convertirlo en números.
- ▶ El período del día es la otra candidata fuerte (punta mañana 60 min, fuera de punta 32): queda para el ejercicio.

Una categórica, convertida en columnas 0/1

Antes: una columna de texto

Después: una columna 0/1 por modo (dummies)

```
pd.get_dummies
```

Viaje	ModoAgrupado (texto)
1734510101	Auto
1734310202	Bip! (solo o combinado)
1734620301	Caminata
1001800101	Bicicleta
1735020302	Taxi Colectivo
1734710101	Taxi
1734620501	Otros



Auto (referencia)	Bip! (solo o comb.)	Caminata	Bicicleta	Taxi Colectivo	Taxi	Otros
1	0	0	0	0	0	0
0	1	0	0	0	0	0
0	0	1	0	0	0	0
0	0	0	1	0	0	0
0	0	0	0	1	0	0
0	0	0	0	0	1	0
0	0	0	0	0	0	1

Cada viaje tiene un solo 1, en la columna de su modo. El auto es la referencia: su columna se saca y un viaje en auto queda con todo en 0.

El modo es texto y la fórmula solo suma números: `pd.get_dummies` crea una columna por categoría. Cada viaje tiene un solo 1, en la de su modo; el auto se saca y queda de referencia.

Las dummies, en código

```
# Una columna 0/1 por modo; el auto queda de referencia
dummies = pd.get_dummies(viajes["ModoAgrupado"])
dummies = dummies.drop(columns=["Auto"])

# Explicar la duración (log) con la distancia (log) y el modo
```

- Las dummies se agregan a la X junto al log de la distancia. Cada coeficiente se lee comparado con la referencia: ese modo frente al auto, a igual distancia.

La ecuación de la duración, leída

El modelo ajustado, sobre los 102 mil viajes


$$\log_{10}(\text{duración}) = 1,15 + 0,37 \cdot \log_{10}(\text{dist}) + 0,27 \cdot \text{Bip!} + \dots$$

1,15: el intercepto, la referencia (un viaje en auto)

0,37: el coeficiente de la distancia (en log), el mismo para todos los modos

0,27 · Bip!: la dummy de Bip!, que vale 1 solo si el viaje es en Bip! y 0 si no

los puntos suspensivos son las dummies de los demás modos, cada una con su coeficiente

El modelo ajustado como ecuación: la distancia con su coeficiente y una dummy por modo con el suyo; el auto es la referencia y no lleva término. La tabla completa de coeficientes viene en la próxima diapo.

El resultado: distancia y modo

$$\log_{10}(\text{duración}) \sim \log_{10}(\text{distancia}) + \text{modo} \cdot R^2 = 0,60$$

Modo (vs. auto)	Coeficiente	Tiempo, a igual distancia
Bip! (solo o combinado)	0,27	× 1,87
Otros	0,20	× 1,57
Taxi Colectivo	0,13	× 1,35
Bicicleta	0,07	× 1,16
Caminata	0,03	× 1,08
Taxi	0,01	× 1,03

A igual distancia, un viaje en Bip! tarda 1,87 veces lo que uno en auto; taxi y caminata quedan casi iguales al auto. El R^2 sube de 0,53 a 0,60.

Cómo se lee la dummy, con el logaritmo

La ecuación completa, y el mismo viaje de 5 km ($\log_{10} 5 = 0,70$) en auto y en Bip!

$$\log_{10}(\text{dur}) = 1,15 + 0,37 \cdot \log_{10}(\text{dist}) + 0,07 \cdot \text{Bici} + 0,27 \cdot \text{Bip!} + 0,03 \cdot \text{Cam} + 0,20 \cdot \text{Otros} + 0,01 \cdot \text{Taxi} + 0,13 \cdot \text{Colect}$$

En auto, todas las dummies valen 0:

$$\log_{10}(\text{dur}) = 1,15 + 0,37 \cdot 0,70 + 0,07 \cdot 0 + 0,27 \cdot 0 + 0,03 \cdot 0 + 0,20 \cdot 0 + 0,01 \cdot 0 + 0,13 \cdot 0 = 1,41$$

$$\text{dur} = 10^{1,41} = \mathbf{25,6 \text{ min}}$$

En Bip!, solo la dummy de Bip! vale 1:

$$\log_{10}(\text{dur}) = 1,15 + 0,37 \cdot 0,70 + 0,07 \cdot 0 + 0,27 \cdot 1 + 0,03 \cdot 0 + 0,20 \cdot 0 + 0,01 \cdot 0 + 0,13 \cdot 0 = 1,68$$

$$\text{dur} = 10^{1,68} = \mathbf{47,8 \text{ min}}$$

$47,8 / 25,6 = 1,87 = 10^{0,27}$: sumar 0,27 en log es multiplicar el tiempo por 1,87

La regla para leer una dummy

- ▶ **El coeficiente de una dummy solo se considera si el viaje es en ese modo de transporte; si no, la dummy vale 0 y el término desaparece.**
- ▶ Como el modelo está en log, el coeficiente se suma al log, y sumar en log es multiplicar: $10 \text{ elevado a } 0,27 = 1,87$. Por eso los dos tiempos se dividen y no se restan.
- ▶ Lectura: un viaje en Bip! tarda 1,87 veces lo que uno en auto, a igual distancia.

Advertencia: el R^2 ajustado

R^2 ajustado = $1 - (1 - R^2) \cdot (n - 1) / (n - k - 1)$: descuenta cada variable extra

Modelo	n	k	R^2	R^2 ajustado
vehículos ~ ingreso	18.264	1	0,2613	0,2612
vehículos ~ ingreso + personas	18.264	2	0,2659	0,2658
vehículos ~ ingreso + personas + bicicletas	18.264	3	0,2672	0,2671
log duración ~ log distancia	102.223	1	0,5334	0,5334
log duración ~ log distancia + modo	102.223	7	0,6023	0,6023
el mismo 0,266 con pocos datos	30	3	0,2660	0,1813

El R^2 nunca baja al agregar variables; el ajustado descuenta cada una (en statsmodels, rsquared_adj). Con nuestros n es idéntico; con pocos datos, no. En sus proyectos, comparen modelos con el ajustado.

Síntesis

- ▶ Muchos puntos: alpha o hexbin. Colas largas: log.
- ▶ El impacto de filas y atípicos se mide con y sin, sobre todos los resúmenes en uso.
- ▶ Cuando la conclusión es sobre la ciudad, se pondera: WLS.
- ▶ La múltiple aísla el efecto de cada variable (categóricas como dummies); R^2 dice cuánto explica y el valor p si un coeficiente se distingue del azar.
- ▶ **El primer EDA del proyecto usa exactamente estas herramientas (entrega: martes 15).**

Recreo

10 minutos · al volver: las presentaciones de ideas

Presentaciones de ideas

De 5 a 7 minutos por equipo, y preguntas de todos

El formato

- ▶ **Esta instancia no lleva nota: es para recibir retroalimentación temprano, cuando corregir cuesta poco.**
- ▶ Después de cada equipo, preguntas y comentarios del curso.

Próxima clase

- ▶ Martes 8: fundamentos de probabilidad y nociones de inferencia estadística.
- ▶ La pregunta pendiente desde la clase 3: ¿qué significa el valor p que statsmodels ya nos mostró?
- ▶ **La formulación se entrega el lunes 7; el primer análisis exploratorio, el martes 15.**

Referencias

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

Seabold, S. y Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. Proceedings of the 9th Python in Science Conference.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo 5 (regresión lineal).

Datos: Encuesta Origen Destino Santiago 2012 (Sectra).