

Introducción y fundamentos estadísticos

Clase 4 · Cierre del EDA y regresión múltiple

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 3 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Contenidos de la clase

- ▶ 1. El impacto de sacar filas y atípicos.
- ▶ 2. La regresión ponderada (WLS).
- ▶ 3. Visualización: muchos puntos y colas largas.
- ▶ 4. Regresión múltiple: varias variables a la vez.
- ▶ 5. Presentaciones de las ideas de proyecto Capstone (segundo bloque).


Avisos del proyecto Capstone

- ▶ **Hoy, en el segundo bloque: presentación de la idea de cada equipo, de 5 a 7 minutos, sin nota.**
- ▶ La formulación se entrega el lunes 7; el primer análisis exploratorio, el lunes 15.
- ▶ El enunciado y la rúbrica del primer análisis exploratorio ya están publicados en el repositorio.

Lo pendiente de la clase 3

Del impacto de una fila a la regresión ponderada

El impacto de sacar una fila



Medirlo es recalcular con y sin: r casi no se mueve ($-0,34$), pero la pendiente cambia en un quinto, de $-4,8$ a $-5,8$ minutos por millón. Cada resumen tiene su propia sensibilidad.

Las fórmulas, con factor de expansión

Con factores de expansión, cada término se pesa por su w_i

$$b_w = \frac{\sum_i w_i (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_i w_i (x_i - \bar{x}_w)^2} \quad a_w = \bar{y}_w - b_w \bar{x}_w$$

w_i : el factor de expansión de la fila i · $\bar{x}_w, \bar{y}_w$: las medias ponderadas

La misma recta de mínimos cuadrados, con cada término pesado por su factor: es la que usa el modelo que sigue, y en statsmodels se llama WLS (weighted least squares).


Otro modelo: la motorización del hogar

```
x = h["IngresoHogar"] / 1e6
y, w = h["NumVeh"], h["Factor"]

# La fórmula de la pendiente ponderada, tal cual
b = (w*(x - xw)*(y - yw)).sum() / (w*(x - xw)**2).sum()
```

- 18.264 hogares reales, ponderados por su factor: vehículos = $0,20 + 0,50 \cdot$ ingreso. Medio vehículo más por cada millón.

Los atípicos de la variable a predecir



El boxplot de NumVeh (clase 2): la cerca de Tukey queda en 2,5, y los hogares de 3 autos o más son atípicos. La siguiente diapo mide qué pasa al sacarlos.

Sacar atípicos de la variable a predecir


```
q1, q3 = h["NumVeh"].quantile([0.25, 0.75])  
sin_atipicos = h[h["NumVeh"] <= q3 + 1.5 * (q3 - q1)] # = 2.5  
  
# El mismo modelo, sin los hogares de 3 autos o más  
np.polyfit(sin_atipicos["IngresoHogar"] / 1e6,  
sin_atipicos["NumVeh"], 1)
```

- Sacar 236 hogares aplanar la pendiente ponderada (0,50 a 0,44): no eran errores, eran la señal. Los atípicos de y se investigan; se eliminan solo por dominio.

Visualización


Muchos puntos y colas largas

Graficar 90 mil puntos: overplotting




Con todos los puntos sólidos, el scatter se satura y miente. Los remedios: transparencia (alpha), muestreo, o hexbin, donde el color cuenta los viajes (la distancia viene en la tabla DistanciaViaje.csv; sus -1 son faltantes disfrazados).

Cuándo usar escala logarítmica





La misma distancia tiene cola larga: en lineal se aplasta; en log, la forma aparece. Y transformar con log es feature engineering clásico: vuelve lineales las relaciones multiplicativas.

La misma regresión, tres veces



La transformación aplicada a duración ~ distancia: el log en ambos lados endereza la nube y el R^2 sube de 0,32 a 0,53. Y el modelo todavía pide más variables.

El mismo gráfico, dos veces



Los mismos 30 mil viajes: sin rotular y saturado, contra rotulado, con transparencia y con el hallazgo en el título.

Checklist del buen gráfico

- ▶ Título que diga el hallazgo, no solo las variables.
- ▶ Ejes con nombre y unidad; ejes que parten de cero en gráficos de barras.
- ▶ Muchos puntos: alpha, muestreo o hexbin.
- ▶ Colas largas: escala logarítmica o eje recortado, declarándolo.
- ▶ **El gráfico se corrige igual que el código: se itera hasta que un tercero lo entienda sin explicación oral.**

Regresión múltiple

El primer modelo con varias variables

La fórmula de la regresión múltiple

El mismo método de mínimos cuadrados, con varias variables a la vez

$$\hat{y} = a + b_1 x_1 + b_2 x_2 + \dots + b_k x_k$$

$\hat{y}$: el valor predicho · x_j : cada variable explicativa · b_j : cambio de $\hat{y}$ por unidad de x_j , con las demás constantes · a : intercepto

Cada coeficiente aísla el efecto de su variable: cuánto cambia la predicción por una unidad de esa x , manteniendo las demás constantes.

La motorización, con dos variables

```
# Explicar los vehículos del hogar con el ingreso y las personas
X = sm.add_constant(pd.DataFrame({
    "ingreso": h["IngresoHogar"] / 1e6,
    "personas": h["NumPer"]}))
modelo = sm.WLS(h["NumVeh"], X, weights=h["Factor"]).fit()
```

- Ponderado: 0,48 vehículos por millón (era 0,50 a solas) y 0,03 por persona extra. El R^2 sube apenas, de 0,261 a 0,266: agregar variables no siempre aporta.

La ecuación ajustada y su lectura

El modelo ajustado, con los números de los 18.264 hogares


$$\widehat{\text{vehículos}} = 0,106 + 0,484 \cdot \text{ingreso} + 0,033 \cdot \text{personas}$$

0,484: vehículos extra por cada millón de ingreso, con las personas fijas

0,033: vehículos extra por cada persona del hogar, con el ingreso fijo

0,106: el punto de partida (intercepto), con ingreso 0 y hogar de 0 personas

La fórmula de la múltiple con nuestros números: cada coeficiente se lee con las demás variables fijas.

Leer el modelo: R^2

Cuánta de la variabilidad de y explica el modelo

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

y_i : lo observado · $\hat{y}_i$: lo que predice el modelo · $\bar{y}$: la media de y · 0 = no explica nada, 1 = predice exacto

Nuestro 0,266: ingreso y personas explican un cuarto de la variabilidad de los vehículos entre hogares. Agregar variables nunca baja el R^2 ; por eso no basta con mirarlo.


El valor p: dónde vive

=====						
	coef	std err	t	el valor p P> t	[0.025	0.975]

const	0.1058	0.011	9.537	0.000	0.084	0.128
ingreso	0.4839	0.006	75.243	0.000	0.471	0.496
personas	0.0330	0.003	10.725	0.000	0.027	0.039
=====						

La pregunta que responde $P>|t|$: si el efecto real fuera cero, ¿qué tan raro sería este coeficiente por azar? Aquí ambos dan 0,000. Ojo: con n grande hasta lo minúsculo es significativo; la clase 5 lo formaliza.

El mapa para elegir variables



La fila de NumVeh es el mapa: ingreso 0,47 es el motor; las bicicletas casi no correlacionan con los vehículos (0,06) y son redundantes entre sí (0,83). Probarlas confirma: R^2 0,266 a 0,267.

Una categórica entra como dummies

```
# Una columna 0/1 por modo; el auto queda de referencia
dummies = pd.get_dummies(viajes["ModoAgrupado"])
dummies = dummies.drop(columns=["Auto"])

# Explicar la duración (log) con la distancia (log) y el modo
```

- Cada coeficiente se lee comparado con la referencia: qué le pasa al tiempo de un viaje por ser en ese modo y no en auto, a igual distancia.

El resultado: distancia y modo

$$\log_{10}(\text{duración}) \sim \log_{10}(\text{distancia}) + \text{modo} \cdot R^2 = 0,60$$

Modo (vs. auto)	Coeficiente	Tiempo, a igual distancia
Bip! (solo o combinado)	0,27	× 1,87
Otros	0,20	× 1,57
Taxi Colectivo	0,13	× 1,35
Bicicleta	0,07	× 1,16
Caminata	0,03	× 1,08
Taxi	0,01	× 1,03

A igual distancia, un viaje en Bip! tarda 1,87 veces lo que uno en auto; taxi y caminata quedan casi iguales al auto. El R^2 sube de 0,53 a 0,60.

La ecuación de la duración, leída

El modelo ajustado, sobre los 102 mil viajes


$$\log_{10}(\text{duración}) = 1,15 + 0,37 \cdot \log_{10}(\text{dist}) + 0,27 \cdot \text{Bip!} + \dots$$

en log, los efectos multiplican: distancia $\times 10$ multiplica la duración por $10^{0,37} \approx 2,3$
cada dummy vale 1 solo en su modo: Bip! = 1 multiplica por $10^{0,27} \approx 1,87$ frente al auto
los puntos suspensivos son las demás dummies (caminata, taxi, bicicleta y otros)

La misma tabla de coeficientes, escrita como ecuación: en escala log los efectos multiplican en vez de sumar.

Síntesis

- ▶ El impacto de filas y atípicos se mide con y sin, sobre todos los resúmenes en uso.
- ▶ Cuando la conclusión es sobre la ciudad, se pondera: WLS.
- ▶ Muchos puntos: alpha o hexbin. Colas largas: log.
- ▶ La múltiple aísla el efecto de cada variable (categóricas como dummies); R^2 dice cuánto explica y el valor p si un coeficiente se distingue del azar.
- ▶ **El primer EDA del proyecto usa exactamente estas herramientas (entrega: lunes 15).**

Recreo

10 minutos · al volver: las presentaciones de ideas

Presentaciones de ideas

De 5 a 7 minutos por equipo, y preguntas de todos

El formato

- ▶ **Esta instancia no lleva nota: es para recibir retroalimentación temprano, cuando corregir cuesta poco.**
- ▶ Después de cada equipo, preguntas y comentarios del curso.

Próxima clase

- ▶ Martes 8: fundamentos de probabilidad y nociones de inferencia estadística.
- ▶ La pregunta pendiente desde la clase 3: ¿qué significa el valor p que statsmodels ya nos mostró?
- ▶ **La formulación se entrega el lunes 7; el primer análisis exploratorio, el lunes 15.**

Referencias

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

Seabold, S. y Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. Proceedings of the 9th Python in Science Conference.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo 5 (regresión lineal).

Datos: Encuesta Origen Destino Santiago 2012 (Sectra).