

Introducción y fundamentos estadísticos

Clase 4 · Cierre del EDA y regresión múltiple

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 3 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Contenidos de la clase

- ▶ 1. Presentaciones de las ideas de proyecto Capstone.
- ▶ 2. El impacto de sacar filas y atípicos.
- ▶ 3. La regresión ponderada (WLS).
- ▶ 4. Visualización: muchos puntos y colas largas.
- ▶ 5. Regresión múltiple: varias variables a la vez.

Avisos del proyecto Capstone

- ▶ **Hoy: presentación de la idea de cada equipo, de 5 a 7 minutos, sin nota.**
- ▶ La formulación se entrega el lunes 7; el primer análisis exploratorio, el lunes 15.
- ▶ El enunciado y la rúbrica del primer análisis exploratorio ya están publicados en el repositorio.

Presentaciones de ideas

De 5 a 7 minutos por equipo, y preguntas de todos

El formato de hoy

- ▶ **Esta instancia no lleva nota: es para recibir retroalimentación temprano, cuando corregir cuesta poco.**
- ▶ Esquema sugerido: qué motiva el problema, el problema en sí, los datos y sus fuentes, y las primeras ideas.
- ▶ Después de cada equipo, preguntas y comentarios del curso.
- ▶ La pauta completa está en el repositorio, en evaluaciones.

Recreo

10 minutos · al volver: el cierre del EDA y la regresión múltiple

Lo pendiente de la clase 3

Del impacto de una fila a la regresión ponderada

El impacto de sacar una fila

- ▶ **Medirlo: recalculamos cada resumen sin la fila, y comparar.**
- ▶ Sin Lo Barnechea, r casi no se mueve (sigue en $-0,34$), pero la pendiente cambia en un quinto: de $-4,8$ a $-5,8$ minutos por millón.
- ▶ Un mismo punto puede pesar poco en un resumen y mucho en otro. El código está en el notebook.

Las fórmulas, con factor de expansión

Con factores de expansión, cada término se pesa por su w_i

$$b_w = \frac{\sum_i w_i (x_i - \bar{x}_w)(y_i - \bar{y}_w)}{\sum_i w_i (x_i - \bar{x}_w)^2} \quad a_w = \bar{y}_w - b_w \bar{x}_w$$

w_i : el factor de expansión de la fila i · $\bar{x}_w, \bar{y}_w$: las medias ponderadas

La misma recta de mínimos cuadrados, con cada término pesado por su factor: es la que usa el modelo que sigue, y en statsmodels se llama WLS (weighted least squares).


Otro modelo: la motorización del hogar

```
x = h["IngresoHogar"] / 1e6
y, w = h["NumVeh"], h["Factor"]

# La fórmula de la pendiente ponderada, tal cual
b = (w*(x - xw)*(y - yw)).sum() / (w*(x - xw)**2).sum()
```

- 18.264 hogares reales, ponderados por su factor: vehículos = $0,20 + 0,50 \cdot$ ingreso. Medio vehículo más por cada millón.

Los atípicos de la variable a predecir



El boxplot de NumVeh (clase 2): la cerca de Tukey queda en 2,5, y los hogares de 3 autos o más son atípicos. La siguiente diapo mide qué pasa al sacarlos.

Sacar atípicos de la variable a predecir

```
q1, q3 = h["NumVeh"].quantile([0.25, 0.75])
sin_atipicos = h[h["NumVeh"] <= q3 + 1.5 * (q3 - q1)]


# El mismo modelo, sin los hogares de 3 autos o más
np.polyfit(sin_atipicos["IngresoHogar"] / 1e6,
sin_atipicos["NumVeh"], 1)
```

- Sacar 236 hogares aplanar la pendiente ponderada (0,50 a 0,44): no eran errores, eran la señal. Los atípicos de y se investigan; se eliminan solo por dominio.

Visualización


Muchos puntos y colas largas

Graficar 90 mil puntos: overplotting




Con todos los puntos sólidos, el scatter se satura y miente. Los remedios: transparencia (alpha), muestreo, o hexbin, donde el color cuenta los viajes (la distancia viene en la tabla DistanciaViaje.csv; sus -1 son faltantes disfrazados).

Cuándo usar escala logarítmica





La misma distancia tiene cola larga: en lineal se aplasta; en log, la forma aparece. Y transformar con log es feature engineering clásico: vuelve lineales las relaciones multiplicativas.

La misma regresión, tres veces



La transformación aplicada a duración ~ distancia: el log en ambos lados endereza la nube y el R^2 sube de 0,32 a 0,53. Y el modelo todavía pide más variables.

El mismo gráfico, dos veces



Los mismos 30 mil viajes: sin rotular y saturado, contra rotulado, con transparencia y con el hallazgo en el título.

Checklist del buen gráfico

- ▶ Título que diga el hallazgo, no solo las variables.
- ▶ Ejes con nombre y unidad; ejes que parten de cero en gráficos de barras.
- ▶ Muchos puntos: alpha, muestreo o hexbin.
- ▶ Colas largas: escala logarítmica o eje recortado, declarándolo.
- ▶ **El gráfico se corrige igual que el código: se itera hasta que un tercero lo entienda sin explicación oral.**

Regresión múltiple

El primer modelo con varias variables

La fórmula de la regresión múltiple

El mismo método de mínimos cuadrados, con varias variables a la vez

$$\hat{y} = a + b_1 x_1 + b_2 x_2 + \dots + b_k x_k$$

$\hat{y}$: el valor predicho · x_j : cada variable explicativa · b_j : cambio de $\hat{y}$ por unidad de x_j , con las demás constantes · a : intercepto

Cada coeficiente aísla el efecto de su variable: cuánto cambia la predicción por una unidad de esa x , manteniendo las demás constantes.

La motorización, con dos variables

```
X = sm.add_constant(pd.DataFrame({  
    "ingreso": h["IngresoHogar"] / 1e6,  
    "personas": h["NumPer"]}))  
  
modelo = sm.WLS(h["NumVeh"], X, weights=h["Factor"]).fit()
```

- Ponderado: 0,48 vehículos por millón (era 0,50 a solas) y 0,03 por persona extra. El R^2 sube apenas, de 0,261 a 0,266: agregar variables no siempre aporta.

Leer el modelo: R^2

Cuánta de la variabilidad de y explica el modelo

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$


y_i : lo observado · $\hat{y}_i$: lo que predice el modelo · $\bar{y}$: la media de y · 0 = no explica nada, 1 = predice exacto

Nuestro 0,266: ingreso y personas explican un cuarto de la variabilidad de los vehículos entre hogares. Agregar variables nunca baja el R^2 ; por eso no basta con mirarlo.

El valor p, por ahora

- ▶ **La pregunta que responde: si el efecto real fuera cero, ¿qué tan raro sería este coeficiente solo por azar?**
- ▶ En el summary es la columna $P > |t|$: ingreso y personas dan p prácticamente 0, ninguna parece azar.
- ▶ Significativo no es sinónimo de importante: con 18 mil hogares, un aporte de 0,003 vehículos por bicicleta también da p diminuto.
- ▶ La definición formal, con hipótesis y umbrales, es la clase 5.

El mapa para elegir variables



La fila de NumVeh es el mapa: ingreso 0,47 es el motor; las bicicletas casi no correlacionan con los vehículos (0,06) y son redundantes entre sí (0,83). Probarlas confirma: R^2 0,266 a 0,267.

Una categórica entra como dummies

```
# Una columna 0/1 por modo; el auto queda de referencia
dummies = pd.get_dummies(viajes["ModoAgrupado"])
dummies = dummies.drop(columns=["Auto"])

# Se agregan a la X junto al log de la distancia
```

- Cada coeficiente se lee comparado con la referencia: qué le pasa al tiempo de un viaje por ser en ese modo y no en auto, a igual distancia.

El resultado: distancia y modo

$$\log_{10}(\text{duración}) \sim \log_{10}(\text{distancia}) + \text{modo} \cdot R^2 = 0,60$$

Modo (vs. auto)	Coeficiente	Tiempo, a igual distancia
Bip! (solo o combinado)	0,27	× 1,87
Otros	0,20	× 1,57
Taxi Colectivo	0,13	× 1,35
Bicicleta	0,07	× 1,16
Caminata	0,03	× 1,08
Taxi	0,01	× 1,03

A igual distancia, un viaje en Bip! tarda 1,87 veces lo que uno en auto; taxi y caminata quedan casi iguales al auto. El R^2 sube de 0,53 a 0,60.

Síntesis

- ▶ El impacto de filas y atípicos se mide con y sin, sobre todos los resúmenes en uso.
- ▶ Cuando la conclusión es sobre la ciudad, se pondera: WLS.
- ▶ Muchos puntos: alpha o hexbin. Colas largas: log, que además es feature engineering.
- ▶ La regresión múltiple aísla el efecto de cada variable con las demás constantes; las categóricas entran como dummies.
- ▶ R^2 dice cuánto explica el modelo; el valor p, si un coeficiente se distingue del azar. Significativo no es importante.
- ▶ **El primer EDA del proyecto usa exactamente estas herramientas**

Próxima clase

- ▶ Martes 8: fundamentos de probabilidad y nociones de inferencia estadística.
- ▶ La pregunta pendiente desde la clase 3: ¿qué significa el valor p que statsmodels ya nos mostró?
- ▶ **La formulación se entrega el lunes 7; el primer análisis exploratorio, el lunes 15.**

Referencias

Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.

Seabold, S. y Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. Proceedings of the 9th Python in Science Conference.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo 5 (regresión lineal).

Datos: Encuesta Origen Destino Santiago 2012 (Sectra).