

Introducción y fundamentos estadísticos

Clase 5 · Probabilidad e inferencia: ¿real o azar?

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 8 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Avisos del proyecto Capstone

- ▶ **El primer análisis exploratorio se entrega el lunes 15; el enunciado y la rúbrica están publicados en el repositorio.**
- ▶ La formulación entregada el lunes 7 se devuelve con comentarios durante la semana.
- ▶ Lo de hoy entra directo en el EDA: intervalos de confianza y la trampa de probar muchas variables.


Contenidos de la clase

- ▶ 1. El azar tiene forma: variables aleatorias y la normal.
- ▶ 2. Un número se mueve: distribución muestral y error estándar.
- ▶ 3. Primer uso del error estándar: el intervalo de confianza.
- ▶ 4. La pendiente también se mueve: bootstrap.
- ▶ 5. Segundo uso: la prueba de hipótesis, la t y el valor p . Qué supone.
- ▶ 6. La trampa de las comparaciones múltiples.
- ▶ 7. Otro modelo, el mismo lector: regresión logística para un sí o no.

¿Cuánto se movería este número con otra muestra?

La pregunta pendiente desde la clase 3: la pendiente de -4,8 minutos por millón, con 45 comunas y $p = 0,021$. ¿Real o azar? Hoy se responde


Descriptiva e inferencia



La descriptiva habla de la tabla que tenemos; la inferencia, de la población de la que salió, con su incertidumbre. Dos preguntas: cuánto vale, y si es real o azar.

1. El azar tiene forma


Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas



Después: qué supone la regresión, la trampa de probar de todo, y la logística para un sí o no

Probabilidad, el lenguaje de la incertidumbre: variables aleatorias y distribuciones



Una variable aleatoria y su distribución



La duración del próximo viaje depende del azar: es una variable aleatoria. Su distribución dice qué valores toma y con qué frecuencia: en la población, el histograma. La esperanza es su media.


La media también es una variable aleatoria

Dos variables aleatorias: la duración de un viaje, y la media de una muestra de 100 viajes




Depende de qué 100 viajes cayeron en la muestra: otra muestra, otra media. Y aunque la duración no tenga forma de campana, la media sí. Esa campana tiene nombre, y es la siguiente slide.

La distribución normal



La campana tiene dos parámetros: μ , la media, y σ , la desviación estándar. El 95% de los valores cae a menos de $1,96 \sigma$ de la media. Es la distribución de la inferencia porque los promedios la siguen; ese $1,96$ vuelve en los intervalos de confianza.


La duración no es normal; en log, casi



La cola larga (asimetría 5,3) se aleja de la normal; en log la variable se acomoda a la campana. Es la razón de fondo del log de la clase 4.

2. Un número se mueve


Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas



Después: qué supone la regresión, la trampa de probar de todo, y la logística para un sí o no


Muestra y población: una muestra es una de muchas posibles

Dos muestras, dos medias



Hoy tratamos los 113 mil viajes de la EOD como si fueran la población, para poder muestrear muchas veces. Cada muestra de 100 viajes da otra media; ninguna es la poblacional.

La distribución muestral de la media



2.000 muestras, 2.000 medias: su histograma es la distribución muestral, centrada en la media real. Su desviación es el error estándar: cuánto se mueve la media de una muestra a otra. Se pudo hacer porque aquí tenemos la población.

El error estándar, desde una sola muestra

$$EE(\bar{x}) = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}}$$

$\sigma = 36,0$ min: la desviación estándar de la duración en la población, los 113.113 viajes

$s = 35,1$ min: la misma desviación estándar de la duración, pero en la única muestra, los 100 viajes que se tienen

Las dos miden lo mismo, cuánto varía la duración de un viaje a otro · $n = 100$: el tamaño de la muestra · $\bar{x}$: su media

Lo que hicimos recién

con la población, 2.000 muestras de 100:
la desviación de las 2.000 medias

3,7 min

≈

La fórmula, con la población

$\sigma / \sqrt{n} = 36,0 / 10$

3,6 min

≈

La vida real: una sola muestra


$s / \sqrt{n} = 35,1 / 10$
(sin ver la población)

3,5 min

Las 2.000 muestras fueron posibles porque aquí tenemos la población. En la vida real hay una sola muestra y ninguna población a la vista: la fórmula da casi el mismo número desde esa muestra, con s en lugar de σ .

El teorema central del límite


Teorema central del límite: la media se vuelve normal y se angosta con $\sqrt{n}$



La media de una muestra se distribuye normal alrededor de la media real, con desviación $\sigma/\sqrt{n}$, aunque la variable no sea normal. Por eso la normal es la distribución de la inferencia: los promedios lo son, y la regla del $1,96 \sigma$ se les puede aplicar.

3. Primer uso del error estándar: el intervalo


Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas



Después: qué supone la regresión, la trampa de probar de todo, y la logística para un sí o no

Del error estándar a un rango honesto

De la distribución muestral al intervalo



Paso 1: por el TCL las medias muestrales son normales, así que el 95% cae a menos de 1,96 EE de μ .
Paso 2, la misma frase al revés: μ está a menos de 1,96 EE de la media de mi muestra en el 95% de las muestras. Ese rango es el intervalo.

El intervalo de confianza del 95%


El rango que, en el 95% de las muestras, atrapa la media de la población

$$\bar{x} \pm 1,96 \cdot \frac{s}{\sqrt{n}}$$

$\bar{x}$: la media de la muestra · $s/\sqrt{n}$: el error estándar · 1,96: el múltiplo de la normal que deja 95% al centro

Se lee sobre el procedimiento: si repitiéramos el muestreo, el 95% de los intervalos atraparía la media real. Este intervalo en particular la atrapa o no; nunca sabremos cuál de los dos.


Comprobado con la población



100 muestras de 100 viajes, 100 intervalos: los rojos no atrapan la media. Cerca del 95% lo hace; con cola larga y $n = 100$, un poco menos.

4. La pendiente también se mueve


Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas



Después: qué supone la regresión, la trampa de probar de todo, y la logística para un sí o no

La pregunta pendiente: -4,8 minutos por millón, con 45 comunas. Otra muestra de comunas daría otra pendiente. ¿Cuánto se mueve?

Otra muestra, otra recta



No hay una población de comunas de donde sacar otra muestra. El bootstrap la imita con la muestra que hay: saca 45 comunas con reemplazo (algunas se repiten, otras quedan fuera), ajusta la recta y repite.



Remuestrear los datos

```
pendientes = []  
for _ in range(2000):  
    idx = rng.integers(0, 45, 45)      # 45 comunas, con  
    reemplazo  
    pendientes.append(np.polyfit(x[idx], y[idx], 1)[0])  
np.percentile(pendientes, [2.5, 97.5])
```

- Cada remuestra da una pendiente. La distribución de las 2.000 pendientes es la distribución muestral de la pendiente, estimada sin fórmulas ni supuestos.


Comprobado con la media

La distribución muestral de la media, por dos caminos



Sin bootstrap: 2.000 muestras distintas de la población, como en la etapa 2. Con bootstrap: una sola muestra, remuestreada. El ancho se parece, y depende de la muestra que toque; el centro es el de esa muestra, no el real, porque el real no se conoce.

La distribución muestral de la pendiente



Con bootstrap, el histograma: una campana alrededor de la pendiente observada, cuya desviación es el error estándar de la pendiente. Sin bootstrap, la campana punteada: la fórmula de statsmodels, que viene en la siguiente slide. Casi ninguna remuestra llega al 0.

statsmodels lo calcula con una fórmula: std err

	coeficiente	error estándar				
	coef	std err	t	P> t	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

Sin remuestrear, a partir de los residuos: la columna std err. El error estándar de la pendiente es 2,02, cerca del 1,8 del bootstrap. Las demás columnas se van a ir pintando a medida que lleguen sus conceptos.

De dónde sale el std err: la fórmula

Cuánto se mueve la pendiente de una muestra de comunas a otra, calculado desde los residuos

$$EE(b) = \frac{s}{\sqrt{\sum_i (x_i - \bar{x})^2}}, \quad s = \sqrt{\frac{\sum_i e_i^2}{n - 2}}$$

e_i : el residuo de la comuna i , su distancia vertical a la recta · $n - 2$: 45 comunas menos los 2 parámetros de la recta

s : la desviación de los residuos; reemplaza a σ , la desviación de los errores alrededor de la recta verdadera, que no se conoce

$x_i - \bar{x}$: cuánto se aleja el ingreso medio de la comuna i del ingreso medio de todas

Con las 45 comunas: $s = 5,5$ min y $\sqrt{\sum (x - \bar{x})^2} = 2,73$ millones, así que $EE(b) = 5,5 / 2,73 = 2,02$ minutos por millón

La pendiente se mueve menos si las comunas están cerca de la recta (s chico) y si los ingresos están bien desplegados (suma grande)


Los residuos de las 45 comunas dan s , que reemplaza a σ , la desviación de los errores alrededor de la recta verdadera, que no se conoce: la misma decisión de la etapa 2, ahora para la recta. El resultado es el 2,02 del summary.

El intervalo de la pendiente, en el summary

	coeficiente	error estándar			intervalo del 95%	
	coef	std err	t	P> t	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

Las columnas [0.025 0.975]: $b \pm 2,02 \cdot EE = [-8,9; -0,75]$. El primer uso del error estándar, ahora para la pendiente.


El intervalo de la pendiente, por dos caminos



Se parecen, y ninguno incluye el 0. El bootstrap sirve para cualquier estadístico y no necesita supuestos; la fórmula es instantánea, pero supone cosas sobre los residuos que veremos al cerrar la sección 5.

5. Segundo uso del error estándar: el contraste

Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas



Después: qué supone la regresión, la trampa de probar de todo, y la logística para un sí o no

Prueba de hipótesis y valor p: ¿la pendiente es real o azar?

La lógica de la prueba


- ▶ **Hipótesis nula H_0 : la pendiente real es 0, el ingreso no tiene efecto sobre la duración. Alternativa H_1 : no es 0.**
- ▶ Si H_0 fuera cierta, ¿qué tan raro sería obtener una pendiente como la nuestra solo por azar de qué comunas cayeron en la muestra?
- ▶ Es la regla del 1,96 al revés: si la real fuera 0, el 95% de las pendientes caería a menos de unos 2 errores estándar de 0. El estadístico: $t = b / EE$, a cuántos errores estándar del cero está b .
- ▶ El valor p : la probabilidad, si H_0 fuera cierta, de un t así de lejos. Convención: si $p < 0,05$, se rechaza H_0 y el efecto se declara significativo.

t, en el summary

	coeficiente	error estándar	t = coef / EE		intervalo del 95%	
	coef	std err	t	P> t	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750


$t = -4,81 / 2,02 = -2,39$: la pendiente está a 2,4 errores estándar del cero. Falta saber qué tan raro es eso, y con qué distribución se mide.

La t de Student



El error estándar de b se calculó con s , la desviación de los residuos de las 45 comunas, en lugar de σ , la de los errores reales. Con pocos puntos esa estimación agrega incertidumbre: t sigue una normal algo más ancha, con $n - 2$ grados de libertad. Con 45 comunas el 1,96 se vuelve 2,02.

El valor p, dibujado



La t con 43 grados de libertad, centrada en 0: lo que produciría el azar si la pendiente real fuera 0. El área dorada de las dos colas más allá del t observado es el valor p.

t y p, a mano

```
b, ee = modelo.params["ingreso"], modelo.bse["ingreso"]  
t = b / ee                                # -2.39  
  
# Dos colas de la t con n - 2 grados de libertad  
p = 2 * (1 - stats.t.cdf(abs(t), df=43))    # 0.021
```

- Lo que statsmodels imprime sale de esta cuenta: el coeficiente en unidades de su error estándar, y el área que deja en las colas.

El summary completo, por fin


	coeficiente	error estándar	$t = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	t	$P > t $	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

La última columna, $P > |t| = 0,021$: si la pendiente real fuera 0, un t así de lejos ocurre el 2,1% de las veces. Las cinco columnas, pintadas: coeficiente, error estándar, intervalo, t y valor p .

La respuesta, y su letra chica

- ▶ **La pendiente de $-4,8$ no parece azar: $p = 0,021$ y el intervalo $[-8,9; -0,75]$ no incluye el 0. Rechazamos H_0 .**
- ▶ Pero el valor p depende del efecto y del tamaño de la muestra: la motorización (18 mil hogares) tiene $t = 80$ y p prácticamente 0; las comunas, con 45 puntos, apenas cruzan el umbral.
- ▶ Significativo no es importante: el tamaño del efecto lo dice el coeficiente; su precisión, el intervalo.
- ▶ Correlación no es causalidad, tampoco con p pequeño: seguimos reportando asociación.


Intervalo y valor p dicen lo mismo




Que el intervalo no incluya el 0 y que p sea menor que 0,05 es la misma afirmación: b está a más de 2,02 errores estándar del 0. El intervalo además muestra el tamaño y la precisión del efecto; por eso se prefiere.

Supuesto 1: residuos independientes

Residuo de un viaje contra el residuo de otro: independientes a la izquierda, no a la derecha





Los dos primeros viajes de la misma persona: $r = 0,63$



El residuo de un viaje no debería decir nada del residuo de otro. En la EOD la vuelta se parece a la ida: statsmodels cuenta 102 mil viajes independientes cuando hay menos información, y el error estándar queda demasiado chico.

Supuesto 2: la misma varianza en todo el rango

Dispersión de los residuos del modelo duración ~ distancia, por tramo de distancia




Si la dispersión de los residuos crece con x , el error estándar queda mal calculado. Otra razón del log de la clase 4.


Supuesto 3: la normalidad

Con n grande la normalidad de los residuos no hace falta: el TCL hace el trabajo

Los residuos del modelo de motorización (18.264 hogares) no son normales



Y aun así la pendiente, en 1.000 remuestreos, sí es normal




No se supone que las variables sean normales. Con n chico, como las 45 comunas, se supone que los residuos lo son; con n grande el TCL hace el trabajo, porque un coeficiente es un promedio ponderado de los y. Lo que daña son las colas largas y los atípicos.

6. La trampa de las comparaciones múltiples

Qué pasa con el valor p cuando se prueba de todo

20 variables de puro ruido



Números al azar, sin relación con nada, probados contra la duración por comuna: con 20 intentos y umbral 0,05 se espera una falsa alarma. Es lo que pasa al recorrer una matriz de correlación buscando la que dé.


Reglas para el EDA del proyecto

- ▶ **Reportar cuántas pruebas se hicieron; un hallazgo aislado entre muchos intentos merece desconfianza.**
- ▶ La corrección más simple, Bonferroni: dividir el umbral por el número de pruebas ($0,05 / 20 = 0,0025$).
- ▶ Preferir el intervalo de confianza al valor p: muestra el tamaño del efecto y su precisión.
- ▶ Significativo no es importante, y correlación no es causalidad.

7. Otro modelo, el mismo lector


¿Qué hogares tienen auto? Explicar un sí o no con el ingreso del hogar: la regresión logística, y con ella, clasificar

La distribución de un sí o no: Bernoulli y binomial



Tener auto es un sí o no con probabilidad p : una Bernoulli. Contar los síes en n intentos da la binomial, y cada barra sale de su fórmula. La logística modela esa p según el ingreso.

La recta no sirve para un sí o no



Sobre un 0/1, la recta predice 1,39 a los 5 millones y valores negativos abajo: no respeta que la respuesta vive entre 0 y 1. La logística pasa la recta por una S y queda siempre en el rango.

La regresión logística

La probabilidad de un sí, como función de x: la sigmoide

$$P(y = 1 \mid x) = \frac{1}{1 + e^{-(a + bx)}}$$

$P(y = 1 \mid x)$: la probabilidad de un sí dado x · $a + bx$: la misma recta de siempre, en escala de log-chances

e^b : cuánto se multiplican las chances (sí contra no) por cada unidad de x

La misma recta $a + b \cdot x$, pero dentro de la sigmoide. La respuesta es una Bernoulli (la binomial con $n = 1$) cuya probabilidad depende de x .

La logística en statsmodels

```
logistica = sm.GLM(h["tiene_auto"], sm.add_constant(ingreso),  
                  family=sm.families.Binomial(),  
                  freq_weights=h["Factor"]).fit()  
  
np.exp(logistica.params["IngresoHogar"])    # 8.9
```


- GLM con familia binomial, ponderado con el factor. Lectura multiplicativa, como el log de la clase 4: cada millón multiplica las chances de tener auto por 8,9.

El mismo summary, las mismas columnas

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P > z $	[0.025	0.975]
const	-1.8691	0.003	-620.273	0.000	-1.875	-1.863
IngresoHogar	2.1809	0.004	541.553	0.000	2.173	2.189

Las mismas columnas y la misma lectura de la sección 5. Letra chica: el error estándar es minúsculo porque `freq_weights` cuenta cada hogar tantas veces como su factor, como si fueran 2 millones de hogares y no 18 mil; los coeficientes están bien, ese z no.

Clasificar: de la probabilidad a la decisión



Predecir "tiene auto" cuando P supera 0,5 (desde 0,86 millones). Acierta el 70%, contra el 61% de decir siempre "no": la comparación con la base es obligatoria. Dónde se equivoca lo dice la matriz de confusión (un crosstab).

Síntesis

- ▶ **Todo número que sale de una muestra se mueve de muestra en muestra; el error estándar mide cuánto.**
- ▶ Primer uso: el intervalo, estimación ± 2 EE, atrapa el valor real el 95% de las veces.
- ▶ Segundo uso: la prueba, $t = b / EE$ y el valor p . La pendiente de $-4,8$: $p = 0,021$, real.
- ▶ El bootstrap da lo mismo remuestreando, sin fórmulas; la logística usa el mismo summary para un sí o no.
- ▶ **Para el EDA del lunes 15: intervalos, y cuidado con probar de todo.**

Recreo

10 minutos · al volver: manos al teclado, con el notebook

Próxima clase

- ▶ Jueves 10: regresión lineal en profundidad: supuestos, diagnósticos con los residuos y evaluación fuera de la muestra.
- ▶ Con lo de hoy ya se puede leer completo el summary de cualquier modelo.
- ▶ **El primer análisis exploratorio se entrega el lunes 15.**

Referencias

Efron, B. y Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.

Wasserstein, R. L. y Lazar, N. A. (2016). The ASA Statement on p-Values: Context, Process, and Purpose. The American Statistician, 70(2), 129-133.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly.

Datos: Encuesta Origen Destino Santiago 2012 (Sectra).