

Introducción y fundamentos estadísticos

Clase 5 · Probabilidad e inferencia: ¿real o azar?

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 8 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Avisos del proyecto Capstone

- ▶ **El primer análisis exploratorio se entrega el lunes 15; el enunciado y la rúbrica están publicados en el repositorio.**
- ▶ La formulación entregada el lunes 7 se devuelve con comentarios durante la semana.

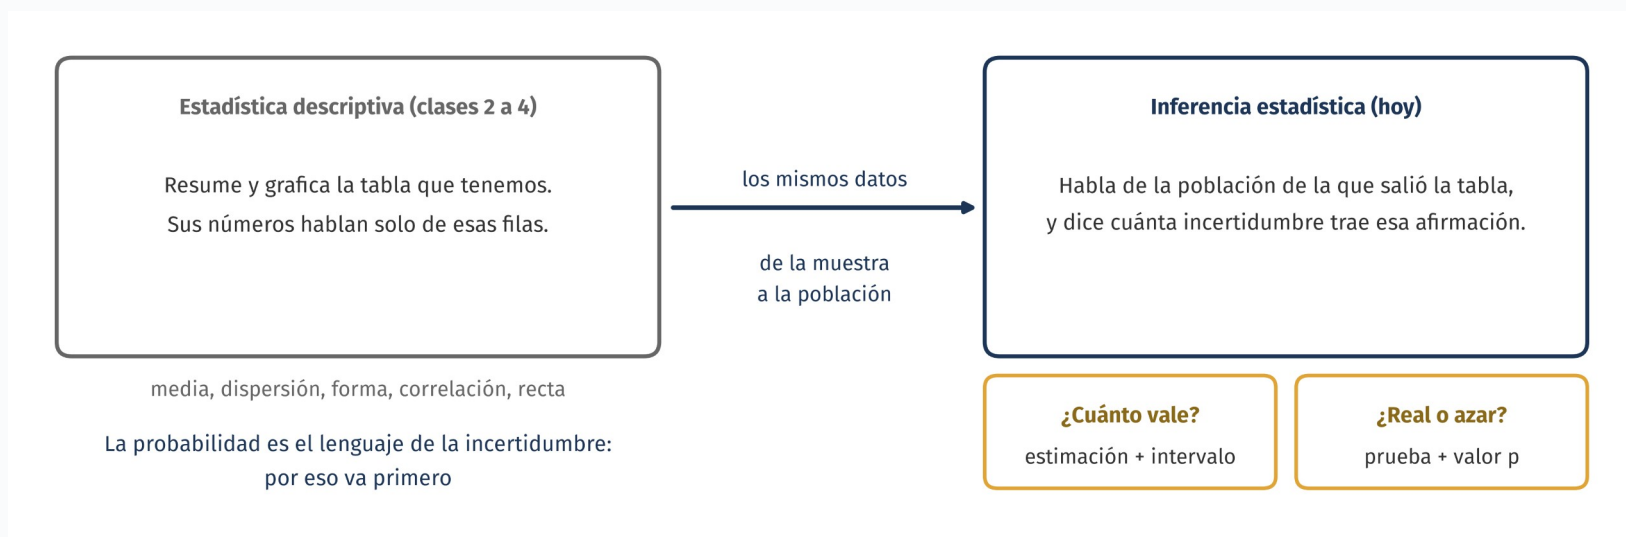
Contenidos de la clase

- ▶ 1. El azar tiene forma: variables aleatorias y la normal.
- ▶ 2. Un número se mueve: distribución muestral y error estándar.
- ▶ 3. Primer uso del error estándar: el intervalo de confianza.
- ▶ 4. La pendiente también se mueve: bootstrap.
- ▶ 5. Segundo uso: la prueba de hipótesis, la t y el valor p . Qué supone.

¿Cuánto se movería este número con otra muestra?

La pregunta pendiente desde la clase 3: la pendiente de -4,8 minutos por millón, con 45 comunas y $p = 0,021$. ¿Real o azar? Hoy se responde


Descriptiva e inferencia



La descriptiva habla de la tabla que tenemos; la inferencia, de la población de la que salió, con su incertidumbre. Dos preguntas: cuánto vale, y si es real o azar.

1. El azar tiene forma


Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas



Después: qué supone la regresión para inferir

Probabilidad, el lenguaje de la incertidumbre: variables aleatorias y distribuciones



Una variable aleatoria y su distribución



La duración del próximo viaje depende del azar: es una variable aleatoria. Su distribución dice qué valores toma y con qué frecuencia: en la población, el histograma. La esperanza es su media.


La media también es una variable aleatoria

Dos variables aleatorias: la duración de un viaje, y la media de una muestra de 100 viajes




Depende de qué 100 viajes cayeron en la muestra: otra muestra, otra media. Y aunque la duración no tenga forma de campana, la media sí. Esa campana tiene nombre, y es la siguiente slide.

La distribución normal



La campana tiene dos parámetros: μ , la media, y σ , la desviación estándar. El 95% de los valores cae a menos de $1,96 \sigma$ de la media. Es la distribución de la inferencia porque los promedios la siguen; ese $1,96$ vuelve en los intervalos de confianza.


La duración no es normal; en log, casi



La cola larga (asimetría 5,3) se aleja de la normal; en log la variable se acomoda a la campana. Es la razón de fondo del log de la clase 4.

2. Un número se mueve


Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas



Después: qué supone la regresión para inferir


Muestra y población: una muestra es una de muchas posibles

Dos muestras, dos medias



Hoy tratamos los 113 mil viajes de la EOD como si fueran la población, para poder muestrear muchas veces. Cada muestra de 100 viajes da otra media; ninguna es la poblacional.



La distribución muestral de la media



2.000 muestras, 2.000 medias: su histograma es la distribución muestral, centrada en la media real. Su desviación es el error estándar: cuánto se mueve la media de una muestra a otra. Se pudo hacer porque aquí tenemos la población.

Desviación estándar y error estándar

Dos desviaciones estándar de cosas distintas, en la misma escala



La desviación estándar σ describe los datos: cuánto varía la duración de un viaje a otro. El error estándar $EE(\bar{x}) = \sigma/\sqrt{n}$ describe el estimador: cuánto varía la media de una muestra a otra. Es la desviación estándar de la distribución muestral; por eso es más chico, y baja con n .

El error estándar, desde una sola muestra

$$EE(\bar{x}) = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}}$$

$\sigma = 36,0$ min: la desviación estándar de la duración en la población, los 113.113 viajes

$s = 35,1$ min: la misma desviación estándar de la duración, pero en la única muestra, los 100 viajes que se tienen

Las dos miden lo mismo, cuánto varía la duración de un viaje a otro · $n = 100$: el tamaño de la muestra · $\bar{x}$: su media

Lo que hicimos recién

con la población, 2.000 muestras de 100:
la desviación de las 2.000 medias

3,7 min

≈

La fórmula, con la población

$\sigma / \sqrt{n} = 36,0 / 10$

3,6 min

≈

La vida real: una sola muestra


$s / \sqrt{n} = 35,1 / 10$
(sin ver la población)

3,5 min

Las 2.000 muestras fueron posibles porque aquí tenemos la población. En la vida real hay una sola muestra y ninguna población a la vista: la fórmula da casi el mismo número desde esa muestra, con s en lugar de σ .

El teorema central del límite


Teorema central del límite: la media se vuelve normal y se angosta con $\sqrt{n}$



La media de una muestra se distribuye normal alrededor de la media real, con desviación $\sigma/\sqrt{n}$, aunque la variable no sea normal. Por eso la normal es la distribución de la inferencia: los promedios lo son, y la regla del $1,96 \sigma$ se les puede aplicar.

3. Primer uso del error estándar: el intervalo


Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas



Después: qué supone la regresión para inferir

Del error estándar a un rango honesto

De la distribución muestral al intervalo



Paso 1: por el TCL las medias muestrales son normales, así que el 95% cae a menos de 1,96 EE de μ .
Paso 2, la misma frase al revés: μ está a menos de 1,96 EE de la media de mi muestra en el 95% de las muestras. Ese rango es el intervalo.

El intervalo de confianza del 95%


El rango que, en el 95% de las muestras, atrapa la media de la población

$$\bar{x} \pm 1,96 \cdot \frac{s}{\sqrt{n}}$$

$\bar{x}$: la media de la muestra · $s/\sqrt{n}$: el error estándar · 1,96: el múltiplo de la normal que deja 95% al centro

Se lee sobre el procedimiento: si repitiéramos el muestreo, el 95% de los intervalos atraparía la media real. Este intervalo en particular la atrapa o no; nunca sabremos cuál de los dos.


Comprobado con la población



100 muestras de 100 viajes, 100 intervalos: los rojos no atrapan la media. Cerca del 95% lo hace; con cola larga y $n = 100$, un poco menos.

4. La pendiente también se mueve

Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas




Después: qué supone la regresión para inferir

La pregunta pendiente: la pendiente de la recta duración = $a + b \cdot \text{ingreso}$, $b = -4,8$ minutos por millón, con 45 comunas (el coef del ingreso en el summary). Otra muestra de comunas daría otra b .
¿Cuánto se mueve?

Qué es el bootstrap


Bootstrap (Efron y Tibshirani, 1993): tratar la muestra como si fuera la población y sacar de ella muchas muestras nuevas del mismo tamaño, con reemplazo, para ver cuánto se mueve la pendiente



Sacar con reemplazo no es quitar una comuna y poner otra: es devolver la comuna sacada a la bolsa antes de sacar la siguiente. Por eso una misma comuna puede salir varias veces, y otra ninguna



No hay una población de comunas de donde sacar otra muestra, así que la muestra hace de población: se sacan de ella muestras nuevas de 45, con reemplazo, y se mira cuánto cambia la pendiente entre ellas. Sin reemplazo no serviría: 45 de 45 son siempre las mismas 45.

Una remuestra: los mismos 45 puntos




La remuestra anterior, sobre el gráfico: las comunas que no salieron quedan vacías, las que salieron varias veces pesan más, y la recta de esta remuestra tiene otra pendiente que la observada.

Otra muestra, otra recta, otra pendiente



Cada remuestra da una recta y cada recta una pendiente: 30 rectas, 30 pendientes. Las 30 son solo para ver la idea; para ver la forma completa hacen falta más, y la siguiente slide dice cuántas y por qué.

Con 3 comunas, 10 remuestras posibles; con 45, 5×10^{25}




Sacar 3 con reemplazo: 10 remuestras posibles

remuestra	comunas que entran	pendiente
AAA	un solo punto, tres veces	sin recta
AAB	A $\times 2$, B $\times 1$	20,7
AAC	A $\times 2$, C $\times 1$	-3,8
ABB	A $\times 1$, B $\times 2$	20,7
ABC	A $\times 1$, B $\times 1$, C $\times 1$	-4,8
ACC	A $\times 1$, C $\times 2$	-3,8
BBB	un solo punto, tres veces	sin recta
BBC	B $\times 2$, C $\times 1$	-6,3
BCC	B $\times 1$, C $\times 2$	-6,3
CCC	un solo punto, tres veces	sin recta

Cada remuestra es un conjunto distinto de puntos, con repeticiones, y cada conjunto da su recta. Con 45 comunas las combinaciones son 5×10^{25} : las 30 rectas y las 2.000 son combinaciones distintas elegidas al azar. Lo que se repite es el procedimiento, no el ajuste.

¿Por qué 2.000 remuestras, y no 30?



Las cuentas

Remuestras distintas posibles	5×10^{25}
(45 comunas sacadas con reemplazo)	
Remuestras sacadas	2.000
Distintas entre sí	2.000
Ajustes repetidos	0

No se repite ningún ajuste: cada remuestra es una combinación distinta de las 45 comunas


Con 30 el histograma es tosco y el error estándar todavía se mueve; desde unas 2.000 deja de cambiar. Y no se repite ningún ajuste: de 5×10^{25} remuestras posibles, las 2.000 sacadas son todas distintas.

Remuestrear los datos

```
pendientes = []  
for _ in range(2000):  
    idx = rng.integers(0, 45, 45)    # con reemplazo  
    pendientes.append(np.polyfit(x[idx], y[idx], 1)[0])  
np.percentile(pendientes, [2.5, 97.5])
```


- Cada remuestra da una pendiente. La distribución de las 2.000 pendientes es la distribución muestral de la pendiente, estimada sin fórmulas ni supuestos.

La distribución muestral de la pendiente



Con bootstrap, el histograma: una campana alrededor de la pendiente observada, cuya desviación es el error estándar de la pendiente. Sin bootstrap, la campana punteada: la fórmula de statsmodels, que viene en la siguiente slide. Casi ninguna remuestra llega al 0.

El intervalo bootstrap: los percentiles 2,5 y 97,5



Ordenar las 2.000 pendientes: la número 50 desde abajo es el percentil 2,5 y la número 50 desde arriba, el 97,5. Entre ambas queda el 95% central de las remuestras, y ese es el intervalo. No supone forma de campana: lo lee directo del histograma.

statsmodels lo calcula con una fórmula: std err

	coeficiente	error estándar				
	coef	std err	t	P> t	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

Sin remuestrear, a partir de los residuos: la columna std err. El error estándar de la pendiente es 2,02, cerca del 1,8 del bootstrap. Las demás columnas se van a ir pintando a medida que lleguen sus conceptos.

De dónde sale el std err: la fórmula

$$EE(b) = \frac{s}{\sqrt{\sum_i (x_i - \bar{x})^2}} \quad \text{con} \quad s = \sqrt{\frac{\sum_i e_i^2}{n - 2}}$$

b : la pendiente de la recta duración = $a + b \cdot$ ingreso, el coef del summary; queremos saber cuánto se mueve

e_i : el residuo de la comuna i , su distancia vertical a la recta

s : la desviación de esos residuos; reemplaza a σ , la de los errores reales, que no se conoce

$x_i - \bar{x}$: cuánto se aleja el ingreso de la comuna i del ingreso medio $\cdot n - 2$: 45 comunas menos 2 parámetros

Con las 45 comunas: $s = 5,5$ min y $\sqrt{\sum (x - \bar{x})^2} = 2,73$, así que $EE(b) = 5,5 / 2,73 = 2,02$

La misma decisión de la etapa 2, ahora para la recta: s reemplaza a σ . La pendiente se mueve menos si las comunas están cerca de la recta (s chico) y si los ingresos están bien desplegados (la suma grande).

El intervalo de la pendiente, en el summary

	coeficiente	error estándar			intervalo del 95%	
	coef	std err	t	P> t	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

Las columnas [0.025 0.975]: $b \pm 2,02 \cdot EE = [-8,9; -0,75]$. El primer uso del error estándar, ahora para la pendiente.

La pendiente de las comunas, con y sin bootstrap

	Sin bootstrap: la fórmula	Con bootstrap
cómo se obtiene	una fórmula, a partir de los residuos de las 45 comunas	2.000 remuestras de las 45 comunas, con reemplazo
pendiente	-4,81	-4,81, la observada
error estándar	2,02	1,82, la desviación de las 2.000
intervalo del 95%	$[-8,9; -0,75]$, $b \pm 2,02 \cdot EE$	$[-9,1; -2,1]$, percentiles 2,5 y 97,5
qué necesita	que exista la fórmula para ese estadístico, y supuestos sobre los residuos	solo el computador, y que la muestra represente a la población
sirve para	medias y coeficientes de regresión	cualquier estadístico


Dos caminos al mismo número, con la misma muestra de 45 comunas: se parecen, y ningún intervalo incluye el 0. La fórmula es instantánea, pero existe solo para algunos estadísticos y supone cosas sobre los residuos.

¿Cuándo bootstrap y cuándo la fórmula?

- ▶ **La fórmula (y su t): medias y coeficientes de una regresión bien planteada, con errores independientes y varianza pareja. Es exacta, instantánea y viene en el summary.**
- ▶ Bootstrap cuando no hay fórmula para ese estadístico: una mediana, un percentil, una razón, un R^2 , la métrica de un modelo.
- ▶ Bootstrap cuando los supuestos fallan: colas largas con pocos datos, varianza que cambia, un estimador que no es un promedio. No supone campana: lee el histograma.
- ▶ Ninguno arregla una muestra sesgada ni filas dependientes. Si se pueden hacer los dos, hacerlos: si coinciden, la fórmula está bien.

5. Segundo uso del error estándar: el contraste

Todo número que sale de una muestra se mueve; el error estándar mide cuánto, y se usa de dos formas




Después: qué supone la regresión para inferir

Prueba de hipótesis y valor p: ¿la pendiente es real o azar?

Qué tiene que ver p con la regresión

El valor p en la regresión: ¿la inclinación de la recta es una señal, o ruido de la muestra?




p pequeño: demasiado raro para ser azar, la relación probablemente es real · p grande: no se distingue del ruido (no hay evidencia, que no es lo mismo que no exista)

Con $p = 0,021$ concluimos que la relación entre ingreso y duración probablemente es real; con $p = 0,40$ no podríamos distinguir la recta del ruido. Lo que p no dice: si el efecto es grande, ni si es causal.


La misma campana, en dos posiciones

La misma campana, con el mismo ancho (EE = 2,02), en dos posiciones

Cuánto se mueve nuestra pendiente: la campana centrada en lo observado. En dorado, el intervalo del 95%: [-8,9; -0,75]



Qué haría el azar si la pendiente real fuera 0: la misma campana, centrada en 0. En dorado, el 95% del azar: $\pm 4,1$. Rojo oscuro: $p = 0,021$



Arriba, centrada en lo observado: cuánto se mueve nuestra pendiente, y de ahí el intervalo. Abajo, centrada en 0: qué haría el azar sin relación, y de ahí la prueba. Que el intervalo no toque el 0 y que b caiga en la zona de rechazo es la misma afirmación.

La lógica de la prueba

- ▶ **Hipótesis nula H_0 : la pendiente real es 0, el ingreso no tiene efecto sobre la duración. Alternativa H_1 : no es 0.**
- ▶ Si H_0 fuera cierta, ¿qué tan raro sería obtener una pendiente como la nuestra solo por azar de qué comunas cayeron en la muestra?
- ▶ Es la regla del 1,96 al revés: si la real fuera 0, el 95% de las pendientes caería a menos de unos 2 errores estándar de 0. El estadístico: $t = b / EE(b)$, a cuántos errores estándar del cero está la pendiente b .
- ▶ El valor p : la probabilidad, si H_0 fuera cierta, de un t así de lejos. Convención: si $p < 0,05$, se rechaza H_0 y el efecto se declara significativo.

t, en el summary

	coeficiente	error estándar	t = coef / EE		intervalo del 95%	
	coef	std err	t	P> t	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

$t = -4,81 / 2,02 = -2,39$: la pendiente está a 2,4 errores estándar del cero. Falta saber qué tan raro es eso, y con qué distribución se mide.

t y p: la fórmula y el código

$$t = \frac{b}{EE(b)} \qquad p = 2 \cdot (1 - F(|t|))$$

t: a cuántos errores estándar del cero está la pendiente b · p: el área de las dos colas de la t de Student más allá de t

Con las comunas: t = -4,81 / 2,02 = -2,39, p = 0,021

```
b, ee = modelo.params["ingreso"], modelo.bse["ingreso"]
t = b / ee                                # -2.39

# Dos colas de la t con n - 2 grados de libertad
p = 2 * (1 - stats.t.cdf(abs(t), df=43))  # 0.021
```

F es la acumulada de la t de Student con $n - 2 = 43$ grados de libertad: la normal con un margen extra, porque σ se estimó con s.

El summary completo, por fin

	coeficiente	error estándar	$t = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	t	$P> t $	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

La última columna, $P>|t| = 0,021$: si la pendiente real fuera 0, un t así de lejos ocurre el 2,1% de las veces. Las cinco columnas, pintadas: coeficiente, error estándar, intervalo, t y valor p .

La respuesta a la pregunta de la clase

- ▶ **La pendiente que nos dio el modelo no es azar: en las comunas de mayor ingreso los viajes duran menos, unos 4,8 minutos menos por cada millón de pesos de ingreso medio (entre 0,75 y 8,9).**
- ▶ Lo que la sostiene: $p = 0,021$ y el intervalo $[-8,9; -0,75]$ no incluye el 0. Con 45 comunas apenas cruza el umbral, porque p depende del efecto y del tamaño de la muestra.
- ▶ Que un efecto sea estadísticamente significativo no dice que sea grande: el tamaño lo da el coeficiente, y su precisión, el intervalo.
- ▶ Correlación no es causalidad, tampoco con p pequeño.

Supuestos de OLS, 1: errores independientes

Supuesto 1 de OLS: los errores son independientes entre filas

Un ejemplo: regresión del gasto del hogar sobre su ingreso, con 20 personas

20 personas de 20 casas distintas: 20 residuos independientes




20 personas de 10 casas (parejas): 20 filas, pero 10 residuos independientes



las dos personas de una casa comparten ingreso, gasto y residuo; OLS cuenta 20

Qué pasa con filas repetidas: la tabla de las 45 comunas, repetida, no agrega información y el error estándar baja igual




Los t y p de OLS suponen errores independientes entre filas. Si 50 de las 100 personas son parejas de la misma casa, comparten ingreso, gasto y residuo: 100 filas, 50 residuos independientes, y OLS cuenta 100. Repetir una tabla muestra el efecto: el error estándar baja de 2,02 a 1,41 sin información nueva.


Supuestos de OLS, 2: varianza constante

El supuesto: los residuos (la distancia vertical de cada punto a la recta) tienen la misma dispersión en todo el rango de x

Se cumple: la nube tiene el mismo ancho en todo el rango de x






Falla: la nube se abre a medida que x crece



La fórmula del std err usa un solo número para todos los residuos, s : $EE(b) = s / \sqrt{\sum (x - \bar{x})^2}$. En los viajes, la dispersión de la duración crece con la distancia; en log casi no cambia. Otra razón del log de la clase 4.

Supuestos de OLS, 3: errores normales, con pocos datos

Supuesto 3: los residuos siguen una normal. Importa con pocos datos; con muchos, el TCL lo reemplaza



El supuesto: los residuos siguen una normal, no las variables. Con 45 comunas hay que mirarlo, en el histograma de residuos y en los atípicos. Con 18 mil hogares deja de importar: los residuos no son normales y la pendiente igual se reparte como una normal, por el teorema central del límite.

Por qué esto importa en ciencia de datos

- ▶ **Todo lo que entrega un modelo sale de una muestra: sus coeficientes, sus predicciones y las métricas con que se evalúa. Con otra muestra, todo eso cambia.**
- ▶ Comparar dos modelos es comparar dos números que se mueven. Sin saber cuánto se mueven, no se puede decir cuál es mejor.
- ▶ Un modelo que se ajusta demasiado a su muestra aprende el azar de esa muestra, y falla con datos nuevos. Medir el movimiento es la forma de detectarlo.
- ▶ Las técnicas de las próximas clases, y del resto del diplomado, son maneras de medir y controlar ese movimiento.

Síntesis

- ▶ Inferir es pasar de la muestra a la población cuantificando la incertidumbre. La herramienta central es el error estándar: la desviación estándar de la distribución muestral de un estimador, sea la media o la pendiente, obtenida por fórmula o por bootstrap.
- ▶ El intervalo de confianza del 95%, estimación $\pm 1,96$ EE (2,02 EE con 43 grados de libertad), delimita los valores de la población compatibles con los datos.
- ▶ La prueba de hipótesis contrasta el estimador con el valor que tendría sin efecto: $t = b / EE(b)$, y su valor p es la probabilidad de un t tan extremo bajo H_0 . Para la pendiente de las comunas, $p = 0,021$: se rechaza H_0 .

Recreo

10 minutos · al volver: manos al teclado, con el notebook

Próxima clase

- ▶ Jueves 10: regresión logística, para una respuesta que es sí o no, y cómo clasificar con ella.
- ▶ Con lo de hoy ya se puede leer completo el summary de cualquier modelo.
- ▶ **El primer análisis exploratorio se entrega el lunes 15.**

Referencias

Efron, B. y Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.

Wasserstein, R. L. y Lazar, N. A. (2016). The ASA Statement on p-Values: Context, Process, and Purpose. The American Statistician, 70(2), 129-133.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly.

Datos: Encuesta Origen Destino Santiago 2012 (Sectra).