

Introducción y fundamentos estadísticos

Clase 5 · Probabilidad e inferencia: ¿real o azar?

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 8 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Avisos del proyecto Capstone

- ▶ **El primer análisis exploratorio se entrega el lunes 15; el enunciado y la rúbrica están publicados en el repositorio.**
- ▶ La formulación entregada el lunes 7 se devuelve con comentarios durante la semana.
- ▶ Lo de hoy entra directo en el EDA: intervalos de confianza y la trampa de probar muchas variables.

Contenidos de la clase

- ▶ 1. Probabilidad: variables aleatorias y distribuciones.
- ▶ 2. Inferencia: muestra y población, la distribución muestral y el error estándar.
- ▶ 3. Intervalos de confianza.
- ▶ 4. Prueba de hipótesis y valor p: la pregunta pendiente.
- ▶ 5. Bootstrap, y regresión logística: clasificar un sí o no.
- ▶ 6. La trampa de las comparaciones múltiples.


¿Cuánto se movería este número con otra muestra?

La pregunta pendiente desde la clase 3: la pendiente de -4,8 minutos por millón, con 45 comunas y $p = 0,021$. ¿Real o azar? Hoy se responde

Descriptiva e inferencia

- ▶ **Estadística descriptiva, clases 2 a 4:** resume y grafica la tabla que tenemos. Sus números hablan solo de esas filas, no de los viajes que nadie encuestó.
- ▶ **Inferencia estadística:** usa esos mismos datos para hablar de la población de la que salieron, y dice cuánta incertidumbre trae esa afirmación.
- ▶ Sus dos preguntas: ¿cuánto vale? (estimación, con un intervalo) y ¿es real o azar? (prueba de hipótesis, con un valor p).
- ▶ La probabilidad es el lenguaje de esa incertidumbre; por eso va primero.

Por qué aparece la normal




No porque los datos sean normales (la duración no lo es), sino porque los promedios lo son: al repetir la muestra, la media y la pendiente se reparten como una campana alrededor del valor real. De esa campana sale el 1,96 que construye el intervalo y el valor p.

Probabilidad

El lenguaje de la incertidumbre: variables aleatorias y distribuciones


Una variable aleatoria y su distribución



La duración del próximo viaje depende del azar: es una variable aleatoria. Su distribución dice qué valores toma y con qué frecuencia: en la población, el histograma. La esperanza es su media.

La distribución normal


La normal $N(\mu, \sigma^2)$ y su regla 68-95-99,7



μ : la media, el centro de la campana · σ : la desviación estándar, su ancho · cada porcentaje: la fracción de los valores que cae en la franja dorada


La campana tiene dos parámetros: μ , la media, y σ , la desviación estándar. El 95% de los valores cae a menos de $1,96 \sigma$ de la media. Es la distribución de la inferencia porque los promedios la siguen; ese 1,96 vuelve en los intervalos de confianza.

¿Es normal la duración? En minutos no; en log, casi



La cola larga (asimetría 5,3) se aleja de la normal; en log la variable se acomoda a la campana. Es la razón de fondo del log de la clase 4.

Una distribución para contar: la binomial




El número de éxitos en n intentos independientes con probabilidad p . Cada barra sale de la fórmula: las formas de elegir k viajes entre 20, por p elevado a k , por $(1 - p)$ elevado a $20 - k$. En Python, `stats.binom.pmf(k, 20, p)`.

Muestra y población

Una muestra es una de muchas posibles


Dos muestras, dos medias

La media de la población es 36,9 min; cada muestra da otra cosa



Hoy tratamos los 113 mil viajes de la EOD como si fueran la población, para poder muestrear muchas veces. Cada muestra de 100 viajes da otra media; ninguna es la poblacional.

La distribución muestral de la media



2.000 muestras, 2.000 medias: su histograma es la distribución muestral, centrada en la media real. Su desviación estándar es el error estándar: cuánto se mueve la media de una muestra a otra.

El error estándar de la media

Cuánto se mueve la media de una muestra a otra


$$EE(\bar{x}) = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}}$$

$\bar{x}$: la media de la muestra · σ : la desviación estándar de la población (en la práctica, s , la de la muestra) · n : el tamaño de la muestra

Se calcula desde una sola muestra, sin ver la población. Para reducirlo a la mitad hay que cuadruplicar la muestra.

El teorema central del límite

Teorema central del límite: la media se vuelve normal y se angosta con $\sqrt{n}$




La media de una muestra se distribuye normal alrededor de la media real, con desviación $\sigma/\sqrt{n}$, aunque la variable no sea normal. Por eso la normal es la distribución de la inferencia: los promedios lo son, y la regla del $1,96 \sigma$ se les puede aplicar.

Intervalos de confianza

Del error estándar a un rango honesto

De la distribución muestral al intervalo



Paso 1: por el TCL las medias muestrales son normales, así que el 95% cae a menos de 1,96 EE de μ .
Paso 2, la misma frase al revés: μ está a menos de 1,96 EE de la media de mi muestra en el 95% de las muestras. Ese rango es el intervalo.

El intervalo de confianza del 95%


El rango que, en el 95% de las muestras, atrapa la media de la población

$$\bar{x} \pm 1,96 \cdot \frac{s}{\sqrt{n}}$$

$\bar{x}$: la media de la muestra · $s/\sqrt{n}$: el error estándar · 1,96: el múltiplo de la normal que deja 95% al centro

Se lee sobre el procedimiento: si repitiéramos el muestreo, el 95% de los intervalos atraparía la media real. Este intervalo en particular la atrapa o no; nunca sabremos cuál de los dos.

Comprobado con la población



100 muestras de 100 viajes, 100 intervalos: los rojos no atrapan la media. Cerca del 95% lo hace; con cola larga y $n = 100$, un poco menos.

Prueba de hipótesis y valor p

La pregunta pendiente: ¿la pendiente es real o azar?

La lógica de la prueba


- ▶ **Hipótesis nula H_0 : la pendiente real es 0, el ingreso no tiene efecto sobre la duración. Alternativa H_1 : no es 0.**
- ▶ Si H_0 fuera cierta, ¿qué tan raro sería obtener una pendiente como la nuestra solo por azar de qué comunas cayeron en la muestra?
- ▶ Esa probabilidad es el valor p. Convención: si $p < 0,05$, se rechaza H_0 y el efecto se declara significativo.
- ▶ El estadístico que lo mide: $t = \text{coeficiente} / \text{error estándar}$, a cuántos errores estándar del cero está la pendiente.

El summary completo, por fin

	coeficiente	error estándar	$t = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	t	$P > t $	[0.025	0.975]
const	38.3352	1.773	21.622	0.000	34.760	41.911
ingreso	-4.8146	2.015	-2.389	0.021	-8.879	-0.750

La pendiente -4,81 con error estándar 2,02: $t = -2,39$. Si la real fuera 0, un t así de lejos ocurre el 2,1% de las veces: $p = 0,021$. El intervalo $[-8,9; -0,75]$ no incluye el 0.

El valor p, dibujado



Con 45 puntos se usa la distribución t (una normal algo más ancha, por estimar σ con s). El área dorada de las dos colas más allá del t observado es el valor p.

t y p, a mano

```
b, ee = modelo.params["ingreso"], modelo.bse["ingreso"]  
t = b / ee                                # -2.39  
  
# Dos colas de la t con n - 2 grados de libertad  
p = 2 * (1 - stats.t.cdf(abs(t), df=43))    # 0.021
```


- Lo que statsmodels imprime sale de esta cuenta: el coeficiente en unidades de su error estándar, y el área que deja en las colas.

La respuesta, y su letra chica


- ▶ **La pendiente de $-4,8$ no parece azar: $p = 0,021$ y el intervalo $[-8,9; -0,75]$ no incluye el 0. Rechazamos H_0 .**
- ▶ Pero el valor p depende del efecto y del tamaño de la muestra: la motorización (18 mil hogares) tiene $t = 80$ y p prácticamente 0; las comunas, con 45 puntos, apenas cruzan el umbral.
- ▶ Significativo no es importante: el tamaño del efecto lo dice el coeficiente; su precisión, el intervalo.
- ▶ Correlación no es causalidad, tampoco con p pequeño: seguimos reportando asociación.

Supuesto 1: residuos independientes

Residuo de un viaje contra el residuo de otro: independientes a la izquierda, no a la derecha





Los dos primeros viajes de la misma persona: $r = 0,63$



El residuo de un viaje no debería decir nada del residuo de otro. En la EOD la vuelta se parece a la ida: statsmodels cuenta 102 mil viajes independientes cuando hay menos información, y el error estándar queda demasiado chico.

Supuesto 2: la misma varianza en todo el rango

Dispersión de los residuos del modelo duración ~ distancia, por tramo de distancia




Si la dispersión de los residuos crece con x , el error estándar queda mal calculado. Otra razón del log de la clase 4.


Supuesto 3: la normalidad

Con n grande la normalidad de los residuos no hace falta: el TCL hace el trabajo

Los residuos del modelo de motorización (18.264 hogares) no son normales



Y aun así la pendiente, en 1.000 remuestreos, sí es normal



No se supone que las variables sean normales. Con n chico, como las 45 comunas, se supone que los residuos lo son; con n grande el TCL hace el trabajo, porque un coeficiente es un promedio ponderado de los y. Lo que daña son las colas largas y los atípicos.

Bootstrap


La misma respuesta, sin fórmulas

Remuestrear los datos

```
pendientes = []  
for _ in range(2000):  
    idx = rng.integers(0, 45, 45)      # 45 comunas, con  
    reemplazo  
    pendientes.append(np.polyfit(x[idx], y[idx], 1)[0])  
np.percentile(pendientes, [2.5, 97.5])
```

- Sacar 45 comunas con reemplazo imita el azar del muestreo: algunas se repiten, otras quedan fuera. La distribución de las 2.000 pendientes dice cuánto se mueve la muestra

La pendiente, remuestreada




El intervalo bootstrap se parece al de statsmodels y casi ninguna remuestra llega al 0: la misma conclusión por un camino que solo usa el computador. Sirve para cualquier estadístico.

¿Qué hogares tienen auto?

Explicar un sí o no (tiene auto) con el ingreso del hogar: la regresión logística, y con ella, clasificar

La recta no sirve para un sí o no



Sobre un 0/1, la recta predice 1,39 a los 5 millones y valores negativos abajo: no respeta que la respuesta vive entre 0 y 1. La logística pasa la recta por una S y queda siempre en el rango.

La regresión logística

La probabilidad de un sí, como función de x: la sigmoide

$$P(y = 1 \mid x) = \frac{1}{1 + e^{-(a + bx)}}$$

$P(y = 1 \mid x)$: la probabilidad de un sí dado $x \cdot a + bx$: la misma recta de siempre, en escala de log-chances

e^b : cuánto se multiplican las chances (sí contra no) por cada unidad de x


La misma recta $a + b \cdot x$, pero dentro de la sigmoide. La respuesta es una Bernoulli (la binomial con $n = 1$) cuya probabilidad depende de x.

La logística en statsmodels

```
logistica = sm.GLM(h["tiene_auto"], sm.add_constant(ingreso),  
                  family=sm.families.Binomial(),  
                  freq_weights=h["Factor"]).fit()  
  
np.exp(logistica.params["IngresoHogar"])    # 8.9
```

- GLM con familia binomial, ponderado con el factor. Lectura multiplicativa, como el log de la clase 4: cada millón multiplica las chances de tener auto por 8,9.

Clasificar: de la probabilidad a la decisión




Predecir "tiene auto" cuando P supera 0,5 (desde 0,86 millones). Acierta el 70%, contra el 61% de decir siempre "no": la comparación con la base es obligatoria. Dónde se equivoca lo dice la matriz de confusión (un crosstab).

La trampa de las comparaciones múltiples

Qué pasa con el valor p cuando se prueba de todo

20 variables de puro ruido



Números al azar, sin relación con nada, probados contra la duración por comuna: con 20 intentos y umbral 0,05 se espera una falsa alarma. Es lo que pasa al recorrer una matriz de correlación buscando la que dé.

Reglas para el EDA del proyecto

- ▶ **Reportar cuántas pruebas se hicieron; un hallazgo aislado entre muchos intentos merece desconfianza.**
- ▶ La corrección más simple, Bonferroni: dividir el umbral por el número de pruebas ($0,05 / 20 = 0,0025$).
- ▶ Preferir el intervalo de confianza al valor p: muestra el tamaño del efecto y su precisión.
- ▶ Significativo no es importante, y correlación no es causalidad.

Síntesis

- ▶ Una muestra es una de muchas: todo número calculado se movería con otra muestra, y el error estándar mide cuánto.
- ▶ El teorema central del límite: los promedios se distribuyen normal, aunque los datos no.
- ▶ El intervalo de confianza convierte el error estándar en un rango que atrapa el valor real el 95% de las veces.
- ▶ El valor p responde: si el efecto real fuera cero, ¿qué tan raro sería lo observado? Con $p < 0,05$, la pendiente de $-4,8$ es real.
- ▶ Para un sí o no, la regresión logística: la recta dentro de una sigmoide; clasificar es cortar en 0,5 y comparar con la base.

Recreo

10 minutos · al volver: manos al teclado, con el notebook

Próxima clase

- ▶ Jueves 10: regresión lineal en profundidad: supuestos, diagnósticos con los residuos y evaluación fuera de la muestra.
- ▶ Con lo de hoy ya se puede leer completo el summary de cualquier modelo.
- ▶ **El primer análisis exploratorio se entrega el lunes 15.**

Referencias

Efron, B. y Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.

Wasserstein, R. L. y Lazar, N. A. (2016). The ASA Statement on p-Values: Context, Process, and Purpose. The American Statistician, 70(2), 129-133.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly.

Datos: Encuesta Origen Destino Santiago 2012 (Sectra).