

Introducción y fundamentos estadísticos

Clase 6 · Regresión logística: ¿sí o no?

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 10 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Avisos del proyecto Capstone

- ▶ **El primer análisis exploratorio se entrega el martes 15 de septiembre por el Aula; el enunciado y la rúbrica están en el repositorio.**
- ▶ Se puede entregar en un repositorio de GitHub, con acceso de lectura para los ayudantes y un PDF con el link subido al Aula.
- ▶ Si el preprocesamiento es extenso, el notebook puede partir de una tabla intermedia, siempre que sea reproducible. Los datos confidenciales se declaran.

Contenidos de la clase


- ▶ 1. Una respuesta que es sí o no: la variable 0/1, Bernoulli y la proporción.
- ▶ 2. Por qué la recta de la clase 4 no sirve para un sí o no.
- ▶ 3. La regresión logística: la recta dentro de una S, y cómo se lee e^b .
- ▶ 4. El mismo summary: coeficientes, error estándar, z y valor p; varias variables y dummies.
- ▶ 5. Clasificar: el umbral, la matriz de confusión, falsos positivos y falsos negativos, y evaluar fuera de la muestra.

La pregunta de la clase: ¿sí o no?

- ▶ **¿Qué clientes de una tarjeta de crédito dejarán de pagar? ¿Qué pasajeros del Titanic sobrevivieron? La respuesta no es un número: es un sí o un no.**
- ▶ La regresión de las clases 4 y 5 explica un número con una recta. Hoy la misma recta explica un sí o no, y para eso hay que pasarla por una curva.
- ▶ El modelo no entrega el sí o el no: entrega una probabilidad. Decidir es cortarla en un umbral, y toda decisión tiene dos formas de equivocarse.
- ▶ Dos ejemplos: 10.000 clientes de tarjeta de crédito (James et al.) y 891 pasajeros del Titanic.

El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros



Después: evaluar fuera de la muestra

Una respuesta que es sí o no

Una respuesta que es sí o no: la variable y vale 1 o 0, y se quiere explicar con una o más x

¿El cliente dejará
de pagar?

y : sí (1) o no (0)

x : deuda en la tarjeta,
ingreso, si estudia

¿El pasajero
sobrevivió?

y : sí (1) o no (0)

x : sexo, clase del
pasaje, edad

¿El correo
es spam?

y : sí (1) o no (0)

x : palabras, adjuntos,
remite

¿El paciente tiene
la enfermedad?

y : sí (1) o no (0)

x : resultado de un
examen, edad

¿El hogar
tiene auto?

y : sí (1) o no (0)

x : ingreso, personas,
sector de la ciudad



los dos ejemplos de hoy

la misma pregunta en otros dominios

En todos los casos la respuesta y vale 1 (sí) o 0 (no), y hay una o más variables x con las que explicarla. Es la misma estructura de la regresión: y a partir de x .

Ejemplo 1: ¿qué clientes dejan de pagar?

Ejemplo 1: 10.000 clientes de tarjeta de crédito; 333 dejaron de pagar (3,3%)




Datos del libro de James et al.: 10.000 clientes, su deuda en la tarjeta (lo que deben después del pago mensual), su ingreso anual y si son estudiantes. Solo 333 dejaron de pagar: el sí es raro, y eso importará al final.

Bernoulli y la proporción

La distribución de un sí o no: la media de una columna de 0 y 1 es la proporción de síes, p

Un cliente: Bernoulli(p), un sí o no con probabilidad p




100 clientes: Binomial($n = 100$, $p = 0,033$), cuántos síes salen



Un cliente es una Bernoulli con probabilidad p de no pagar; la media de la columna de 0 y 1 es la proporción, $p = 0,033$. Contar los síes entre n clientes da la binomial de la clase 5. La logística modela esa p según x .

El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros




Después: evaluar fuera de la muestra


Por qué la recta no sirve

Los mismos datos de dos formas: cada punto gris es un cliente (0 o 1); cada punto azul, la fracción de síes en un tramo de deuda

La recta: probabilidades negativas abajo, y no sigue a los datos arriba




La curva en S: queda entre 0 y 1 y sigue a los datos



Una probabilidad vive entre 0 y 1. La recta da valores negativos con deudas bajas y se queda corta arriba, porque los datos suben en forma de S: casi nadie deja de pagar hasta los 1.500 dólares, y casi todos desde los 2.200.


El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros



Después: evaluar fuera de la muestra

La sigmoide



La sigmoide recibe la recta $z = a + b \cdot x$ y devuelve un número entre 0 y 1. En $z = 0$ vale 0,5; hacia la derecha se acerca a 1 y hacia la izquierda a 0, sin pasarse nunca.

La regresión logística

La regresión logística: la recta $a + b \cdot x$, pasada por la sigmoide

$$P(y = 1 \mid x) = \frac{1}{1 + e^{-(a + b x)}}$$

$$\text{equivalente: } \log \frac{P}{1 - P} = a + b x$$

$P(y = 1 \mid x)$

$a + b \cdot x$

$P / (1 - P)$

log de las chances

e^b

la probabilidad de un sí, dado el valor de x

la misma recta de la regresión lineal


las chances (odds): sí contra no. Con $P = 0,8$, chances 4 a 1

la escala en que la recta es recta: el logit

cuánto se multiplican las chances por cada unidad de x


Las chances (odds) son la razón sí contra no: con $P = 0,8$, cuatro síes por cada no. La recta $a + b \cdot x$ es el logaritmo de las chances, y por eso e^b dice cuánto se multiplican por cada unidad de x .

Cómo se lee b: las chances se multiplican



Con la deuda en cientos de dólares, $b = 0,55$ y $e^b = 1,73$: cada 100 dólares más de deuda multiplican las chances de no pagar por 1,7. En probabilidades: 0,01 con 1.000 dólares, 0,08 con 1.500, 0,59 con 2.000.

Cómo se ajusta: máxima verosimilitud



No hay residuos que minimizar: con un 0/1 no hay distancia vertical que tenga sentido. Se eligen a y b que hacen más probable haber visto exactamente estos síes y noes; statsmodels lo resuelve por iteraciones.

La logística en statsmodels


```
modelo = smf.logit("no_paga ~ deuda_100", data=clientes).fit()

np.exp(modelo.params["deuda_100"])      #  $e^b = 1,73$ 
modelo.predict(nuevos_clientes)         # probabilidades
```

- La misma sintaxis de fórmulas de la clase 5, con logit en lugar de ols. predict entrega probabilidades, no síes y noes. El código completo está en el notebook.

El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros



Después: evaluar fuera de la muestra



El mismo summary, las mismas columnas

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P> z $	[0.025	0.975]
Intercept	10.6513	0.361	29.491	0.000	-11.359	-9.943
deuda_100	0.5499	0.022	24.952	0.000	0.507	0.593

Coeficiente, error estándar, z, valor p e intervalo, como en la clase 5. La única diferencia es z en lugar de t: con 10.000 clientes la referencia es la normal, y $P>|z|$ se lee igual que $P>|t|$.

Varias variables: el caso del estudiante

Ser estudiante y la deuda se confunden: los estudiantes deben más, y la deuda es lo que explica el no pago



Solos, los estudiantes dejan de pagar más (4,3% contra 2,9%). Pero deben más, y a igual deuda dejan de pagar menos. Es la confusión de variables de la clase 4: el coeficiente de una x cambia según qué otras x estén en el modelo.


El summary con varias variables

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P > z $	[0.025	0.975]
Intercept	10.8690	0.492	22.079	0.000	-11.834	-9.904
deuda_100	0.5737	0.023	24.737	0.000	0.528	0.619
ingreso_miles	0.0030	0.008	0.370	0.712	-0.013	0.019
estudiante	-0.6468	0.236	-2.738	0.006	-1.110	-0.184

Estudiante es una dummy, como el modo de la clase 4: $e^{(-0,65)} = 0,52$, a igual deuda e ingreso, las chances de un estudiante son la mitad. El ingreso no aporta ($p = 0,71$): con la deuda en el modelo, no dice nada nuevo.

Ejemplo 2: ¿quién sobrevivió en el Titanic?

Ejemplo 2: 891 pasajeros del Titanic, 38% sobrevivió. Dos variables categóricas y una numérica (la edad)




El 74% de las mujeres sobrevivió contra el 19% de los hombres, y la clase del pasaje ordena a ambos grupos. Dos variables categóricas y la edad: la logística con dummies, otra vez.

El summary del Titanic: cómo leer varios e^b

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P > z $	[0.025	0.975]
Intercept	1.2542	0.360	3.485	0.000	0.549	1.960
sexo[T.mujer]	2.5228	0.207	12.164	0.000	2.116	2.929
C(clase) [T.2]	-1.3098	0.278	-4.710	0.000	-1.855	-0.765
C(clase) [T.3]	-2.5806	0.281	-9.169	0.000	-3.132	-2.029
edad	-0.0370	0.008	-4.831	0.000	-0.052	-0.022

Cada coeficiente compara con una referencia: $e^{2,52} = 12,5$, a igual clase y edad, las chances de una mujer son 12 veces las de un hombre; $e^{-2,58} = 0,08$, la tercera clase tiene el 8% de las chances de la primera; cada año de edad las multiplica por 0,96.


Predecir con varias variables: cuatro perfiles



La recta suma el aporte de cada variable y la sigmoide lo convierte en probabilidad: 0,94 para una mujer de primera clase, 0,08 para un hombre de tercera, ambos de 30 años. Los perfiles del medio quedan cerca de 0,5: ahí el modelo duda.


El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros



Después: evaluar fuera de la muestra

Clasificar: de la probabilidad a la decisión



Un clasificador convierte P en sí o no con un umbral. Con 0,5, el modelo dice "no paga" desde los 1.937 dólares de deuda. A la derecha del corte hay clientes que sí pagan; a la izquierda, clientes que no: los dos errores.

La matriz de confusión

La matriz de confusión: lo real contra lo predicho, umbral 0,5, 10.000 clientes		
	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Lo real en las filas, lo predicho en las columnas. La diagonal son los aciertos; fuera de ella, los dos errores con nombre propio: falso negativo (era sí, dijo no) y falso positivo (era no, dijo sí).

Falso positivo y falso negativo

Los dos errores no cuestan lo mismo, y cuál cuesta más depende del problema, no del modelo

Falso positivo

el modelo dice sí y era no

- banco: le niega la tarjeta a un cliente que sí iba a pagar (pierde un cliente)
- correo: un mensaje real termina en la carpeta de spam
- examen médico: tratar a alguien sano


Falso negativo

el modelo dice no y era sí

- banco: le da la tarjeta a un cliente que no va a pagar (pierde el dinero)
- correo: un spam llega a la bandeja de entrada
- examen médico: no detectar la enfermedad

El modelo no sabe cuál error cuesta más: eso lo pone el problema. Para el banco, un falso negativo es dinero perdido; para un examen médico, una enfermedad sin detectar. El umbral es la forma de elegir cuál error se prefiere.

La exactitud engaña cuando el sí es raro



El modelo acierta el 97,3%, pero decir que nadie deja de pagar acierta el 96,7%. De los 333 clientes que no pagan, detecta 100. Con un sí raro, la exactitud mide sobre todo lo fácil: los noes.

Sensibilidad y especificidad

Tres números de la misma matriz: la sensibilidad mira la fila del sí, la especificidad la fila del no

Umbral 0,5

	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Sensibilidad

de los que eran sí, qué fracción detectó

$$VP / (VP + FN) = 100 / 333 = 0,30$$

Especificidad

de los que eran no, qué fracción dejó en paz

$$VN / (VN + FP) = 9.625 / 9.667 = 0,996$$

Exactitud


de todos, qué fracción acertó

$$(VP + VN) / n = 9.725 / 10.000 = 0,973$$

Sensibilidad: de los que eran sí, qué fracción detectó (0,30). Especificidad: de los que eran no, qué fracción dejó en paz (0,996). Las dos juntas dicen lo que la exactitud esconde.

El umbral es una decisión

El umbral es una decisión: mover 0,5 cambia cuántos falsos negativos y cuántos falsos positivos se aceptan




Cuatro umbrales, en números

umbral	VP	FN	FP	sensib.	especif.	exact.
0,5	100	233	42	0,30	0,996	0,973
0,3	167	166	147	0,50	0,985	0,969
0,2	199	134	263	0,60	0,973	0,960
0,1	244	89	550	0,73	0,943	0,936

Bajar el umbral a 0,2 duplica los clientes detectados (199 de 333) a cambio de 263 falsos positivos. No hay umbral correcto: hay un balance entre los dos errores, y lo fija el costo de cada uno.

Todos los umbrales en una curva: la ROC




Cada punto es un umbral: sensibilidad contra 1 - especificidad. Cuanto más se pega la curva a la esquina superior izquierda, mejor separa el modelo; la diagonal es adivinar al azar.

El Titanic como clasificador

Con un sí frecuente (41%), la exactitud sí dice algo: el modelo gana 20 puntos a la base

Titanic: 714 pasajeros con edad conocida, umbral 0,5

	predicho "sobrevivió"	predicho "murió"
real: sobrevivió	Verdadero positivo 207 el modelo acertó	Falso negativo 83 era sí, el modelo dijo no
real: murió	Falso positivo 68 era no, el modelo dijo sí	Verdadero negativo 356 el modelo acertó




Con un sí frecuente la exactitud sí informa: 79% contra el 59% de decir que todos murieron. Sensibilidad 0,71 y especificidad 0,84: se equivoca más con los que sobrevivieron, hombres jóvenes de tercera clase que el modelo daba por muertos.


Evaluar fuera de la muestra

Un modelo se evalúa con datos que no vio al ajustarse: la medida honesta de cuánto acierta (promedio de 20 repartos)

Separar antes de ajustar



La exactitud que vale es la de los datos de prueba



Medir la exactitud en los mismos datos con que se ajustó el modelo es hacer trampa: el modelo ya los vio. Se separa una parte de prueba antes de ajustar. Con modelos simples como estos las dos cifras se parecen; con modelos más flexibles, la de prueba es la única que vale.

La respuesta a la pregunta de la clase

- ▶ **El modelo no dice quién deja de pagar ni quién sobrevivió: dice con qué probabilidad. Un cliente con 2.000 dólares de deuda tiene 0,59; una mujer de primera clase, 0,94.**
- ▶ El sí o el no lo ponemos nosotros con el umbral, y con él elegimos cuántos falsos positivos y cuántos falsos negativos aceptar.
- ▶ La exactitud sola no basta: hay que mirar los dos errores por separado, y medirlos en datos que el modelo no vio.

Síntesis

- ▶ Un sí o no es una Bernoulli: modelarlo es modelar su probabilidad p según las x .
- ▶ La regresión logística pasa la recta $a + b \cdot x$ por la sigmoide, que la mantiene entre 0 y 1; e^b multiplica las chances por cada unidad de x , y el summary se lee con las columnas de siempre.
- ▶ Clasificar es cortar la probabilidad en un umbral; la matriz de confusión separa los aciertos de los dos errores, que no cuestan lo mismo.
- ▶ Con un sí raro la exactitud engaña; sensibilidad y especificidad no. Y se miden en datos de prueba, no en los de entrenamiento.

Recreo

10 minutos · al volver: manos al teclado, con el notebook

Próxima clase

- ▶ Martes 15: regresión regularizada (Ridge y Lasso), para modelos con muchas variables.
- ▶ Con lo de hoy ya se puede modelar, leer y evaluar una respuesta que es sí o no.
- ▶ **El primer análisis exploratorio se entrega el martes 15.**

Referencias

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). An Introduction to Statistical Learning with Applications in R (2a ed.), capítulo 4 (regresión logística) y sección 5.1 (conjunto de validación). Springer. Disponible en statlearning.com.

Diez, D., Çetinkaya-Rundel, M. y Barr, C. (2019). OpenIntro Statistics (4a ed.), capítulo 9.5 (regresión logística). Disponible en openintro.org.

Datos: Default, del libro de James et al. (statlearning.com); Titanic, del repositorio seaborn-data (github.com/mwaskom/seaborn-data).