

Introducción y fundamentos estadísticos

Clase 6 · Regresión logística: ¿sí o no?

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 10 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Avisos del proyecto Capstone

- ▶ **El primer análisis exploratorio se entrega el martes 15 de septiembre por el Aula; el enunciado y la rúbrica están en el repositorio.**
- ▶ Se puede entregar en un repositorio de GitHub, con acceso de lectura para los ayudantes y un PDF con el link subido al Aula.
- ▶ Si el preprocesamiento es extenso, el notebook puede partir de una tabla intermedia, siempre que sea reproducible. Los datos confidenciales se declaran.

Contenidos de la clase

- ▶ 1. Una respuesta que es sí o no: la variable 0/1, Bernoulli y la proporción.
- ▶ 2. Por qué la recta de la clase 4 no sirve para un sí o no.
- ▶ 3. La regresión logística: la recta dentro de una S, y cómo se lee e^b .
- ▶ 4. El mismo summary: coeficientes, error estándar, z y valor p; varias variables y dummies.
- ▶ 5. Clasificar: el umbral 0,5, la matriz de confusión, falsos positivos y falsos negativos, y evaluar fuera de la muestra.

La pregunta de la clase: ¿sí o no?

- ▶ **¿Qué clientes de una tarjeta de crédito dejarán de pagar? ¿Qué pasajeros del Titanic sobrevivieron? La respuesta no es un número: es un sí o un no.**
- ▶ La regresión de las clases 4 y 5 explica un número con una recta. Hoy la misma recta explica un sí o no, y para eso hay que pasarla por una curva.
- ▶ El modelo no entrega el sí o el no: entrega una probabilidad. Decidir es cortarla en un umbral, y toda decisión tiene dos formas de equivocarse.
- ▶ Dos ejemplos: 10.000 clientes de tarjeta de crédito (James et al.) y 891 pasajeros del Titanic.

El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros

1. Una respuesta
que es sí o no

y vale 0 o 1:
Bernoulli y la
proporción p

2. La recta
no sirve

probabilidades
fuera de $[0, 1]$

3. La logística

la recta dentro
de una S ; e^b
multiplica los odds

4. El mismo
summary

coef, std err, z , p ;
varias x y dummies

5. Clasificar

umbral, matriz de
confusión, falsos
positivos y negativos

Después: evaluar fuera de la muestra

Una respuesta que es sí o no

Una respuesta que es sí o no: la variable y vale 1 o 0, y se quiere explicar con una o más x

¿El cliente dejará
de pagar?

y : sí (1) o no (0)

x : deuda en la tarjeta,
ingreso, si estudia

¿El pasajero
sobrevivió?

y : sí (1) o no (0)

x : sexo, clase del
pasaje, edad

¿El correo
es spam?

y : sí (1) o no (0)

x : palabras, adjuntos,
remite

¿El paciente tiene
la enfermedad?

y : sí (1) o no (0)

x : resultado de un
examen, edad

¿El hogar
tiene auto?

y : sí (1) o no (0)

x : ingreso, personas,
sector de la ciudad

los dos ejemplos de hoy

la misma pregunta en otros dominios

En todos los casos la respuesta y vale 1 (sí) o 0 (no), y hay una o más variables x con las que explicarla. Es la misma estructura de la regresión: y a partir de x .

Los datos: los clientes de la tarjeta



Default (ISLR): 10.000 clientes de tarjeta de crédito, una fila por cliente. Las primeras 6 filas de las 4 columnas

default	student	balance	income
No	No	729,53	44.361,63
No	Yes	817,18	12.106,13
No	No	1.073,55	31.767,14
No	No	529,25	35.704,49
No	No	785,66	38.463,50
No	Yes	919,59	7.491,56

Antes de graficar nada, la tabla. Cada fila es un cliente. default dice si dejó de pagar y student si es estudiante, las dos en Yes o No; balance es la deuda en la tarjeta después del pago mensual e income el ingreso anual, en dólares.

Ejemplo 1: ¿qué clientes dejan de pagar?

Ejemplo 1: 10.000 clientes de tarjeta de crédito; 333 dejaron de pagar (3,3%)



Datos del libro de James et al.: 10.000 clientes, su deuda en la tarjeta (lo que deben después del pago mensual), su ingreso anual y si son estudiantes. Solo 333 dejaron de pagar: el sí es raro, y eso importará al final.

Bernoulli y la proporción

La proporción p : los clientes que dejaron de pagar, sobre el total

La columna no_paga vale 1 (dejó de pagar) o 0 (paga)

clientes: 10.000


con un 1 (dejaron de pagar): 333

proporción $p = 333 / 10.000 = 0,033$

Es la media de la columna de ceros y unos: la fracción de unos.

Un cliente tomado al azar es una Bernoulli(p): no paga con probabilidad $p = 0,033$ y paga con probabilidad $1 - p = 0,967$.


Lo que sigue: que esa p dependa de la deuda de cada cliente.



p es la proporción de unos en la columna: 333 de 10.000, 0,033. Un cliente al azar es una Bernoulli con esa p : la distribución más simple, dos resultados y una probabilidad. La logística modela esa p según la deuda.

El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros



Después: evaluar fuera de la muestra

La probabilidad de no pagar, por tramo de deuda

En cada tramo de deuda, la fracción de clientes que dejó de pagar estima la probabilidad de no pagar

Un tramo es un intervalo de deuda. El tramo 7: de 1.800 a 2.100 dólares

clientes en el tramo: **229**


de ellos, dejaron de pagar: **114**

fracción que no paga = $114 / 229 = 0,50$

Esa fracción es la probabilidad de no pagar de un cliente con esa deuda, estimada con los datos: un punto del gráfico.

Otro tramo, el 4, de 900 a 1.200 dólares: $19 / 2.117 = 0,009$



Y así con los nueve tramos de 300 dólares.



Se agrupan los clientes por tramo de deuda y en cada tramo se cuenta cuántos dejaron de pagar. La fracción es la probabilidad de no pagar de ese tramo, estimada con los datos: casi 0 con deudas bajas, 0,50 entre 1.800 y 2.100 dólares, 1 desde los 2.400. Los nueve puntos tienen forma de S: esa es la curva que hace falta.

Por qué la recta no sirve


Los mismos datos de dos formas: cada punto gris es un cliente (0 o 1); cada punto azul, la fracción que no paga en un tramo de deuda



Nada impide ajustar la recta de la clase 4 con el 0/1 como respuesta, pero una probabilidad vive entre 0 y 1: con deuda 0 la recta da $-0,08$, y a los 2.000 dólares da 0,18 cuando la fracción real es 0,50. Las fracciones suben en forma de S, y la curva de la derecha las sigue: es la regresión logística.

El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros



Después: evaluar fuera de la muestra

De la probabilidad a los odds (chances)

Otra forma de decir la probabilidad: los odds (chances). Con ellas desaparece el techo de 1

Los odds (chances) de un sí: cuántos síes hay por cada no

P = 0,8

8 síes por 2 noes: odds $8 / 2 = 4$ (4 a 1)


P = 0,5

5 síes por 5 noes: odds $5 / 5 = 1$ (1 a 1)

P = 0,2

2 síes por 8 noes: odds $2 / 8 = 0,25$ (1 a 4)

odds = $P / (1 - P)$: la probabilidad del sí dividida por la del no




Los odds (chances) son la probabilidad dicha de otra forma: cuántos síes por cada no. $P = 0,8$ son odds de 4 a 1. Van de 0 a infinito, así que ya no tienen el techo de 1, pero siguen sin poder ser negativas.

De los odds (chances) a su logaritmo

El logaritmo de los odds (chances) puede ser cualquier número, positivo o negativo: aquí sí cabe una recta

Multiplicar los odds por 4 (de 1 a 4) es sumar 1,39 en el logaritmo: el logaritmo convierte multiplicar en sumar



El logaritmo de los odds puede ser cualquier número: negativo si el sí es menos probable que el no, 0 si son igual de probables, positivo si el sí es más probable. En esta escala no hay techo ni piso: aquí sí puede ir una recta.

Despejar P: de la recta a la sigmoide

Recordatorio
 $\text{odds} = P / (1 - P)$

Del modelo a la sigmoide: despejar P en cuatro pasos

1. $\log \frac{P}{1 - P} = z$

el modelo: el log de los odds es la recta, $z = a + b \cdot x$

2. $\frac{P}{1 - P} = e^z$

se deshace el logaritmo con e: los odds son e elevado a la recta

3. $P = e^z (1 - P) \Rightarrow P (1 + e^z) = e^z$ se multiplica por (1 - P) y se juntan los P a la izquierda


4. $P = \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}}$

se despeja P: la sigmoide. Dividir arriba y abajo por e elevado a z da la segunda forma

El modelo dice que el log de los odds es la recta z. Para volver a la probabilidad hay que despejar P, y el resultado es la sigmoide: por eso el exponente es la recta. Es álgebra, no una curva elegida aparte.

La misma relación en tres escalas

La misma relación entre la deuda y el no pago, en tres escalas: la recta vive en la segunda, la S es cómo se ve en la tercera



Con los tramos de la slide 10. En odds, los puntos suben como una exponencial; en log de los odds (chances), siguen una recta, y eso es lo que el modelo supone; y al despejar P como en la slide anterior, la S. La recta y la S son la misma relación vista en dos escalas.

La regresión logística

La regresión logística: la recta $a + b \cdot x$ en la escala del log de los odds (chances); la sigmoide es la misma recta vista en probabilidades

$$\text{el modelo: } \log \frac{P}{1-P} = a + b x$$

$$\text{despejando P: } P(y = 1 | x) = \frac{1}{1 + e^{-(a + b x)}}$$

$P(y = 1 | x)$

$a + b \cdot x$

$P / (1 - P)$

log de los odds

e^b

la probabilidad de un sí, dado el valor de x

la misma recta de la regresión lineal

los odds (chances): sí contra no. Con $P = 0,8$, odds 4 a 1

la escala en que la recta es recta: el logit

cuánto se multiplican los odds (chances) por cada unidad de x

El modelo dice que el log de los odds (chances) es una recta en x . Despejar P de esa ecuación da la sigmoide: por eso el exponente es $a + b \cdot x$, es la misma recta. Y como sumar b en un logaritmo es multiplicar afuera, e^b dice cuánto se multiplican los odds por cada unidad de x .

El modelo ajustado a los clientes

El modelo ajustado a los 10.000 clientes: los mismos símbolos de la slide anterior, con los números del ajuste

$$\log \frac{P}{1-P} = a + b \cdot \text{deuda}_{100}$$

$$\log(P / (1 - P)) = -10,65 + 0,55 \cdot \text{deuda}_{100}$$

$$P(\text{no paga} \mid \text{deuda}) = 1 / (1 + e^{(10,65 - 0,55 \cdot \text{deuda}_{100})})$$

a = -10,65

el log de los odds (chances) de un cliente sin deuda: en probabilidad, 0,00002

b = 0,55

cada 100 dólares más de deuda le suman 0,55 al log de los odds


e^b = 1,73

esos mismos 100 dólares multiplican los odds (chances) por 1,73

Con 2.000 dólares de deuda: $\text{deuda}_{100} = 20$, $z = -10,65 + 0,55 \cdot 20 = 0,35$ y $P = 1 / (1 + e^{(-0,35)}) = 0,59$


La fórmula de la slide anterior con los números del ajuste. a fija el nivel con deuda 0, b dice cuánto sube el log de los odds (chances) por cada 100 dólares, y e^b lo dice como multiplicación.

La sigmoide




La función que apareció al despejar. Recibe la recta $z = a + b \cdot x$, el log de los odds, y devuelve la probabilidad: en $z = 0$ (odds 1 a 1) vale 0,5; hacia la derecha se acerca a 1 y hacia la izquierda a 0, sin pasarse nunca.

Cómo se lee b: los odds (chances) se multiplican



Con la deuda en cientos de dólares, $b = 0,55$ y $e^b = 1,73$: cada 100 dólares más de deuda multiplican los odds (chances) de no pagar por 1,7. En probabilidades: 0,01 con 1.000 dólares, 0,08 con 1.500, 0,59 con 2.000.

Cómo se ajusta: máxima verosimilitud



No hay residuos que minimizar: con un 0/1 no hay distancia vertical que tenga sentido. Se eligen a y b que hacen más probable haber visto exactamente estos síes y noes; statsmodels lo resuelve por iteraciones.

La logística en statsmodels


```
modelo = smf.logit("no_paga ~ deuda_100", data=clientes).fit()

np.exp(modelo.params["deuda_100"])      #  $e^b = 1,73$ 
modelo.predict(nuevos_clientes)         # probabilidades
```

- La misma sintaxis de fórmulas de la clase 5, con logit en lugar de ols. predict entrega probabilidades, no síes y noes. El código completo está en el notebook.

El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros



Después: evaluar fuera de la muestra



El mismo summary, las mismas columnas

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P> z $	[0.025	0.975]
Intercept	-10.6513	0.361	29.491	0.000	-11.359	-9.943
deuda_100	0.5499	0.022	24.952	0.000	0.507	0.593

Coeficiente, error estándar, z, valor p e intervalo, como en la clase 5. La única diferencia es z en lugar de t: con 10.000 clientes la referencia es la normal, y $P>|z|$ se lee igual que $P>|t|$.

Varias variables: el caso del estudiante

Ser estudiante y la deuda se confunden: los estudiantes deben más, y la deuda es lo que explica el no pago



Solos, los estudiantes dejan de pagar más (4,3% contra 2,9%). Pero deben más, y a igual deuda dejan de pagar menos. Es la confusión de variables de la clase 4: el coeficiente de una x cambia según qué otras x estén en el modelo.

El summary solo con estudiante

	coeficiente					
	coef	std err	z	P> z	[0.025	0.975]
Intercept	-3.5041	0.071	-49.554	0.000	-3.643	-3.366
estudiante	0.4049	0.115	3.520	0.000	0.179	0.630

Con una sola x, el modelo confirma las barras de la slide anterior: el coeficiente de estudiante es positivo, 0,40, y $e^{0,40} = 1,50$. Los odds (chances) de no pagar de un estudiante son 1,5 veces las de un no estudiante.

El summary con estudiante y deuda

	coeficiente					
	coef	std err	z	P> z	[0.025	0.975]
Intercept	-10.7495	0.369	-29.115	0.000	-11.473	-10.026
deuda_100	0.5738	0.023	24.748	0.000	0.528	0.619
estudiante	-0.7149	0.148	-4.846	0.000	-1.004	-0.426

Se agrega la deuda y el coeficiente de estudiante se da vuelta: pasa de 0,40 a -0,71, y $e^{(-0,71)} = 0,49$. A igual deuda, los odds (chances) de no pagar de un estudiante son la mitad. Ahí está la confusión de la slide anterior.

El summary con varias variables

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P > z $	[0.025	0.975]
Intercept	-10.8690	0.492	-22.079	0.000	-11.834	-9.904
deuda_100	0.5737	0.023	24.737	0.000	0.528	0.619
ingreso_miles	0.0030	0.008	0.370	0.712	-0.013	0.019
estudiante	-0.6468	0.236	-2.738	0.006	-1.110	-0.184

Estudiante es una dummy, como el modo de la clase 4: $e^{(-0,65)} = 0,52$, a igual deuda e ingreso, los odds de un estudiante son la mitad. El ingreso no aporta ($p = 0,71$), pero no por la deuda: el ingreso y ser estudiante van juntos, 18 mil dólares contra 40 mil, así que con estudiante adentro el ingreso no dice nada nuevo.

El modelo final, escrito: los clientes

Ejemplo 1, el modelo final escrito: la recta en log de los odds, y la sigmoide para volver a la probabilidad

$$\log \frac{P}{1-P} = a + b_1 \cdot \text{deuda}_{100} + b_2 \cdot \text{estudiante} + b_3 \cdot \text{ingreso}_{\text{miles}}$$

$$z = -10,87 + 0,57 \cdot \text{deuda}_{100} - 0,65 \cdot \text{estudiante} + 0,003 \cdot \text{ingreso}$$

$$P = \frac{1}{1 + e^{-z}} \quad \text{con } z \text{ la recta de arriba}$$

Un estudiante con 2.000 dólares de deuda y 20 mil dólares de ingreso: $\text{deuda}_{100} = 20$, $\text{estudiante} = 1$, $\text{ingreso} = 20$

$$z = -10,87 + 0,57 \cdot 20 - 0,65 \cdot 1 + 0,003 \cdot 20 = 0,02$$

$$P(\text{no paga}) = 1 / (1 + e^{(-0,02)}) = 0,50$$

Los coeficientes del summary puestos en la recta. Para un cliente concreto se reemplazan sus valores, sale z, y la sigmoide lo convierte en probabilidad. Es lo que hace predict.

Los datos: los pasajeros del Titanic


Titanic: 891 pasajeros, una fila por pasajero. Las primeras 6 filas de las 4 columnas que usa el modelo, de las 15 del archivo

survived	pclass	sex	age
0	3	male	22,0
1	1	female	38,0
1	3	female	26,0
1	1	female	35,0
0	3	male	35,0
0	3	male	NaN

El segundo dataset, con la misma mirada previa. survived vale 1 si el pasajero sobrevivió, pclass es la clase del pasaje (1, 2 o 3) y sex el sexo. La edad falta en 177 pasajeros, y el modelo usa los 714 que sí la tienen.

Ejemplo 2: ¿quién sobrevivió en el Titanic?

Ejemplo 2: 891 pasajeros del Titanic, 38% sobrevivió. Dos variables categóricas y una numérica (la edad)



El 74% de las mujeres sobrevivió contra el 19% de los hombres, y la clase del pasaje ordena a ambos grupos. Dos variables categóricas y la edad: la logística con dummies, otra vez.

El summary del Titanic: cómo leer varios e^b

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P > z $	[0.025	0.975]
Intercept	1.2542	0.360	3.485	0.000	0.549	1.960
sexo[T.mujer]	2.5228	0.207	12.164	0.000	2.116	2.929
C(clase)[T.2]	-1.3098	0.278	-4.710	0.000	-1.855	-0.765
C(clase)[T.3]	-2.5806	0.281	-9.169	0.000	-3.132	-2.029
edad	-0.0370	0.008	-4.831	0.000	-0.052	-0.022

Cada coeficiente compara con una referencia: $e^{2,52} = 12,5$, a igual clase y edad, los odds de una mujer son 12 veces las de un hombre; $e^{(-2,58)} = 0,08$, la tercera clase tiene el 8% de los odds de la primera; cada año de edad las multiplica por 0,96.

El modelo final, escrito: el Titanic

Ejemplo 2, el modelo final escrito: las categóricas entran como dummies, con hombre y primera clase como referencia

$$\log \frac{P}{1-P} = a + b_1 \cdot \text{mujer} + b_2 \cdot \text{clase2} + b_3 \cdot \text{clase3} + b_4 \cdot \text{edad}$$

$$z = 1,25 + 2,52 \cdot \text{mujer} - 1,31 \cdot \text{clase2} - 2,58 \cdot \text{clase3} - 0,037 \cdot \text{edad}$$

$$P = \frac{1}{1 + e^{-z}} \quad \text{con } z \text{ la recta de arriba}$$


Una mujer de primera clase de 30 años: mujer = 1, clase2 = 0, clase3 = 0, edad = 30

$z = 1,25 + 2,52 - 0,037 \cdot 30 = 2,67$ Un hombre de tercera de 30 años: $z = 1,25 - 2,58 - 0,037 \cdot 30 = -2,44$

P(sobrevive) = 0,94 para ella, 0,08 para él

Cada categórica aporta una dummy por categoría, menos la de referencia: mujer (contra hombre), clase2 y clase3 (contra primera). Un pasajero de la referencia solo lleva a y la edad.


Predecir con varias variables: cuatro perfiles



La recta suma el aporte de cada variable y la sigmoide lo convierte en probabilidad: 0,94 para una mujer de primera clase, 0,08 para un hombre de tercera, ambos de 30 años. Los perfiles del medio quedan cerca de 0,5: ahí el modelo duda.


El mapa de la clase

El modelo no predice el sí o el no: predice una probabilidad. La decisión, y sus dos errores, la ponemos nosotros



Después: evaluar fuera de la muestra

Clasificar: de la probabilidad a la decisión



Un clasificador convierte P en sí o no con un umbral. Con 0,5, el modelo dice "no paga" desde los 1.937 dólares de deuda. A la derecha del corte hay clientes que sí pagan; a la izquierda, clientes que no: los dos errores.

La matriz de confusión

La matriz de confusión: lo real contra lo predicho, umbral 0,5, 10.000 clientes

	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Lo real en las filas, lo predicho en las columnas. La diagonal son los aciertos; fuera de ella, los dos errores con nombre propio: falso negativo (era sí, dijo no) y falso positivo (era no, dijo sí). De 333 clientes que no pagan, el modelo detecta 100.

Falso positivo y falso negativo

Los dos errores no cuestan lo mismo, y cuál cuesta más depende del problema, no del modelo

Falso positivo

el modelo dice sí y era no

- banco: le niega la tarjeta a un cliente que sí iba a pagar (pierde un cliente)
- correo: un mensaje real termina en la carpeta de spam
- examen médico: tratar a alguien sano

Falso negativo

el modelo dice no y era sí

- banco: le da la tarjeta a un cliente que no va a pagar (pierde el dinero)
- correo: un spam llega a la bandeja de entrada
- examen médico: no detectar la enfermedad

El modelo no sabe cuál error cuesta más: eso lo pone el problema. Para el banco, un falso negativo es dinero perdido; para un examen médico, una enfermedad sin detectar. Cómo elegir el umbral según ese costo queda para la próxima clase.

La exactitud: qué fracción acertó

La exactitud (accuracy): de todas las predicciones, qué fracción acertó, y la base con la que hay que compararla

La matriz de la slide anterior, umbral 0,5

	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Exactitud: la fracción de clientes en que el modelo acertó

aciertos: la diagonal de la matriz

$$\text{verdaderos positivos} + \text{verdaderos negativos} = 100 + 9.625 = 9.725$$

$$\text{exactitud} = 9.725 / 10.000 = 0,973$$

Sin modelo, decir que todos pagan también es un clasificador.

Su exactitud es la fracción de clientes que de verdad pagan:



$$\text{base} = 9.667 / 10.000 = 0,967$$

La siguiente slide compara los dos números.

La medida más obvia de un clasificador: los aciertos, la diagonal de la matriz, divididos por el total. 0,973 parece muy bueno. Pero cualquier exactitud hay que compararla con la de no tener modelo: predecir siempre la clase más frecuente, aquí "paga".

La exactitud engaña cuando el sí es raro

Cuando el sí es raro (3,3%), la exactitud es alta hasta sin modelo: hay que mirar los dos errores por separado




El modelo acierta el 97,3% y decir que nadie deja de pagar acierta el 96,7%, que es $1 - 0,033$: uno menos la proporción que no paga, la p de la slide 9. De los 333 clientes que no pagan, el modelo detecta 100. Con un sí raro, la exactitud mide sobre todo lo fácil: los noes.

El Titanic como clasificador

Con un sí frecuente (41%), la exactitud sí dice algo: el modelo gana 20 puntos a la base

Titanic: 714 pasajeros con edad conocida, umbral 0,5

	predicho "sobrevivió"	predicho "murió"
real: sobrevivió	Verdadero positivo 207 el modelo acertó	Falso negativo 83 era sí, el modelo dijo no
real: murió	Falso positivo 68 era no, el modelo dijo sí	Verdadero negativo 356 el modelo acertó




Con un sí frecuente la exactitud sí informa: 79% contra el 59% de decir que todos murieron. Los errores: 83 falsos negativos, pasajeros que sobrevivieron y el modelo daba por muertos, y 68 falsos positivos.

Evaluar fuera de la muestra


Un modelo se evalúa con datos que no vio al ajustarse: la medida honesta de cuánto acierta (promedio de 20 repartos)

Separar antes de ajustar



se reparten al azar, una sola vez

La exactitud que vale es la de los datos de prueba



Medir la exactitud en los mismos datos con que se ajustó el modelo es hacer trampa: el modelo ya los vio. Se separa una parte de prueba antes de ajustar. Con modelos simples como estos las dos cifras se parecen; con modelos más flexibles, la de prueba es la única que vale.

La respuesta a la pregunta de la clase

- ▶ **El modelo no dice quién deja de pagar ni quién sobrevivió: dice con qué probabilidad. Un cliente con 2.000 dólares de deuda tiene 0,59; una mujer de primera clase, 0,94.**
- ▶ El sí o el no lo ponemos nosotros con el umbral, y cada umbral deja una cantidad de falsos positivos y de falsos negativos. Cómo elegirlo según el costo de cada error queda para la próxima clase.
- ▶ La exactitud sola no basta: hay que mirar los dos errores por separado, y medirlos en datos que el modelo no vio.

Síntesis

- ▶ Un sí o no es una Bernoulli: modelarlo es modelar su probabilidad p según las x .
- ▶ La regresión logística pasa la recta $a + b \cdot x$ por la sigmoide, que la mantiene entre 0 y 1; e^b multiplica los odds por cada unidad de x , y el summary se lee con las columnas de siempre.
- ▶ Clasificar es cortar la probabilidad en un umbral; la matriz de confusión separa los aciertos de los dos errores, que no cuestan lo mismo.
- ▶ Con un sí raro la exactitud engaña: hay que contar los falsos negativos y los falsos positivos. Y todo se mide en datos de prueba, no en los de entrenamiento.

Recreo

10 minutos · al volver: manos al teclado, con el notebook

Próxima clase

- ▶ Martes 15: sensibilidad y especificidad, cómo elegir el umbral según el costo de cada error y la curva ROC; después, regresión regularizada (Ridge y Lasso).
- ▶ Con lo de hoy ya se puede modelar, leer y evaluar una respuesta que es sí o no.
- ▶ **El primer análisis exploratorio se entrega el martes 15.**

Referencias

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). An Introduction to Statistical Learning with Applications in R (2a ed.), capítulo 4 (regresión logística) y sección 5.1 (conjunto de validación). Springer. Disponible en statlearning.com.

Diez, D., Çetinkaya-Rundel, M. y Barr, C. (2019). OpenIntro Statistics (4a ed.), capítulo 9.5 (regresión logística). Disponible en openintro.org.

Datos: Default, del libro de James et al. (statlearning.com); Titanic, del repositorio seaborn-data (github.com/mwaskom/seaborn-data).