

Introducción y fundamentos estadísticos

Clase 6 · Regresión y logística

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · jueves 10 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA


Contenidos de la clase

- ▶ 1. Lo que ya sabemos leer del summary (repaso de la clase 5).
- ▶ 2. Diagnósticos con los residuos (pendiente).
- ▶ 3. Evaluar un modelo fuera de la muestra (pendiente).
- ▶ 4. Otro modelo, el mismo lector: regresión logística para un sí o no.

Otro modelo, el mismo lector


¿Qué hogares tienen auto? Explicar un sí o no con el ingreso del hogar: la regresión logística, y con ella, clasificar

La distribución de un sí o no: Bernoulli y binomial



Tener auto es un sí o no con probabilidad p : una Bernoulli. Contar los síes en n intentos da la binomial, y cada barra sale de su fórmula. La logística modela esa p según el ingreso.

La recta no sirve para un sí o no



Sobre un 0/1, la recta predice 1,39 a los 5 millones y valores negativos abajo: no respeta que la respuesta vive entre 0 y 1. La logística pasa la recta por una S y queda siempre en el rango.

La regresión logística

La probabilidad de un sí, como función de x: la sigmoide

$$P(y = 1 \mid x) = \frac{1}{1 + e^{-(a + bx)}}$$

$P(y = 1 \mid x)$: la probabilidad de un sí dado x · $a + bx$: la misma recta de siempre, en escala de log-chances

e^b : cuánto se multiplican las chances (sí contra no) por cada unidad de x

La misma recta $a + b \cdot x$, pero dentro de la sigmoide. La respuesta es una Bernoulli (la binomial con $n = 1$) cuya probabilidad depende de x .

La logística en statsmodels

```
logistica = sm.GLM(h["tiene_auto"], sm.add_constant(ingreso),  
                  family=sm.families.Binomial(),  
                  freq_weights=h["Factor"]).fit()  
  
np.exp(logistica.params["IngresoHogar"])    # 8.9
```


- GLM con familia binomial, ponderado con el factor. Lectura multiplicativa, como el log de la clase 4: cada millón multiplica las chances de tener auto por 8,9.

El mismo summary, las mismas columnas

	coeficiente	error estándar	$z = \text{coef} / \text{EE}$	valor p	intervalo del 95%	
	coef	std err	z	$P > z $	[0.025	0.975]
const	-1.8691	0.003	-620.273	0.000	-1.875	-1.863
IngresoHogar	2.1809	0.004	541.553	0.000	2.173	2.189

Las mismas columnas: z es el t cuando la referencia es la normal en vez de la t de Student (con n grande, lo mismo), y $P > |z|$ su valor p. Letra chica: el error estándar es minúsculo porque `freq_weights` cuenta cada hogar tantas veces como su factor; los coeficientes están bien, ese z no.

Clasificar: de la probabilidad a la decisión



Predecir "tiene auto" cuando P supera 0,5 (desde 0,86 millones). Acierta el 70%, contra el 61% de decir siempre "no": la comparación con la base es obligatoria. Dónde se equivoca lo dice la matriz de confusión (un crosstab).

Síntesis

- ▶ Para un sí o no, la regresión logística: la recta $a + b \cdot x$ dentro de una sigmoide, y el coeficiente se lee multiplicando las chances.
- ▶ El summary se lee con las mismas columnas: coef, std err, z y $P > |z|$.
- ▶ Clasificar es cortar la probabilidad en un umbral y comparar la exactitud con la de predecir siempre la clase mayoritaria.

Referencias

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2021). An Introduction to Statistical Learning (2a ed.), capítulo 4. Springer.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly.

Datos: Encuesta Origen Destino Santiago 2012 (Sectra).