

Introducción y fundamentos estadísticos

Clase 7 · Evaluar y regularizar modelos

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 15 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Avisos del proyecto Capstone

- ▶ **Hoy, martes 15 de septiembre, se entrega el primer análisis exploratorio por el Aula.**
- ▶ Informe de avance, la última evaluación: presentación oral el martes 22 en la clase 8 (máximo 10 minutos por equipo) e informe escrito el viernes 25 (máximo 7 páginas). Oral y escrito pesan 50% cada uno; el enunciado está en el repositorio.
- ▶ El informe de avance debe incluir un modelo ajustado a los datos del proyecto: uno de los vistos en clases u otro que el equipo ya maneje.
- ▶ El jueves 17 no hay clases.

Contenidos de la clase


- ▶ 1. Medir los dos errores de un clasificador: sensibilidad, especificidad y precisión.
- ▶ 2. Elegir el umbral según el costo de cada error.
- ▶ 3. Comparar clasificadores: la curva ROC y el AUC.
- ▶ 4. Muchas variables: el error en datos de prueba y el sobreajuste.
- ▶ 5. Regularizar: Ridge y Lasso, y cómo elegir λ con validación cruzada.

¿Cuánto cuesta equivocarse?

- ▶ **La clase 6 dejó dos preguntas abiertas: si con un sí raro la exactitud engaña, ¿qué se mide? Y el umbral 0,5, ¿por qué 0,5?**
- ▶ La primera mitad las responde: medidas que miran cada error por separado, y un umbral que sale del costo de cada error.
- ▶ La segunda mitad vuelve a la regresión: con muchas variables, el modelo se ajusta al azar de su muestra y se equivoca más en datos nuevos. Regularizar lo corrige.
- ▶ El hilo de las dos: un modelo se juzga por sus errores donde importan, con el costo correcto y en datos que no vio.

El mapa de la clase

Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio



clasificar: los clientes de la tarjeta

regresión: los salarios de béisbol

Recordatorio: la matriz de confusión

La matriz de confusión de la clase 6: umbral 0,5, 10.000 clientes		
	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Lo real en las filas, lo predicho en las columnas. Con umbral 0,5 el modelo acierta el 97,3%, pero decir que todos pagan acierta el 96,7%: la exactitud mezcla los dos errores. Hoy se miran por separado.

Sensibilidad: ¿cuántos morosos detecta?

	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Sensibilidad

De los clientes que no pagan, ¿qué fracción detecta?

Se mira la fila de los que no pagan (en inglés, recall).

$$\text{sensibilidad} = \text{VP} / (\text{VP} + \text{FN})$$

$$= 100 / (100 + 233) = 100 / 333 = 0,30$$

El modelo detecta 3 de cada 10 clientes que no pagan; se le escapan 7.

Mira solo a los clientes que no pagan. Es la medida que importa cuando dejar pasar un sí es caro: un moroso sin detectar, una enfermedad sin diagnosticar.

Especificidad: ¿a cuántos deja en paz?

	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Especificidad

De los clientes que pagan, ¿qué fracción deja en paz?

Se mira la fila de los que pagan.

$$\text{especificidad} = \text{VN} / (\text{VN} + \text{FP})$$

$$= 9.625 / (9.625 + 42) = 0,996$$

El modelo casi no molesta a los que pagan:
de cada 1.000, a 996 no los declara morosos.

Mira solo a los clientes que pagan. Importa cuando molestar a un no es caro: negarle la tarjeta a un buen cliente, alarmar a un paciente sano.

Precisión: de los que marca, ¿cuántos lo son?

	predicho "no paga"	predicho "paga"
real: no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no
real: paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó

Precisión

De los clientes que declara morosos, ¿qué fracción lo es?

Se mira la columna del predicho "no paga" (en inglés, precision).

precisión = $VP / (VP + FP)$

= $100 / (100 + 42) = 100 / 142 = 0,70$

De cada 10 clientes que el modelo declara morosos, 7 lo son de verdad.

Mira solo a los clientes que el modelo declara morosos. Importa cuando actuar sobre cada sí cuesta: en el libro, una aseguradora que llama solo a los clientes que el modelo marca logra que compre el 33% de los llamados, contra el 6% llamando al azar (James et al., pp. 165 a 167).


Cuatro medidas, una sola matriz

medida	la pregunta que responde	fórmula	qué parte mira	umbral 0,5
Exactitud (accuracy)	De todos, ¿qué fracción acertó?	$(VP + VN) / \text{total}$	toda la matriz	0,973
Sensibilidad (recall)	De los que no pagan, ¿qué fracción detecta?	$VP / (VP + FN)$	la fila del sí	0,30
Especificidad	De los que pagan, ¿qué fracción deja en paz?	$VN / (VN + FP)$	la fila del no	0,996
Precisión (precision)	De los que declara morosos, ¿qué fracción lo es?	$VP / (VP + FP)$	la columna del sí	0,70

Todas salen de contar las celdas de la matriz. La exactitud mira todo junto; las otras tres miran un error por vez, y por eso no engañan cuando el sí es raro.

El mapa de la clase

Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio



clasificar: los clientes de la tarjeta

regresión: los salarios de béisbol

Mover el umbral cambia los errores


Bajar el umbral a 0,2: el modelo detecta 99 clientes más que no pagan, a cambio de 221 falsos positivos más

Umbral 0,5				Umbral 0,2			
		predicho "no paga"	predicho "paga"			predicho "no paga"	predicho "paga"
real:	no paga	Verdadero positivo 100 el modelo acertó	Falso negativo 233 era sí, el modelo dijo no	real:	no paga	Verdadero positivo 199 el modelo acertó	Falso negativo 134 era sí, el modelo dijo no
	paga	Falso positivo 42 era no, el modelo dijo sí	Verdadero negativo 9.625 el modelo acertó		paga	Falso positivo 263 era no, el modelo dijo sí	Verdadero negativo 9.404 el modelo acertó
sensibilidad 0,30 · especificidad 0,996				sensibilidad 0,60 · especificidad 0,973			

El modelo es el mismo: solo cambia desde qué probabilidad se dice "no paga". Con 0,2 se detectan 199 morosos en vez de 100, y se molesta a 263 buenos clientes en vez de 42.

Sensibilidad y especificidad según el umbral

Bajar el umbral sube la sensibilidad y baja la especificidad: no se pueden subir las dos a la vez



umbral	VP	FN	FP	sensib.	especif.
0,5	100	233	42	0,30	0,996
0,3	167	166	147	0,50	0,985
0,2	199	134	263	0,60	0,973
0,1	244	89	550	0,73	0,943

Cada umbral es un balance entre los dos errores. ¿Cuál elegir? Depende de cuánto cuesta cada error, y eso no lo dice el modelo: lo dice el problema.

El costo de cada error

Con esos costos, el umbral 0,5 no es el mejor: el costo total es mínimo con un umbral mucho más bajo


Supuesto: los dos errores no cuestan lo mismo

falso negativo (darle la tarjeta a quien no paga): cuesta 10

falso positivo (negársela a quien sí paga): cuesta 1

costo total = $10 \cdot FN + 1 \cdot FP$

umbral	$10 \cdot FN + FP$	costo total
0,50	$10 \cdot 233 + 42$	2.372
0,30	$10 \cdot 166 + 147$	1.807
0,20	$10 \cdot 134 + 263$	1.603
0,10	$10 \cdot 89 + 550$	1.440
0,08	$10 \cdot 72 + 673$	1.393




Si dejar pasar a un moroso cuesta 10 veces lo que cuesta rechazar a un buen cliente, el costo total baja de 2.372 con umbral 0,5 a 1.393 con umbral 0,08. Los costos son un supuesto: en un proyecto real los define el problema.

De dónde sale el umbral

El umbral según los costos
 $FP / (FP + FN)$


Conviene rechazar cuando el costo esperado de aprobar supera al de rechazar: umbral = costo FP / (costo FP + costo FN)




Aprobar a un cliente con probabilidad P de no pagar cuesta, en promedio, $P \cdot 10$; rechazarlo cuesta $(1 - P) \cdot 1$. Conviene rechazar cuando $P \cdot 10 > 1 - P$, es decir, desde $P = 1/11 = 0,09$. Con costos iguales la regla da 0,5: por eso es el umbral por defecto.

El mapa de la clase

Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio





La curva ROC: todos los umbrales a la vez



Cada punto es un umbral. Bajarlo mueve el punto hacia arriba y a la derecha: más morosos detectados y más buenos clientes molestados. La diagonal es adivinar al azar; cuanto más se acerca la curva a la esquina superior izquierda, mejor separa el modelo.

El AUC: comparar modelos sin elegir umbral


El área bajo la curva ROC (AUC) resume todos los umbrales en un número: 1 separa perfecto, 0,5 es adivinar



Si se toma al azar un cliente que no paga y uno que paga, el modelo de la deuda le da más probabilidad al que no paga en el 95% de los pares: eso es su AUC. El modelo solo con estudiante acierta en el 54%, casi como adivinar.

El mapa de la clase

Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio



clasificar: los clientes de la tarjeta

regresión: los salarios de béisbol

Otro problema: el salario de jugadores de béisbol

Ejemplo: el salario de jugadores de béisbol de las grandes ligas, en miles de dólares de 1987 (James et al., laboratorio 6.6)

jugador	salario	temporadas	turnos	hits	jonrones	turnos_carrera	hits_carrera	division_oeste
1	475,0	14	315	81	7	3.449	835	1
2	480,0	3	479	130	18	1.624	457	1
3	500,0	11	496	141	20	5.628	1.575	0
4	91,5	2	321	87	10	396	101	0
5	750,0	11	594	169	4	4.408	1.133	1

263 jugadores y 19 variables (la tabla muestra 7):

de la temporada 1986: turnos al bate, hits, jonrones, carreras anotadas e impulsadas, bases por bolas, outs en defensa, asistencias, errores

de toda la carrera: temporadas y los mismos totales acumulados · categóricas: liga, división y liga en 1987

Datos del laboratorio de Ridge y Lasso del libro: 263 jugadores con salario conocido y 19 variables de su temporada 1986 y de toda su carrera. La respuesta es un número, así que volvemos a la regresión lineal.

El error de una regresión: el RMSE

Medir el error de una regresión en datos de prueba: el RMSE, en miles de dólares

jugador	salario real	predicho	residuo	residuo ²
1	500	620	-120	14.297
2	700	315	385	148.125
3	700	753	-53	2.780
4	210	492	-282	79.370
5	105	341	-236	55.753

cinco jugadores de prueba, con el modelo de mínimos cuadrados

RMSE: raíz del error cuadrático medio

1. promedio de los residuos al cuadrado

= 60.065

2. su raíz, para volver a miles de dólares

RMSE = $\sqrt{60.065}$ = 245

Con los 132 jugadores de prueba: RMSE = 342

Sin modelo, prediciendo el salario medio: 416


Es el tamaño típico del error, en las unidades de y.

Como en la clase 6, los datos se separan en 131 jugadores de entrenamiento y 132 de prueba. El RMSE es la raíz del promedio de los residuos al cuadrado: el tamaño típico del error, en miles de dólares.


Mínimos cuadrados con 19 variables

Mínimos cuadrados con las 19 variables: se ajusta al azar de sus 131 jugadores

Dos variables que dicen lo mismo (correlación 0,995), con coeficientes enormes y opuestos




Error en entrenamiento y en prueba



Turnos al bate y hits de la carrera dicen casi lo mismo, y mínimos cuadrados les da coeficientes enormes de signo opuesto que se cancelan. El modelo se ajusta al azar de sus 131 jugadores: se equivoca en 301 con ellos y en 342 con los que no vio.

Con otra muestra, otros coeficientes


Un punto por reparto: con 20 grupos distintos de 131 jugadores, mínimos cuadrados cambia hasta de signo; Ridge casi no se mueve



Cada punto es un reparto distinto en entrenamiento y prueba. Con mínimos cuadrados, el coeficiente de turnos al bate de la carrera va de -1.400 a 627; con Ridge, de 15 a 36. Es la idea de la clase 5: todo número que sale de una muestra se mueve, y aquí se mueve demasiado.

El mapa de la clase

Un modelo se juzga por sus errores donde importan: con el costo correcto y en datos que no vio



clasificar: los clientes de la tarjeta

regresión: los salarios de béisbol

Regularizar: castigar los coeficientes grandes

Regularizar: al error del modelo se le suma un castigo por tener coeficientes grandes

Mínimos cuadrados (clase 4):

$$\text{minimizar } \sum_i (y_i - \hat{y}_i)^2$$

Ridge:

$$\text{minimizar } \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j b_j^2$$

Lasso:

$$\text{minimizar } \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j |b_j|$$

$$\sum_i (y_i - \hat{y}_i)^2$$

$$b_j$$

λ (lambda)

$$\lambda = 0$$

λ muy grande

la suma de los residuos al cuadrado: qué tan bien se ajusta el modelo

el coeficiente de la variable j (el intercepto no se penaliza)

cuánto pesa la penalización; en scikit-learn se llama alpha

no hay penalización: es mínimos cuadrados

todos los coeficientes van a 0 y el modelo predice el promedio

Mínimos cuadrados solo busca ajustar bien. Ridge y Lasso buscan ajustar bien y, a la vez, tener coeficientes chicos. λ decide cuánto pesa cada cosa.

Antes de penalizar, estandarizar

Antes de penalizar: estandarizar, para que todas las variables estén en la misma escala

jugador	temporadas	turnos carrera	temporadas (z)	turnos carrera (z)
1	17	4.061	2,01	0,62
2	11	5.562	0,75	1,27
3	5	2.364	-0,50	-0,11
media	7,4	2.625	0	0
desv. estándar	4,8	2.313	1	1

$$z = \frac{x - \text{media}}{\text{desviación estándar}}$$


Sin estandarizar, una temporada y un turno al bate no son comparables, y la penalización castigaría distinto a variables en escalas distintas.

Después, todas las variables tienen media 0 y desviación 1, y cada coeficiente se lee como cuánto cambia y por una desviación estándar de x .

La media y la desviación se calculan con los datos de entrenamiento, y se aplican también a los de prueba.


La penalización suma coeficientes de variables distintas, así que tienen que estar en la misma escala. La media y la desviación se calculan con el entrenamiento y se aplican también a la prueba.

Ridge: todos los coeficientes se achican




A la izquierda, los coeficientes de mínimos cuadrados, con los opuestos de -1.400 y 1.427. Al subir λ se achican y se juntan: Ridge reparte el peso entre variables que dicen lo mismo. Ninguno llega exactamente a 0.

El error de Ridge según λ



El error en entrenamiento solo sube con λ : penalizar empeora el ajuste. El de prueba baja de 342 a 316 y después sube. El λ no se elige mirando la prueba, sino con validación cruzada.

Lasso: los coeficientes se apagan de a uno



Lasso castiga el valor absoluto de los coeficientes, y eso lleva a algunos exactamente a 0: el modelo elige variables. Con el λ elegido quedan 7 de las 19, como en el libro.

Cómo elegir λ : validación cruzada


Elegir λ con validación cruzada: sin tocar los datos de prueba

Cinco partes: cada una valida una vez

vuelta 1	valida	ajusta	ajusta	ajusta	ajusta
vuelta 2	ajusta	valida	ajusta	ajusta	ajusta
vuelta 3	ajusta	ajusta	valida	ajusta	ajusta
vuelta 4	ajusta	ajusta	ajusta	valida	ajusta
vuelta 5	ajusta	ajusta	ajusta	ajusta	valida


solo con los 131 jugadores de entrenamiento

Se prueba cada λ y se elige el de menor error



El entrenamiento se divide en cinco partes. Para cada λ se ajusta con cuatro y se mide el error en la quinta, cinco veces, y se promedia. Se elige el λ con menor error promedio; la prueba queda intacta para la medición final.

El resultado en datos que no vio



En este reparto, Ridge baja el error de 342 a 316, y Lasso a 325 usando solo 7 variables. En 20 repartos distintos, cada uno le gana a mínimos cuadrados en 17: no es suerte de un reparto.

Ridge y Lasso en scikit-learn

```
escala = StandardScaler().fit(X_ent)
Z_ent = escala.transform(X_ent)
Z_pru = escala.transform(X_pru)
lasso = LassoCV(cv=5).fit(Z_ent, y_ent)
lasso.predict(Z_pru)
```

- LassoCV elige λ con validación cruzada; Ridge es igual, con RidgeCV. scikit-learn llama alpha a λ .

¿Ridge o Lasso?

- ▶ **Ninguno es mejor en todos los casos (James et al., p. 224).**
- ▶ Lasso, si se sospecha que pocas variables importan: deja un modelo más simple, que se puede explicar.
- ▶ Ridge, si muchas variables aportan un poco o dicen casi lo mismo: estabiliza sus coeficientes sin descartar ninguna.
- ▶ En los dos, λ se elige con validación cruzada y el error se mide en prueba.
- ▶ La logística se regulariza igual; scikit-learn lo hace por defecto, y por eso sus coeficientes no coinciden con los de statsmodels.

La respuesta a la pregunta de la clase

- ▶ **Equivocarse cuesta distinto según el error y según dónde se mida.**
- ▶ En un clasificador, la matriz separa los dos errores; sensibilidad, especificidad y precisión miden cada uno, y el umbral se elige con el costo de cada error, no por defecto en 0,5.
- ▶ En una regresión con muchas variables, el error que vale es el de prueba: mínimos cuadrados se ajusta al azar de su muestra, y Ridge o Lasso lo corrigen castigando los coeficientes grandes, con λ elegido por validación cruzada.

Síntesis

- ▶ Sensibilidad, especificidad y precisión miden un error por vez; la exactitud los mezcla.
- ▶ El umbral de menor costo es $\text{costo FP} / (\text{costo FP} + \text{costo FN})$; con costos iguales, 0,5.
- ▶ La curva ROC muestra todos los umbrales y el AUC la resume para comparar modelos.
- ▶ Con muchas variables, un mejor ajuste en entrenamiento puede ser más error en prueba.
- ▶ Ridge achica y estabiliza todos los coeficientes; Lasso lleva algunos a 0 y elige variables; λ se elige con validación cruzada.

Recreo

10 minutos · al volver: manos al teclado, con el notebook

Próxima clase

- ▶ El jueves 17 no hay clases.
- ▶ Martes 22, la última clase del módulo: reducción de dimensionalidad (PCA) y las presentaciones orales del avance de cada equipo.
- ▶ **Hoy se entrega el análisis exploratorio; el informe de avance, el viernes 25.**

Referencias

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer. Pp. 145 a 149 (sensibilidad, especificidad y curva ROC, con los datos Default); pp. 165 a 167 (precisión, con los datos Caravan); sección 5.1.3, p. 181 (validación cruzada); sección 6.2, pp. 214 a 228 (Ridge y Lasso); laboratorio 6.6, pp. 251 a 255 (Ridge y Lasso con los datos Hitters). PDF gratuito en statlearning.com.

Documentación de scikit-learn sobre modelos lineales, Ridge y Lasso:
scikit-learn.org/stable/modules/linear_model.html

Datos: Default y Hitters, del libro de James et al. (statlearning.com).