

Introducción y fundamentos estadísticos

Clase 8 · PCA y cierre del módulo

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 22 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Cómo se organiza la sesión de hoy

- ▶ **De 18:00 a 18:30, la última clase del módulo, en dos partes: el análisis de componentes principales y el cierre.**
- ▶ Desde las 18:30, las presentaciones orales del avance: ocho equipos, máximo 10 minutos cada uno más preguntas, en el orden en que se ofrezcan. El tiempo se controla. Recreo de 10 minutos a mitad de las presentaciones.
- ▶ Las slides, en PDF, se suben al Aula hasta el final de la clase (20:30), un envío por equipo con los nombres de sus integrantes.
- ▶ El informe escrito se entrega el viernes 25 de septiembre por el Aula, con un máximo de 7 páginas. Las dos rúbricas están publicadas.

Contenidos de la clase

- ▶ 1. El problema: muchas variables que se mueven juntas.
- ▶ 2. Qué es el análisis de componentes principales y para qué sirve.
- ▶ 3. Cómo se leen las componentes: cuánta variación explica cada una y de qué está hecha.
- ▶ 4. Cuándo conviene usarlo y cuándo no.
- ▶ 5. Cierre del módulo: el hilo de las ocho clases y lo que sigue.

La idea de la clase


- ▶ **Muchas variables que se mueven juntas dicen pocas cosas.**
- ▶ El análisis de componentes principales encuentra cuántas cosas distintas dicen y cuánto pesa cada una.
- ▶ Lo hace construyendo variables nuevas a partir de las originales, en vez de elegir algunas y descartar el resto.
- ▶ Con los números del béisbol de la clase 7: 16 variables que, en lo esencial, son dos.

1. El problema

Muchas variables que se mueven juntas


Las variables del béisbol van en bloques

La matriz de correlaciones de las 19 variables: dos bloques de variables que dicen casi lo mismo



La matriz de la clase 7. Las 7 variables de la carrera se correlacionan entre 0,72 y 0,995; en el bloque de la temporada 1986, turnos, hits y anotadas están entre 0,90 y 0,96. Cada bloque dice casi lo mismo por dentro. La pregunta de hoy: ¿cuántas cosas distintas miden las 16 variables numéricas?

Dos variables que dicen casi lo mismo




¿Cuánto se pierde si las dos variables se reemplazan por una sola?

Cada punto es un jugador, con sus turnos al bate y sus hits acumulados en la carrera. Correlación 0,995: los puntos siguen una diagonal y saber una variable es saber casi la otra.

2. La idea

Reemplazar dos variables por una sola; después, 16 por pocas

Primero: estandarizar las dos variables




A cada variable se le resta su media y se divide por su desviación estándar (el puntaje z de la clase 2). Las dos quedan con media 0 y desviación 1, y el centro de la nube en el origen.

Los puntos siguen una recta: la diagonal




La recta pasa por el centro y sigue la nube de puntos. Es la dirección en que los jugadores se diferencian: hacia arriba y a la derecha, más carrera.

Cada jugador queda en un solo número




A cada jugador se le marca el punto más cercano de la diagonal. Su posición sobre ella es un solo número que reemplaza a sus dos valores: A queda en -1,60, B en -0,48 y C en 2,01. Lo que se pierde es la distancia del punto a la recta, que aquí es casi nula.

Cuánto se conserva y cuánto se pierde



Se mide con la dispersión de las posiciones a lo largo de cada dirección: 1,41 sobre la diagonal, casi toda la que hay, y 0,07 en su perpendicular. Quedarse con la posición sobre la diagonal conserva el 99,8% de la variación y pierde el 0,2%.

La diagonal se llama primera componente



Ninguna otra dirección conserva más variación que la diagonal: por eso se llama primera componente principal. Su perpendicular, la que conserva el resto, es la segunda.

En la práctica: un puntaje ponderado por jugador

$$\text{primera componente} = 0,707 \times z(\text{turnos_carrera}) + 0,707 \times z(\text{hits_carrera})$$

$z = \text{valor estandarizado: (valor - media) / desviación estándar}$


jugador	turnos_carrera	hits_carrera	z turnos	z hits	$0,707 \times z \text{ turnos} + 0,707 \times z \text{ hits}$	1.ª componente
A	19	4	-1,16	-1,11	$0,707 \times (-1,16) + 0,707 \times (-1,11)$	-1,60
B	1.931	491	-0,32	-0,36	$0,707 \times (-0,32) + 0,707 \times (-0,36)$	-0,48
C	6.100	1.583	1,51	1,33	$0,707 \times (1,51) + 0,707 \times (1,33)$	2,01

Con 16 variables es la misma cuenta con 16 términos: $0,33 \times z(\text{turnos_carrera}) + 0,33 \times z(\text{hits_carrera}) + \dots + 0,20 \times z(\text{turnos}) + \dots - 0,01 \times z(\text{errores})$

La posición sobre la diagonal se calcula como un puntaje ponderado, igual que el de la admisión universitaria: cada variable entra con un peso y sale un número por jugador. Aquí los pesos no los fija nadie: se calculan para que ese número separe a los jugadores lo más posible.

El análisis de componentes principales


- ▶ **Busca la dirección en que los datos más se dispersan (la primera componente), luego la que más se dispersa entre las perpendiculares (la segunda), y así hasta tener tantas como variables.**
- ▶ Cada componente es una variable nueva: un puntaje ponderado de las originales, con una parte de la variación total.
- ▶ No usa ninguna respuesta Y: es un método no supervisado (James et al., 2013, p. 375).



¿Para qué sirve?


- ▶ **Para mirar los datos: con 16 variables hay 120 gráficos de dispersión posibles; con dos componentes, uno solo.**
- ▶ Para entregarle a un modelo menos entradas: las componentes reemplazan a un grupo de variables que se repiten.
- ▶ Para entender de qué está hecha la variación: qué variables se mueven juntas y cuánto pesa cada grupo.
- ▶ Lo que no hace: no elige variables ni las descarta, y no sabe qué se quiere predecir.

Con 16 variables, los mismos pasos



Con 16 variables la nube no se puede dibujar, pero el cálculo es el mismo: cada jugador es un punto con 16 coordenadas, se busca la dirección de mayor dispersión, luego la perpendicular que más se dispersa, y así hasta tener 16 componentes, ordenadas de la que más variación conserva a la que menos.

Por qué se estandariza




Con las variables en sus unidades, la primera componente es casi solo `turnos_carrera`, porque su desviación estándar (2.287) es 476 veces la de `temporadas` (4,8): PCA sigue a la variable que más varía en sus unidades. Con cada variable estandarizada (media 0 y desviación 1, como en las clases 2 y 7) todas parten iguales. El libro recomienda estandarizar, salvo que las variables compartan unidad (James et al., 2013, p. 381).

3. Cómo se leen


Cuánta variación explica cada componente y de qué está hecha

Cuánta variación explica cada componente




La primera componente explica el 45,3% de la variación de las 16 variables; la segunda, el 25,7%; la tercera, el 10,8%. Dos componentes reúnen el 71% y tres, el 82%. Para decidir cuántas conservar, el libro sugiere mirar dónde la curva deja de caer (el codo) y advierte que no hay una regla objetiva: depende del uso (James et al., 2013, p. 384).

De qué está hecha cada componente: los pesos




Primera componente: las siete variables de la carrera pesan casi lo mismo (0,29 a 0,34), las de la temporada la mitad (0,19 a 0,23) y la defensa no cuenta: mide cuánta carrera lleva el jugador.
Segunda componente: la temporada 1986 pesa positivo (0,24 a 0,39) y la carrera negativo (-0,12 a -0,26): separa a quien rindió este año más de lo que dice su carrera.

Los 263 jugadores en dos componentes



Cada punto es un jugador y el color, su salario de 1987, que PCA no usó. El salario crece hacia la derecha (correlación 0,64 con la primera componente) y casi nada hacia arriba (0,11 con la segunda): la carrera pesa en el salario; la última temporada, poco. Dos ejes muestran lo que en 16 variables había que leer coeficiente por coeficiente.

El mismo cálculo con las flores de la clase 2



Las cuatro medidas de iris se resumen en dos componentes que reúnen el 96% de la variación. La primera (73%) pesa casi igual el largo y el ancho del pétalo y el largo del sépalo (0,52 a 0,58): el tamaño de la flor. La segunda (23%) es casi solo el ancho del sépalo (0,92). PCA no conoce la especie y aun así las tres quedan separadas a lo largo de la primera componente.

4. Cuándo

Cuándo conviene y cuándo no

¿Cuándo conviene?

- ▶ **Con muchas variables numéricas que se correlacionan en bloques, como en la matriz de la clase 7.**
- ▶ Para mirar los datos en un plano, o para entregarle a un modelo menos entradas.
- ▶ No aporta si las variables son pocas y distintas entre sí: no hay nada que resumir.

Tres precauciones

- ▶ **Las variables categóricas (las dummies de la clase 6) no entran bien en el cálculo: se dejan fuera o se tratan aparte.**
- ▶ Las componentes no siempre tienen una lectura clara. Aquí sí (la carrera; la temporada frente a la carrera), pero no está garantizado.
- ▶ Es no supervisado: la dirección de más variación no es necesariamente la que mejor predice la respuesta. Ridge y Lasso eligen mirando Y; PCA no la mira.

En el código: cinco líneas


```
Z = StandardScaler().fit_transform(X) # 1. estandarizar
pca = PCA().fit(Z)                    # 2. las componentes
pca.explained_variance_ratio_         # 3. cuánto explica
pca.components_                       # 4. los pesos
puntajes = pca.transform(Z)           # 5. los puntajes
```

- El ejemplo completo, con las tablas de pesos y los gráficos de la clase, está en el notebook `08_componentes_principales.ipynb`.

5. Cierre del módulo

Ocho clases, un hilo

El módulo en una página



Cada clase dejó una idea. Juntas, son lo que el módulo enseñó: cómo se llega de una pregunta y unos datos a un resultado, y cómo se lee ese resultado con su incertidumbre.

Lo que sigue en el diplomado

- ▶ **Módulo 2, Visualización e Inteligencia de Negocios: visualización efectiva, narrativas con datos y métricas de negocio.**
- ▶ Módulo 3, Machine Learning para la Toma de Decisiones: aprendizaje supervisado y no supervisado (clustering y PCA en profundidad), evaluación de modelos, redes neuronales y explicabilidad.
- ▶ El Capstone continúa en esos módulos: el primer modelo de hoy es el punto de partida.
- ▶ Lo que se lleva de aquí: leer un resultado con su incertidumbre, juzgar un modelo en datos que no vio, y distinguir describir de encontrar una relación.

Ahora: las presentaciones del avance

- ▶ **Ocho equipos, en el orden en que se ofrezcan. Máximo 10 minutos por equipo; el tiempo se controla. Después, preguntas de la profesora y del curso.**
- ▶ Se evalúa el avance, no un resultado final: el modelo es un primer intento. La exigencia está en el tiempo, la claridad, la explicación de los gráficos y las relaciones, y en advertir qué falta o qué no tiene sentido.
- ▶ Las slides, en PDF, al Aula hasta las 20:30: un envío por equipo con los nombres.
- ▶ El informe escrito, el viernes 25 de septiembre por el Aula: máximo 7 páginas, con su rúbrica publicada.

Referencias

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer. Sección 10.2, pp. 374 a 385: qué es una componente principal, por qué estandarizar, la proporción de variación explicada y cuántas componentes usar. PDF gratuito en statlearning.com.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo "In Depth: Principal Component Analysis", de acceso abierto en jakevdp.github.io/PythonDataScienceHandbook.

Documentación de scikit-learn, `sklearn.decomposition.PCA`:
scikit-learn.org/stable/modules/decomposition.html

Datos: Hitters, del libro de James et al. (statlearning.com), e iris (Fisher, 1936), incluido en scikit-learn.