

Introducción y fundamentos estadísticos

Clase 8 · PCA y cierre del módulo

Daniela Opitz

Diplomado en Ciencia de Datos Aplicada · Departamento de Informática · UTFSM · martes 22 de septiembre, 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

DEPARTAMENTO
DE INFORMÁTICA

Cómo se organiza la sesión de hoy

- ▶ **De 18:00 a 18:30, la última clase del módulo, en dos partes: el análisis de componentes principales y el cierre.**
- ▶ Desde las 18:30, las presentaciones orales del avance: ocho equipos, máximo 10 minutos cada uno más preguntas, en el orden en que se ofrezcan. El tiempo se controla. Recreo de 10 minutos a mitad de las presentaciones.
- ▶ Las slides, en PDF, se suben al Aula hasta el final de la clase (20:30), un envío por equipo con los nombres de sus integrantes.
- ▶ El informe escrito se entrega el viernes 25 de septiembre por el Aula, con un máximo de 7 páginas. Las dos rúbricas están publicadas.

Contenidos de la clase

- ▶ 1. El problema: muchas variables que se mueven juntas.
- ▶ 2. Qué es el análisis de componentes principales y para qué sirve.
- ▶ 3. Cómo se leen las componentes: cuánta variación explica cada una y de qué está hecha.
- ▶ 4. Cuándo conviene usarlo y cuándo no.
- ▶ 5. Cierre del módulo: el hilo de las ocho clases y lo que sigue.

La idea de la clase


- ▶ **Muchas variables que se mueven juntas dicen pocas cosas.**
- ▶ El análisis de componentes principales encuentra cuántas cosas distintas dicen y cuánto pesa cada una.
- ▶ Lo hace construyendo variables nuevas a partir de las originales, en vez de elegir algunas y descartar el resto.
- ▶ Con los números del béisbol de la clase 7: 16 variables que, en lo esencial, son dos.

1. El problema

Muchas variables que se mueven juntas


Las variables del béisbol van en bloques

La matriz de correlaciones de las 19 variables: dos bloques de variables que dicen casi lo mismo



La matriz de la clase 7. Las 7 variables de la carrera se correlacionan entre 0,72 y 0,995; en el bloque de la temporada 1986, turnos, hits y anotadas están entre 0,90 y 0,96. Cada bloque dice casi lo mismo por dentro. La pregunta de hoy: ¿cuántas cosas distintas miden las 16 variables numéricas?

Dos variables que dicen casi lo mismo




¿Cuánto se pierde si las dos variables se reemplazan por una sola?

Cada punto es un jugador, con sus turnos al bate y sus hits acumulados en la carrera. Correlación 0,995: los puntos siguen una diagonal y saber una variable es saber casi la otra.

2. La idea


Reemplazar dos variables por una sola; después, 16 por pocas

Primero: estandarizar las dos variables




A cada variable se le resta su media y se divide por su desviación estándar (el puntaje z de la clase 2). Las dos quedan con media 0 y desviación 1, y el centro de la nube en el origen.

Los puntos siguen una recta: la diagonal




La recta pasa por el centro y sigue la nube de puntos. Es la dirección en que los jugadores se diferencian: hacia arriba y a la derecha, más carrera.

Cada jugador queda en un solo número



- ▶ **La diagonal es una regla: el 0 en el centro de la nube, en las unidades de los ejes, positivo hacia arriba y a la derecha.**
- ▶ A cada jugador se le marca el punto de la regla más cercano y se lee el número: A cae en -1,60, B en -0,48 y C en 2,01.
- ▶ Ese número es la variable nueva: reemplaza a los dos valores de cada jugador, sus turnos y sus hits.

Es un cambio de ejes: las dos componentes



- **Un cambio de sistema de referencia: en vez de turnos y hits, dos ejes nuevos girados 45°, la diagonal y su perpendicular, con el mismo centro.**
- Cada jugador tiene dos coordenadas nuevas. A pasa de (-1,16; -1,11) a (-1,60; 0,03); C, de (1,51; 1,33) a (2,01; -0,13).
- La segunda coordenada es casi 0 para todos: es lo que se descarta al quedarse con un solo número.
- El primer eje se llama primera componente principal; el segundo, segunda.

En la práctica: un puntaje ponderado por jugador

$$\text{primera componente} = 0,707 \times z(\text{turnos_carrera}) + 0,707 \times z(\text{hits_carrera})$$

z = valor estandarizado: $(\text{valor} - \text{media}) / \text{desviación estándar}$

los pesos 0,707 y 0,707 son la dirección de la diagonal: un paso de 1 sobre ella avanza 0,707 en turnos y 0,707 en hits

jugador	turnos_carrera	hits_carrera	z turnos	z hits	$0,707 \times z \text{ turnos} + 0,707 \times z \text{ hits}$	1.ª componente
A	19	4	-1,16	-1,11	$0,707 \times (-1,16) + 0,707 \times (-1,11)$	-1,60
B	1.931	491	-0,32	-0,36	$0,707 \times (-0,32) + 0,707 \times (-0,36)$	-0,48
C	6.100	1.583	1,51	1,33	$0,707 \times (1,51) + 0,707 \times (1,33)$	2,01

Con 16 variables es la misma cuenta con 16 términos: $0,33 \times z(\text{turnos_carrera}) + 0,33 \times z(\text{hits_carrera}) + \dots + 0,20 \times z(\text{turnos}) + \dots - 0,01 \times z(\text{errores})$

Un puntaje ponderado, como el de la admisión universitaria: cada variable entra con un peso y sale un número por jugador. Los pesos son la dirección de la diagonal: un paso de 1 sobre ella avanza 0,707 en turnos y 0,707 en hits. Por eso no los fija nadie: los fija la dirección en que los puntos más se dispersan.

Cuánto se conserva y cuánto se pierde

La variación total es la suma de las varianzas de las coordenadas, y no cambia al girar los ejes

varianza = dispersión al cuadrado (clase 2)

ejes originales

turnos (z): 1,000

+

hits (z): 1,000

=

total: 2,000

ejes nuevos

1.ª coordenada: 1,995

+

2.ª coordenada: 0,005

=

total: 2,000

(dispersiones

$1,412^2 = 1,995$

$0,070^2 = 0,005$)


parte de la 1.ª: $1,995 / 2,000 = 99,8\%$

parte de la 2.ª: $0,005 / 2,000 = 0,2\%$

Quedarse con la posición sobre la diagonal conserva el 99,8% de la variación de los datos y pierde el 0,2%. Sale de las varianzas: las dos variables estandarizadas tienen 1 y 1 (total 2); las dos coordenadas nuevas reparten esa misma variación, 1,995 y 0,005; $1,995 / 2 = 99,8\%$ y $0,005 / 2 = 0,2\%$. Con 16 variables, la variación total es 16 y cada componente se lleva una parte.

El análisis de componentes principales

- ▶ **Busca la dirección en que los datos más se dispersan (la primera componente), luego la que más se dispersa entre las perpendiculares (la segunda), y así hasta tener tantas como variables.**
- ▶ Cada componente es una variable nueva: un puntaje ponderado de las originales, con una parte de la variación total.
- ▶ No usa ninguna respuesta Y: es un método no supervisado (James et al., 2013, p. 375).




¿Para qué sirve?


- ▶ **Para mirar los datos: con 16 variables hay 120 gráficos de dispersión posibles; con dos componentes, uno solo.**
- ▶ Para entregarle a un modelo menos entradas: las componentes reemplazan a un grupo de variables que se repiten.
- ▶ Para entender de qué está hecha la variación: qué variables se mueven juntas y cuánto pesa cada grupo.
- ▶ Lo que no hace: no elige variables ni las descarta, y no sabe qué se quiere predecir.

Con tres variables: tres ejes, y se decide cuántos conservar

Tres variables: cada jugador es un punto en el espacio




Tres ejes nuevos: cuánto se lleva cada uno




Siempre salen tantos ejes como variables. Aquí se agrega una tercera que no tiene que ver con las otras dos, los outs de defensa: el primer eje junta turnos y hits (66,7%), el segundo es la defensa (33,1%) y el tercero, la diferencia entre turnos y hits, casi nada (0,2%). Con dos ejes se conserva el 99,8% y el tercero se descarta. Si las tres variables dijieran cosas distintas, harían falta los tres.

Con 16 variables, los mismos pasos



Con 16 variables la nube no se puede dibujar, pero el cálculo es el mismo: cada jugador es un punto con 16 coordenadas, se busca la dirección de mayor dispersión, luego la perpendicular que más se dispersa, y así hasta tener 16 componentes, ordenadas de la que más variación conserva a la que menos.

Por qué se estandariza




Con las variables en sus unidades, la primera componente es casi solo `turnos_carrera`, porque su desviación estándar (2.287) es 476 veces la de `temporadas` (4,8): PCA sigue a la variable que más varía en sus unidades. Con cada variable estandarizada (media 0 y desviación 1, como en las clases 2 y 7) todas parten iguales. Se estandariza salvo que las variables compartan unidad (James et al., 2013, p. 381).

3. Cómo se leen


Cuánta variación explica cada componente y de qué está hecha

Cuánto explica cada componente: el codo





Las barras caen fuerte al principio (45,3%, 25,7%, 10,8%) y desde la cuarta quedan casi planas (5,4%, 4,4%, 3,2%...). Ese quiebre es el codo. Se conservan las componentes de antes del codo, que son las que explican mucho cada una: aquí, dos o tres.

¿Con cuántas quedarse?




El acumulado dice cuánto se conserva con cada cantidad: con dos componentes, el 71%; con tres, el 82%; con cinco, el 92%; con diez, el 99%. Conservar diez de dieciséis casi no reduce nada: el codo sugiere dos o tres. No hay una regla objetiva: depende de cuánta variación se acepte perder y para qué se usen las componentes (James et al., 2013, p. 384).

De dónde salen los pesos




Los pesos de una componente son la dirección de su eje: cuánto avanza cada variable en un paso de 1 sobre él. Con dos variables, 0,707 y 0,707; con dieciséis, dieciséis pesos cuyos cuadrados suman 1.

De qué está hecha cada componente: los pesos




1.ª componente: la carrera pesa 0,29 a 0,34, la temporada 1986 la mitad (0,19 a 0,23) y la defensa nada: cuánta carrera lleva el jugador. 2.ª: la temporada positiva (0,24 a 0,39) y la carrera negativa (-0,12 a -0,26): quien rindió este año más de lo que dice su carrera.

Los 263 jugadores en dos componentes



Cada punto es un jugador y el color, su salario de 1987, que PCA no usó. El salario crece hacia la derecha (correlación 0,64 con la primera componente) y casi nada hacia arriba (0,11 con la segunda): la carrera pesa en el salario; la última temporada, poco. Dos ejes muestran lo que en 16 variables había que leer coeficiente por coeficiente.

El salario con pocas componentes



- ▶ Con el reparto de la clase 7 (131 y 132 jugadores), el salario se predice con las primeras k componentes. Con 1, 2 o 3, el error de prueba es 321.
- ▶ Mínimos cuadrados con las mismas 16 variables da 347 y con las 19, 342; Lasso 325 y Ridge 316.
- ▶ Dos números por jugador predicen casi tan bien como el mejor modelo de la clase 7 (en 20 repartos le gana a mínimos cuadrados en 17): es la regresión sobre componentes principales (James et al., 2013, sección 6.3.1).

4. Cuándo

Cuándo conviene y cuándo no

¿Cuándo conviene?

- ▶ **Con muchas variables numéricas que se correlacionan en bloques, como en la matriz de la clase 7.**
- ▶ Para mirar los datos en un plano, o para entregarle a un modelo menos entradas.
- ▶ No aporta si las variables son pocas y distintas entre sí: no hay nada que resumir.

Tres precauciones

- ▶ **Las variables categóricas (las dummies de la clase 6) no entran bien en el cálculo: se dejan fuera o se tratan aparte.**
- ▶ Las componentes no siempre tienen una lectura clara. Aquí sí (la carrera; la temporada frente a la carrera), pero no está garantizado.
- ▶ Es no supervisado: la dirección de más variación no es necesariamente la que mejor predice la respuesta. Ridge y Lasso eligen mirando Y; PCA no la mira.

En el código: cinco líneas

```
Z = StandardScaler().fit_transform(X) # 1. estandarizar
pca = PCA().fit(Z) # 2. las componentes
pca.explained_variance_ratio_ # 3. cuánto explica
pca.components_ # 4. los pesos
puntajes = pca.transform(Z) # 5. los puntajes
```

- El ejemplo completo, con las tablas de pesos y los gráficos de la clase, está en el notebook `08_componentes_principales.ipynb`.

5. Cierre del módulo

Ocho clases, un hilo

El módulo en una página



Cada clase dejó una idea. Juntas, son lo que el módulo enseñó: cómo se llega de una pregunta y unos datos a un resultado, y cómo se lee ese resultado con su incertidumbre.

Ahora: las presentaciones del avance

- ▶ **Ocho equipos, en el orden en que se ofrezcan. Máximo 10 minutos por equipo; el tiempo se controla. Después, preguntas de la profesora y del curso.**
- ▶ Se evalúa el avance, no un resultado final: el modelo es un primer intento. La exigencia está en el tiempo, la claridad, la explicación de los gráficos y las relaciones, y en advertir qué falta o qué no tiene sentido.
- ▶ Las slides, en PDF, al Aula hasta las 20:30: un envío por equipo con los nombres.
- ▶ El informe escrito, el viernes 25 de septiembre por el Aula: máximo 7 páginas, con su rúbrica publicada.

Referencias

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer. Sección 10.2, pp. 374 a 385: qué es una componente principal, por qué estandarizar, la proporción de variación explicada y cuántas componentes usar; sección 6.3.1, regresión sobre componentes principales. PDF gratuito en statlearning.com.

VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. Capítulo "In Depth: Principal Component Analysis", de acceso abierto en jakevdp.github.io/PythonDataScienceHandbook.

Documentación de scikit-learn, sklearn.decomposition.PCA:
scikit-learn.org/stable/modules/decomposition.html

Datos: Hitters, del libro de James et al. (statlearning.com).